Laboratorio 5 BD

Predicción de Precios en Marketplaces

Davante

Objetivos del Proyecto

1 Implementar sistema de scraping

Extraer precios de productos de una tienda en línea mediante técnicas de web scraping automatizado, permitiendo la recolección sistemática de datos de precios.

2 Almacenar datos estructurados

Guardar la información obtenida en Google Sheets de manera estructurada, facilitando su posterior análisis y procesamiento para la predicción de precios.

3 Aplicar machine learning

Desarrollar un modelo de regresión lineal para predecir tendencias de precios basado en los datos históricos recopilados, permitiendo anticipar cambios en el mercado.

4 Automatizar con Make

Configurar la ejecución automática del scraping y la predicción en la nube, enviando alertas cuando se detecten cambios significativos en los precios.

5 Aplicar cloud computing

Implementar un servicio en la nube capaz de ejecutar los scripts

Tecnologías Utilizadas

Python

Lenguaje de programación principal para desarrollar los scripts de web scraping, procesamiento de datos y modelo de machine learning, aprovechando su versatilidad y amplia gama de bibliotecas.

AWS

Plataforma de cloud computing utilizada para desarrollar la solución en la nube, permitiendo la ejecución de los scripts de forma remota y automatizada sin necesidad de infraestructura local.

Make

Herramienta de automatización sin código que conectará todos los componentes del sistema, permitiendo la ejecución programada de tareas y el flujo de datos entre diferentes servicios.

Power BI/Airtable

Plataforma de visualización de datos para crear dashboards interactivos que muestren la evolución de precios y las predicciones generadas por el modelo de machine learning.

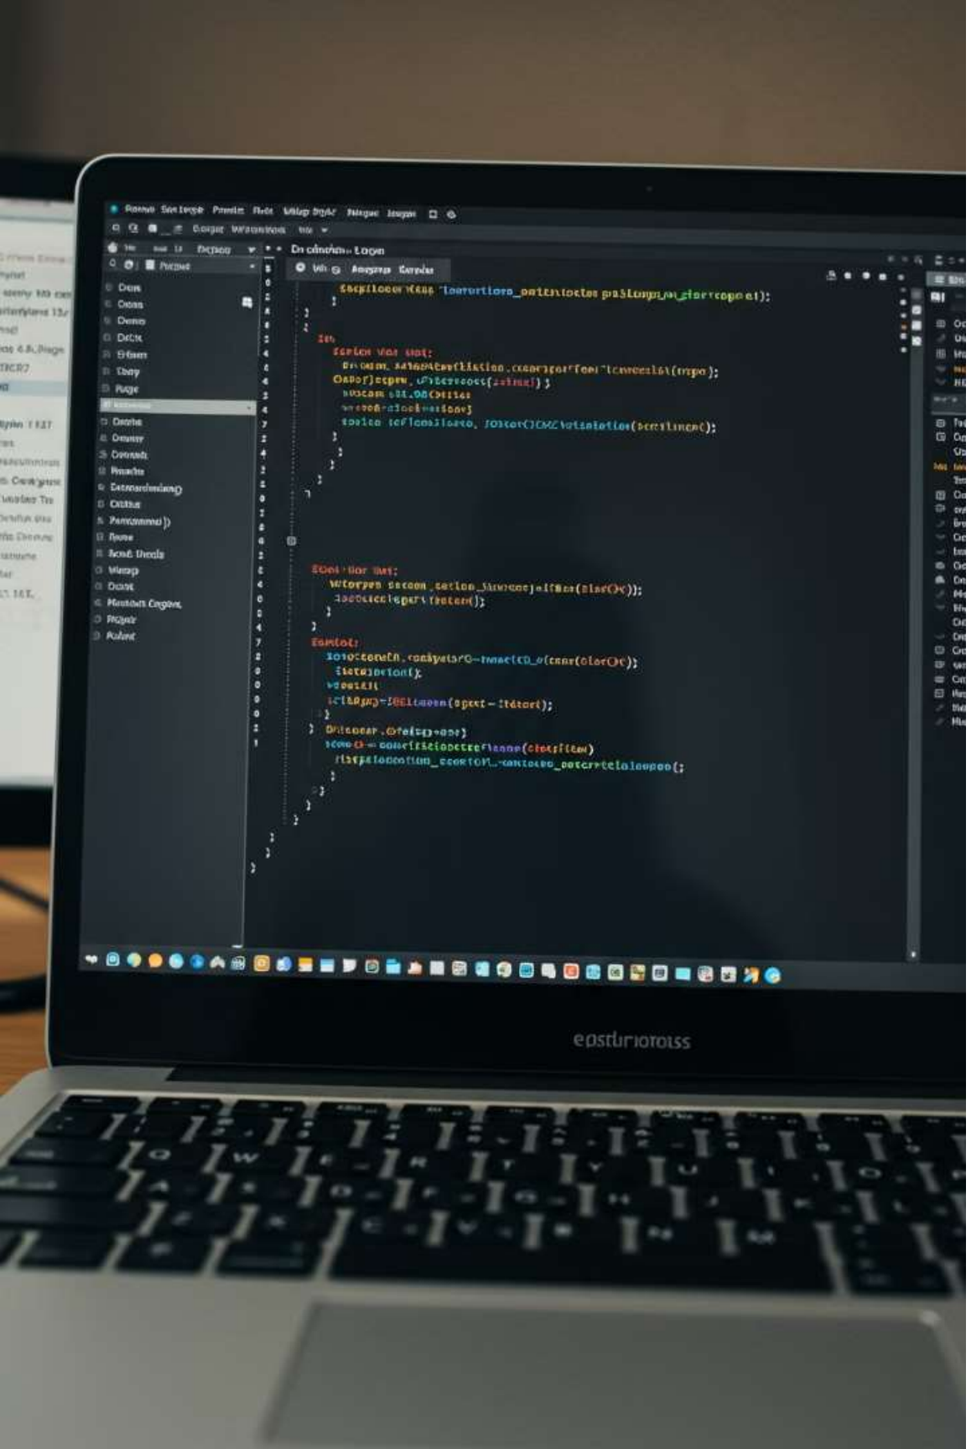

Fase 1: Ejecución en Local

Selección del sitio web

Utilizaremos una tienda en línea de prueba que permita hacer scraping sin restricciones. En este ejemplo, se tomará una web pública de ejemplo, como una librería en línea: https://books.toscrape.com

Organización de archivos

El desarrollo de los scripts para su ejecución en local generará una unidad de almacenamiento con una estructura organizada para mantener el código y los datos separados.

Instalación de dependencias

Instalaremos las librerías necesarias mediante pip: selenium, pandas, gspread, oauth2client, numpy, scikit-learn y requests para el correcto funcionamiento de nuestros scripts.

Script 1: extraer.py

Importación de librerías

El script comienza importando las librerías necesarias: selenium para controlar el navegador, pandas para organizar los datos extraídos, y time para gestionar pausas en la ejecución.

Configuración de Selenium

Se configura ChromeDriver en modo headless (sin interfaz gráfica) para ejecutar el navegador en segundo plano, optimizando recursos del sistema durante el scraping.

Extracción de datos

El script navega a la URL de la tienda, localiza los elementos que contienen información de los libros mediante selectores CSS, y extrae el título y precio de cada libro.

Almacenamiento en CSV

Los datos extraídos se organizan en un DataFrame de pandas y se guardan en un archivo CSV llamado "precios_libros.csv" para su posterior procesamiento.

Script 2: data2google.py

1

Configuración de credenciales

El script utiliza las credenciales de Google Cloud para autenticarse con la API de Google Sheets. Estas credenciales se cargan desde un archivo JSON que contiene la clave de servicio necesaria para acceder a las hojas de cálculo.

2

Lectura del archivo CSV

Se lee el archivo CSV generado por el script de extracción, procesando cada fila para obtener los títulos y precios de los libros. El script maneja posibles errores como la ausencia del archivo.

3

Conexión con Google Sheets

Se establece conexión con la hoja de cálculo "Precios_Libros" previamente creada y compartida con la cuenta de servicio. El script limpia la hoja antes de escribir los nuevos datos.

4

Escritura de datos

Se escriben los encabezados y cada fila de datos en la hoja de cálculo, utilizando el método append_row para agregar cada registro como una nueva fila en Google Sheets.

Script 3: predecir.py

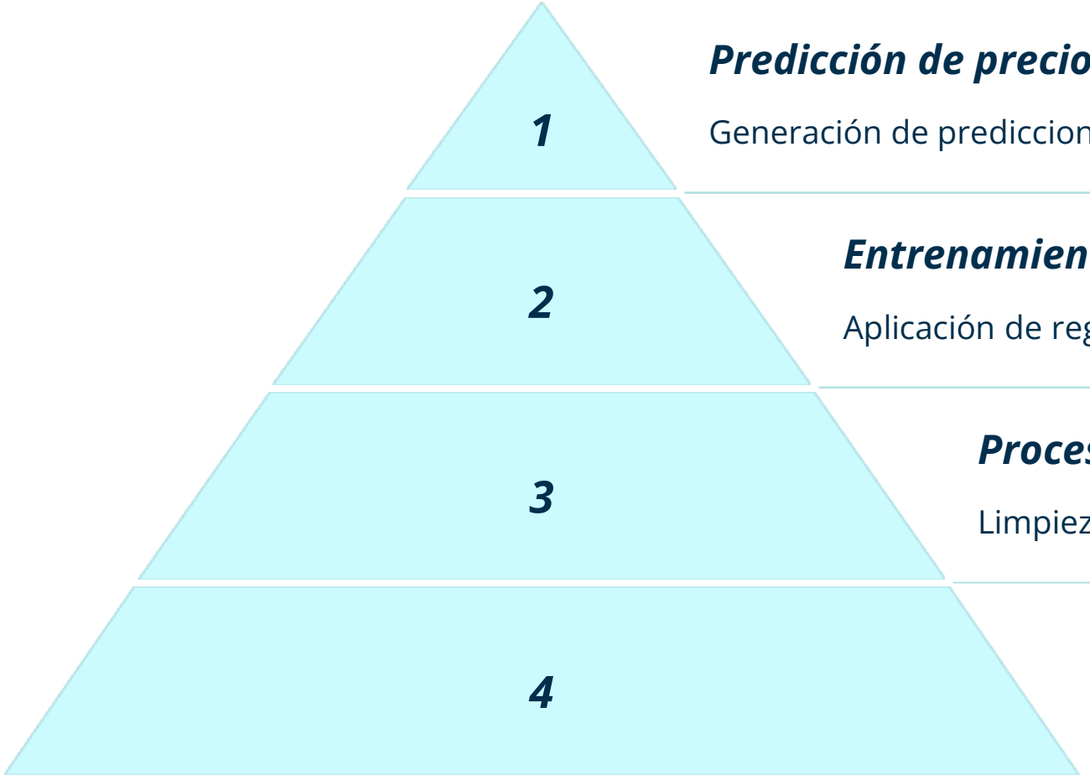

Predicción de precios

Generación de predicciones para 7 días

Entrenamiento del modelo

Aplicación de regresión lineal a los datos

Procesamiento de datos

Limpieza y preparación para análisis

Conexión con Google Sheets

Acceso a datos históricos almacenados

Este script entrena un modelo de regresión lineal con los datos guardados en Google Sheets y realiza una predicción del precio medio de los libros durante los próximos 7 días. El modelo utiliza los datos históricos para identificar tendencias y patrones en los precios.

Las predicciones generadas se almacenan en una segunda hoja del mismo documento de Google Sheets, evitando duplicados y manteniendo un registro ordenado de las proyecciones realizadas a lo largo del tiempo.

Fase 2: Cloud Computing con AWS

1

Crear instancia Windows en AWS

Accede a AWS EC2 Console y lanza una instancia con Microsoft Windows Server 2022 Base, configurando los grupos de seguridad para abrir los puertos RDP (3389) y HTTP (80).

2

Conectar mediante RDP

Utiliza la aplicación 'Conexión a Escritorio Remoto' con la IP pública de tu instancia, el usuario Administrator y la contraseña obtenida con tu archivo .pem.

3

Instalar Python y dependencias

Descarga e instala Python marcando la opción "Add Python to PATH", y luego instala las librerías necesarias mediante pip.

4

Configurar servidor Flask

Crea una aplicación web con Flask que exponga endpoints para ejecutar los scripts de extracción y predicción, así como para descargar el archivo CSV generado.

Automatización con Make

Ejecutar scraping

Módulo HTTP que se conecta al servidor para ejecutar extraer.py cada 24 horas

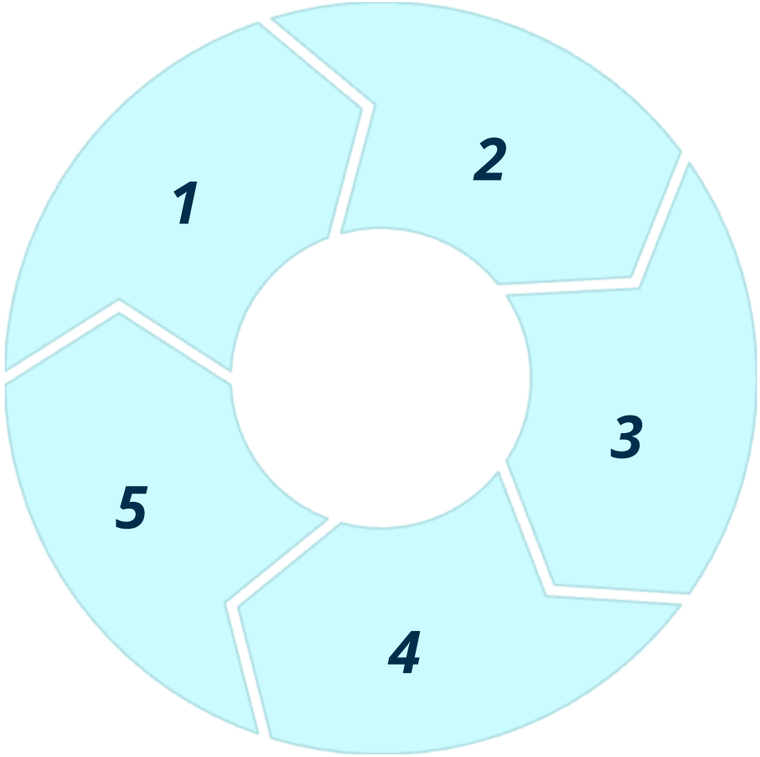

Descargar CSV

Obtiene el archivo generado por el scraping mediante una petición HTTP

Estructurar datos

Convierte el CSV en un formato adecuado para Google Sheets

Guardar en Google Sheets

Almacena los datos procesados en la hoja de cálculo

Ejecutar predicción

Inicia el script de predicción para generar proyecciones de precios

Ampliaciones del Proyecto

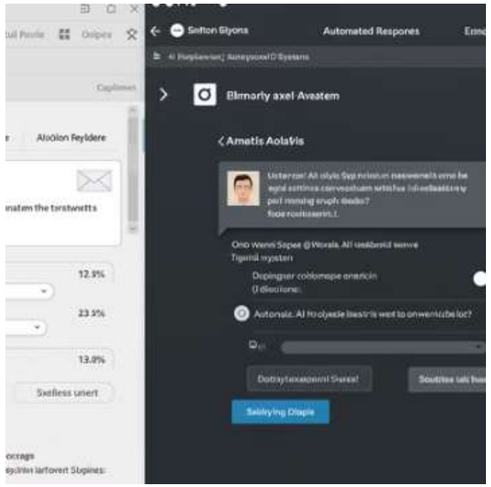

El proyecto puede ampliarse con funcionalidades adicionales como un sistema de alertas que notifique cuando la predicción de precios cambie más del 10%, visualizaciones avanzadas en Power BI, o incluso integraciones con sistemas de respuesta automatizada.

Otras posibles ampliaciones incluyen el análisis de la competencia mediante web scraping de múltiples sitios, la generación de mensajes personalizados para clientes basados en los cambios de precios, o la implementación de modelos de machine learning más complejos para mejorar la precisión de las predicciones.