MEDAC
Instituto Oficial de Formación Profesional

BIG DATA APLICADO

Herramientas para la gestión de soluciones

1

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. Herramientas de almacenamiento de datos 4

/ 3. Herramientas de procesamiento Big Data 4

/ 4. Herramientas de análisis de datos 5

/ 5. Caso práctico 1: “Spark en la vida real” 6

/ 6. Herramientas de visualización 7

/ 7. Caso práctico 2: “Big Data y Tableau en el sector bancario y de las finanzas” 7

/ 8. Resumen y resolución del caso práctico de la unidad 8

/ 9. Bibliografía 9

© MEDAC
Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Conocer las herramientas más relevantes en Big Data para el almacenamiento de datos.

Conocer las herramientas de procesamiento y gestión de los datos.

Conocer herramientas de análisis y visualización de datos.

/ 1. Introducción y contextualización práctica

En un proyecto Big Data hay varias piezas imprescindibles:

- Los datos.
- Los ingenieros y científicos de datos (para establecer las arquitecturas y herramientas de procesamiento sobre las que se trabajarán para extraer el valor de los datos).
- Un CEO convencido de la necesidad de implantación de tecnologías Big Data en su negocio.
- Herramientas Big Data adecuadas.

Este tema se centrará en mostrar las herramientas para:

- Almacenar los datos.
- Procesarlos y gestionarlos.
- Analizarlos.
- Visualizarlos.

A continuación, vamos a plantear el caso práctico del tema.

Escucha el siguiente audio con el planteamiento del problema y revisa la solución en último punto de esta unidad, 'Resumen del tema y resolución del caso práctico'.

Fig.1. Centro de Datos.

Audio intro. "¿Qué tratamiento de datos hay que aplicar?"

https://bit.ly/3OOO11O

/ 2. Herramientas de almacenamiento de datos

Las herramientas de almacenamiento pueden ser de dos tipos: SQL y NoSQL.

Las **BBDD SQL** usan un lenguaje declarativo de acceso a bases de datos relacionales, que permite efectuar consultas/ *queries* para almacenar, modificar y extraer información de forma sencilla.

La principal característica es que las bases de datos SQL siguen un estándar, tanto en la forma en la que se diseñan como en el modo en el que almacenan la información y en el que deben consultarse.

Para conocer las ventajas que ofrecen las BBDD NoSQL frente a las SQL, escucha el siguiente audio:

Audio 1. "NoSQL vs. SQL"
https://bit.ly/3FwxE9n

Como **desventaja de NoSQL** frente a SQL, destacar que no siguen el estándar SQL y, por tanto, no cumplen alguna de las propiedades ACID.

Elegir SQL o NoSQL dependerá del tipo de proyecto, aunque **para proyectos Big Data, las NoSQL suelen ser más convenientes.**

	BBDD SQL	BBDD NoSQL
Modelo de almacenamiento de datos	Tablas con filas y columnas fijas	Documento: archivos JSON; clave-valor: pares clave-valor; Wide-columns: tablas con filas y columnas dinámicas; Grafos: nodos y aristas
Historia del desarrollo	1970, con el foco en reducir los datos duplicados	2000, con el foco en escalabilidad y rápida gestión de cambios (Agile y DevOps)
Esquemas	Rígido	Flexible
Escalado	Vertical (servidores mayores, más caros)	Horizontal (más económico, servidores commodity)
Transacciones multi-record ACID	Se puede	En la mayoría de los casos no se puede (Mongo DB es una excepción)
Joins/Uniones	Suelen ser necesarias	No suelen ser necesarias
Ejemplos	Oracle, MySQL, Microsoft SQL Server, PostgreSQL	Documento: MongoDB y CouchDB; clave-valor: Redis y DinamoDB, Wide-column: Cassandra y HBase; Grafos: Neo4j y Amazon Neptune

Tabla 1. Comparación BBDD SQL y NoSQL.

/ 3. Herramientas de procesamiento Big Data

Existen varias herramientas o infraestructuras Open Source destinadas a gestionar y procesar datos. Son plataformas de alto rendimiento para manipular fuentes de datos por lotes (*batch*) o en tiempo real. Algunas de ellas son: Hadoop, Apache Spark, Storm o Kafka.

Hadoop es la implementación Open Source de MapReduce y es de las más utilizadas para procesamiento de Big Data.

Spark, desarrollado en la Universidad de Berkeley California, es una alternativa a Hadoop, que viene a solventar algunas limitaciones de este. La característica que hace a Spark brillar con luz propia es la capacidad para trabajar en memoria. Permite almacenar los datos en memoria, eliminando las limitaciones de Hadoop para realizar tareas iterativas.

Estos *frameworks* emplean lenguajes de programación determinados en base a su funcionamiento. El lenguaje de programación se emplea, principalmente, para el diseño de algoritmos, depurar y mantener el código fuente de los programas informáticos. Los más utilizados en Big Data son Python, Java, R y Scala.

Fig.2. Herramientas de procesamiento Big Data (Spark y Hadoop).

¡! Sabías que...

Como dato curioso os contaremos que la ciudad que más centros de datos tiene es Londres. El número de centros de datos en Londres asciende a 300.

Por otra parte, destacar que con el uso de servidores de propósito general o *commodity* en Big Data surge la necesidad de utilizar modelos de programación paralelizada. MapReduce es el modelo de programación Big Data más usado en este ámbito.

Vídeo 1. "El Data Center o Centro de Datos"

https://bit.ly/3zixboV

/ 4. Herramientas de análisis de datos

A continuación, se explicarán algunas herramientas para la fase de preparación de datos (análisis exploratorio, preprocesado y acondicionamiento de los datos antes del modelado y análisis de resultados). Estas herramientas no están tan estandarizadas como las de procesamiento y almacenamiento.

- **Hadoop:** Puede llevar a cabo una ingesta de datos paralelizada y combinar distintos flujos de datos no estructurados con distintas fuentes de origen. Es una herramienta que, como hemos visto, sirve para el procesamiento y el análisis. Se estudiará más en detalle en unidades posteriores.

- **Alpine Miner:** Tiene un GUI para crear flujos de trabajo analíticos que incluyen una serie de eventos escalonados que aplican minería de datos.

- **OpenRefine** (formalmente *Google Refine*): Es una de las herramientas Open Source más potentes. Es muy útil para trabajar con conjuntos de datos que presenten dificultadas para su tratamiento.

- **Data Wrangler:** Desarrollada por Standford University. Es una herramienta interactiva para limpiar y transformar los datos. La ventaja es que se puede evaluar la limpieza y transformación de datos en su GUI a través de un subconjunto de datos pequeño, y posteriormente, trasladar las operaciones realizadas (en código Java o Python) a todo el conjunto del entorno de pruebas completo.

Algunos lenguajes y herramientas útiles para la fase de modelado (configuración de los conjuntos de entrenamiento y test, desarrollo del modelo analítico, validación del modelo) son:

- **Python:** Lenguaje de programación que dispone de librerías para llevar a cabo Machine Learning, analítica (Scikit-Learn, Numpy, Scipy, Pandas) y visualización (Matplotlib).
- **R:** Tiene un gran conjunto de capacidades para preparar modelos e interpretarlos. Además, tiene la posibilidad para hacer de interfaz con bases de datos a través de conexión ODBC. Dispone de alrededor de 5000 librerías, lo cual lo hace ideal para análisis de datos y gráficos Big Data.
- **Octave:** Lenguaje de modelado computacional destinado, principalmente, a cálculos numéricos. Muy usado en entornos universitarios.
- **MADlib:** Biblioteca de algoritmos de Machine Learning que pueden ser implementados en bases de datos (PostgreSQL)

Fig.3. Python y R.

/ 5. Caso práctico 1: "Spark en la vida real"

Planteamiento: El proveedor de contenido digital (películas y series) APTV ha montado su negocio utilizando un proveedor de servicios que tiene varios centros de datos repartidos por el mundo. Esto le da la posibilidad de ofrecer contenido en base a la geolocalización. ¿Cómo crees que pueden utilizar Spark?

Nudo: El equipo de ingeniería y operación de APTV usa Spark para medir información como, por ejemplo, las localizaciones donde hay más tráfico (más consumo de contenido). Esto se puede emplear para optimizar los costes de la empresa, actualizando el consumo computacional de cada centro de datos.

Los científicos de datos analizan el contenido consumido por los usuarios para mejorar los sistemas de recomendación de películas y series.

Ambas herramientas (geolocalización y comportamiento del usuario) se pueden implementar con Spark.

Desenlace: En el siguiente diagrama se describe el escenario donde Spark Streaming es utilizado para consumir y agregar la información de los usuarios en tiempo real.

Los datos agregados de geolocalización se almacenan en una BBDD NoSQL.

La información de hábitos de los consumidores es enviada a un módulo de Spark Machine Learning para mejorar un modelo de filtrado colaborativo que permitirá lanzar recomendaciones inteligentes a los usuarios según sus preferencias.

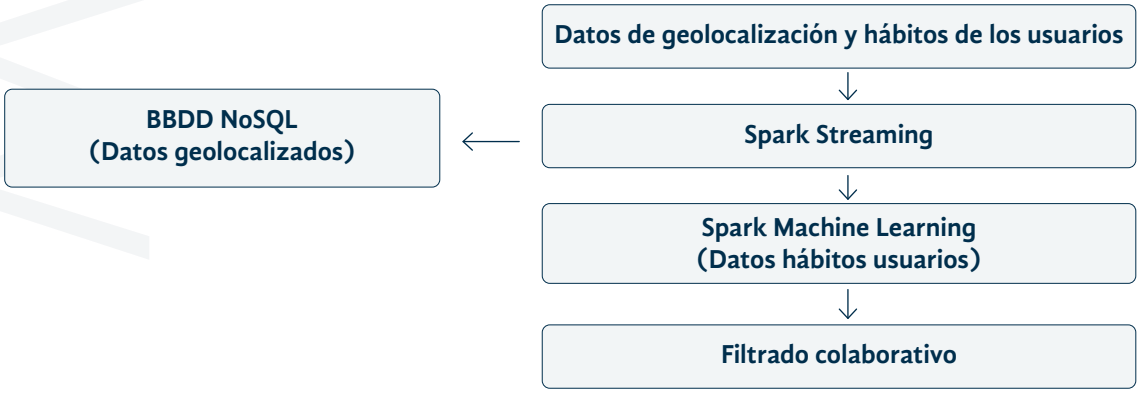

Fig.4. Proyecto Big Data de APTV.

A continuación os presentamos el siguiente recurso pedagógico con información relevante para el tema.

¡! Sabías que...

En el mundo, hay del orden de 6000 centros de datos que consumen entre el 3 y el 6 % de la energía mundial. En las 20 ciudades más importantes del mundo, hay 2200 de esos 6000.

/ 6. Herramientas de visualización

Además de saber cómo almacenar datos, procesarlos y analizarlos, ser un experto en Big Data conlleva saber **comunicar la información que esos datos nos han proporcionado tras su clasificación y estudio**. Para ello, es fundamental **'pintar' los datos en un formato amigable y efectivo** que facilite la labor de interpretación, visualizándolos de manera sencilla y asequible.

Las visualizaciones permiten crear tablas, diagramas, imágenes u otros métodos de representar los datos. La visualización de Big Data no es tan sencilla como con *datasets* de pequeño tamaño.

La razón por la que no se pueden usar las herramientas tradicionales (Excel, por ejemplo) es por cuestión de escalabilidad y dinamismo de los datos. También es importante elegir bien el diagrama más adecuado. Por ejemplo, si tenemos que representar datos geolocalizados, lo más idóneo sería representarlos sobre un mapa, aunque algunas de las características se generen sobre otro gráfico complementario.

Hay una gran variedad de herramientas: SAS Visual analytics, Plotly, Tableau y Power BI son algunos ejemplos que veremos a continuación:

- **Tableau:** Tiene infraestructura Hadoop y usa Hive (que estudiaremos más adelante) para estructurar las consultas, almacenar información y el análisis en memoria. Por todo ello es un mecanismo interactivo entre el usuario y las aplicaciones Big Data. Tableau Desktop es gratuita para estudiantes e investigadores.

- **Plotly:** Es una herramienta *online* gratuita que puede instalarse en Python y R. En este enlace, encontrarás más información.

- **Power BI:** Es un ecosistema de Microsoft para realizar tareas de **inteligencia de negocio**. Hablamos de ecosistema porque lo componen una colección de herramientas que cubren todo el espectro de **la inteligencia de negocio** (modelado de fuentes de datos, análisis y visualización).

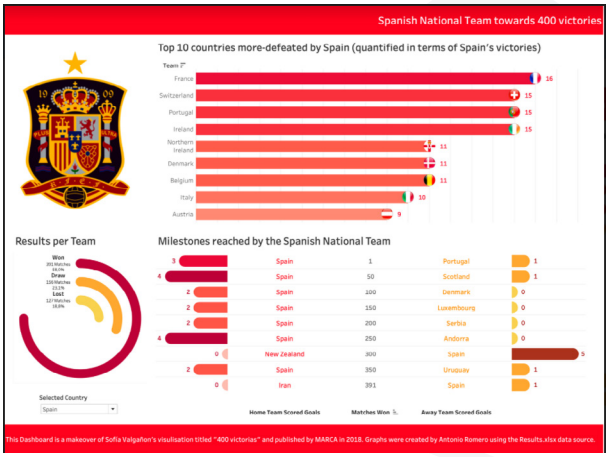

Fig.5. Dashboard en Tableau.

/ 7. Caso práctico 2: "Big Data y Tableau en el sector bancario y de las finanzas"

Planteamiento: Las tecnologías Big Data empoderan a las empresas dándoles acceso casi en tiempo real o streaming para su análisis. Los bancos tienen acceso a datos de transacciones y pueden emplear analítica predictiva para intuir el comportamiento de las ventas, identificar datos atípicos y avisar de operaciones fraudulentas.

Nudo: Antes de usar Tableau, los empleados de MoneySQ monitorizaban los indicadores del negocio manualmente. Esto les obligaba a cargar versiones duplicadas de los datos en plataformas como Excel y otras herramientas *online*.

El proceso de recogida de información relevante y envío de informes solía costar un par de días, lo que significaba que la empresa solo podía tomar decisiones una vez por semana. Esta manera de trabajar era un atraso dentro del mundo bancario dado el entorno cambiante en el que se mueve.

Desenlace: Ahora que tienen Tableau declaran que la herramienta Big Data les permite minimizar el tiempo en la toma de decisiones hasta 1 día. Esto les ha ofrecido ser más versátiles también a la hora de ofrecer productos a sus clientes.

MoneySQ asegura que los análisis antes se hacían por equipos, y en muchas ocasiones, un equipo no entendía lo que había hecho el equipo anterior, lo cual era una manera poco eficiente de trabajar. Por ejemplo: el equipo de crédito tenía Data Scientist, que hacía un trabajo que no se entendía en Marketing (donde no había Data Scientists). Tableau ha resuelto el problema, pues el equipo de crédito plasma los datos de forma visual, lo cual es entendible hasta por personal no técnico.

Fig.6. Logos de MoneySQ y Tableau.

/ 8. Resumen y resolución del caso práctico de la unidad

Como hemos podido visualizar en el vídeo de la unidad, los centros de datos almacenan los datos de las grandes organizaciones en forma, generalmente, de clúster. Para que el corazón del Big Data siga latiendo, cuentan con herramientas de almacenamiento, procesado, análisis y visualización, las cuales hemos estudiado en el tema.

El siguiente esquema resumen podemos ver los conceptos expuestos en esta unidad:

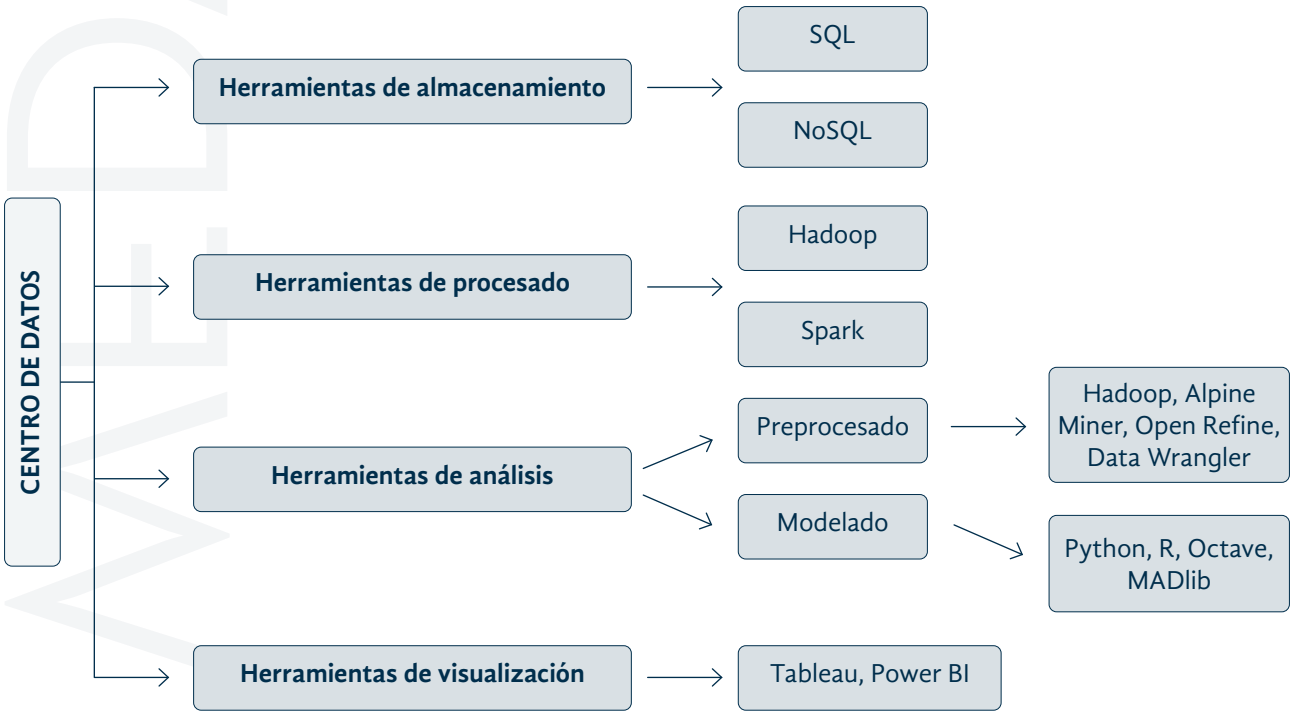

Fig.7. Esquema de la unidad.

Resolución del caso práctico inicial

En este proyecto, sería conveniente usar una base de datos NoSQL (como, por ejemplo, Cassandra) dados los grandes volúmenes de datos y las buenas características de escalabilidad, capacidad para generar réplicas en varios centros de datos, alta disponibilidad, alta tolerancia a fallos, alto rendimiento de escritura y lectura eficiente de las bases de datos NoSQL.

El usuario hará consultas a la base de datos NoSQL para obtener la información deseada, como, por ejemplo, medidas de concentración en un radio de kilómetro de un punto de referencia.

Los resultados devueltos por la consulta deben ser reestructurados para su procesado. Se propone el uso de Python para que, en base a los datos clínicos del usuario y a las medidas de concentración obtenidas en tiempo real de la base de datos NoSQL, determine si el usuario puede salir a dar un paseo por la zona.

Los resultados se mostrarán en un mapa que se podría generar con Python Folium u otra herramienta de visualización, para que el usuario vea el grado de contaminación que hay en su zona en la pantalla, y la recomendación sobre si salir o no a dar un paseo.

/ 9. Bibliografía

Información sobre centros de datos Google (https://www.google.com/intl/es/about/datacenters)

Min Chen, Shiwen Mao y Yin Zhang. *Big Data: Related Technologies, Challenges and Future Prospects*. Springer

Kuan-Ching Li. *Big Data Management and Processing.*CRC

Shoban Babu Siramoju. *Introduction to Big Data: Infraestructure and Networking Considerations*. Horizon Books

Jen Stirrup. *Tableau: Creating Interactive Data Visualisations*. Packt Publishing

MEDAC