MEDAC
Instituto Oficial de Formación Profesional

BIG DATA APLICADO

Tipos de computación

3

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. Tipos de computación 4

2.1. Diferencias entre la computación paralela y distribuida 4

/ 3. Fundamentos de la computación distribuida 5

/ 4. Sistemas de almacenamiento distribuido 6

4.1. Hadoop 7

/ 5. Caso práctico 1: "Sistema de almacenamiento distribuido para datos hospitalarios de la Junta de Andalucía" 7

/ 6. Caso práctico 2: "Sistema de almacenamiento para empresa *data-driven*" 8

/ 7. Resumen y resolución del caso práctico de la unidad 8

/ 8. Bibliografía 9

© MEDAC
Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Exponer en qué consiste la computación distribuida y paralela, paradigma del Big Data.

Conocer los sistemas de almacenamiento distribuidos.

Conocer el concepto de tolerancia a fallos.

/ 1. Introducción y contextualización práctica

Para la ejecución de un proyecto Big Data se necesitan dos aspectos fundamentales: **datos**, una gran cantidad de datos, y una amplia capacidad de **procesamiento** para procesar estos datos de forma rápida.

Esto se traduce en que se requiere de **una gran capacidad computacional** para el desarrollo de un proyecto Big Data.

En concreto, el presente tema se centra, principalmente, en **la aportación de la computación distribuida al ecosistema Big Data** y de los diferentes sistemas de almacenamiento que trabajan con este paradigma en la actualidad.

De manera adicional, se compararán las características de esta computación con el modo de funcionamiento de la distribución paralela y concurrente.

A continuación, vamos a plantear un caso práctico a través del cual podremos aproximarnos de forma práctica a la teoría de este tema.

Escucha el siguiente audio donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

Fig.1. Computadoras en Data Center.

Audio intro. "La computación distribuida"

https://bit.ly/3pfpKeJ

/ 2. Tipos de computación

Si bien la computación distribuida es el tipo de computación más conocida en lo que respecta al ecosistema Big Data, **existen otros tipos de computación**, con sus características específicas, además de aportaciones y ventajas sobre la distribuida. A continuación, vamos a conocer dos de ellos:

- **Computación concurrente**: Tipo de computación que permite **realizar cálculos de manera concurrente, y no uno solo a la vez de forma secuencial**. Con este tipo de computación, varios procesos corren cada uno en un procesador, donde también puede haber varios procesos en un único procesador.

- **Computación paralela**: Es el tipo de computación que **permite ejecutar diferentes tareas al mismo tiempo**. En este caso, los procesos tienen que correr cada uno en un procesador.

Según las definiciones aportadas, pueden ser confundidos los dos paradigmas de computación. Ambas pueden ser descritas como **'múltiples procesos ejecutándose dentro del mismo periodo de tiempo'**. La principal diferencia reside en que en **la computación paralela**, **la ejecución ocurre en el mismísimo instante físico**. Por tanto, es imposible hacer computación paralela en un ordenador con un solo núcleo.

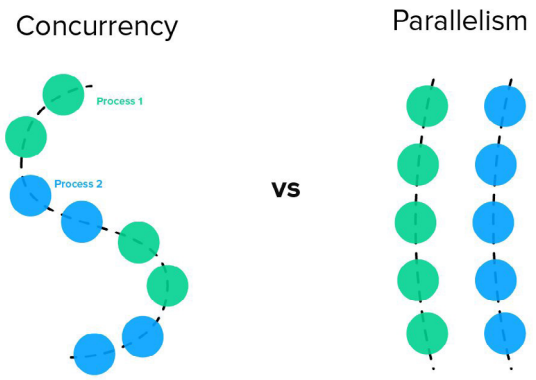

Fig.2. Computación concurrente frente a paralela.

2.1. Diferencias entre la computación paralela y distribuida

Según lo planteado hasta el momento, puede intuirse una similitud muy evidente entre la computación paralela y la distribuida. No obstante, existen diferencias entre ambos modelos de computación, algunas de las cuales se enumeran a continuación:

	PARALELA	DISTRIBUIDA
Funcionamiento	Múltiples procesadores ejecutan múltiples tareas a la vez	Las computadoras en red se comunican y coordinan el trabajo para lograr un objetivo común
Computadoras requeridas	Una única computadora	Múltiples computadoras
Mecanismo de procesamiento	Múltiples procesadores realizan procesamiento	Las computadoras realizan procesamiento según las tareas asignadas

Tabla 1. Diferencias entre computación paralela y distribuida.

Podríamos destacar, por tanto, que la principal diferencia entre los dos tipos de computación analizados es que la computación paralela se centra en la ejecución de tareas por parte de varios procesadores que trabajan de forma simultánea, mientras que en la computación distribuida, varias computadoras conectadas entre sí colaboran para lograr un objetivo común.

En lo que se refiere a los principales usos de ambos tipos de computación, **la computación paralela se emplea para aumentar el rendimiento computacional**, mientras que **la distribuida se utiliza para coordinar el uso de recursos compartidos**.

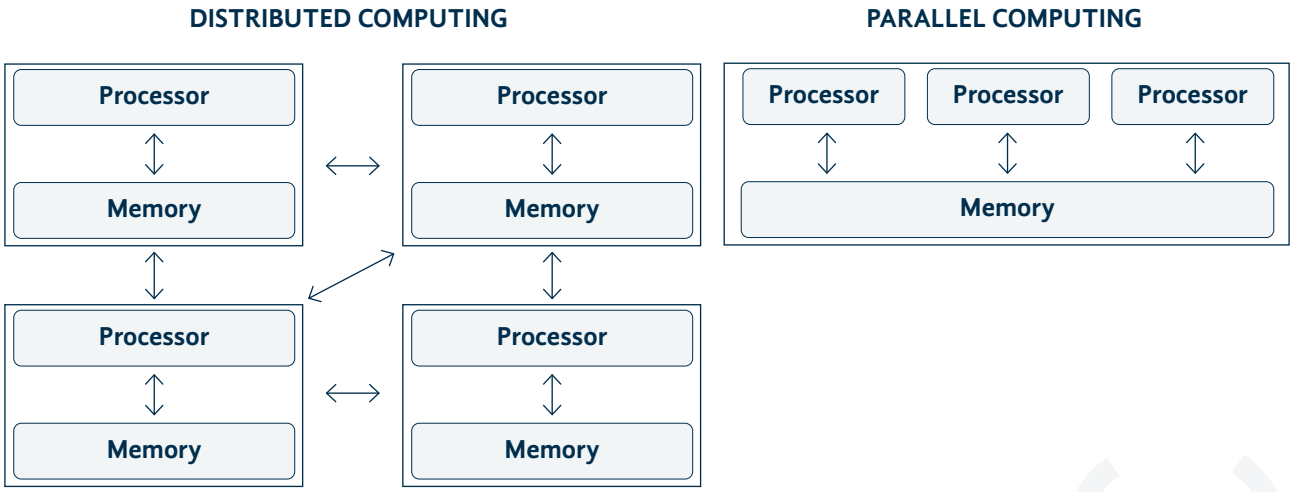

Fig.3. Distribución paralela vs. distribuida.

Enlaces de interés...

Te recomendamos acceder a este enlace, dónde encontrarás las diferencias entre computación paralela y distribuida.

/ 3. Fundamentos de la computación distribuida

De acuerdo con lo previamente definido, la computación distribuida está basada en el **trabajo colaborativo de un conjunto de ordenadores** que trabajan de forma conjunta y coordinada para resolver **un problema común**. A estos ordenadores se les conoce como **nodos**, mientras que a la red computacional formada por el conjunto de ordenadores se la conoce como **clúster**.

En concreto, la computación distribuida se basa en el siguiente **procedimiento**:

1. Una tarea para la que se requiere poder computacional llega a la red de ordenadores, es decir, al clúster.
2. Esa tarea se divide en diferentes subtareas. Estas subtareas se asignan a los diferentes nodos que forman el clúster.
3. Los nodos trabajan en las subtareas que se les han asignado.
4. Cuando los nodos han ejecutado las subtareas que tenían asignadas, se lleva a cabo un proceso de consolidación para la presentación final de resultados.

Este procedimiento culmina con **una significativa aceleración de los tiempos de computación**, siendo especialmente muy empleada en procesos repetitivos en los que intervienen grandes volúmenes de datos.

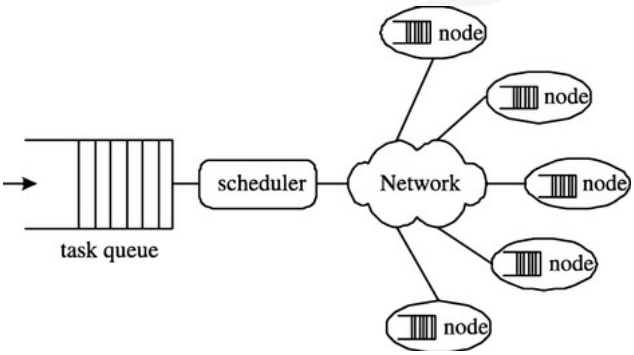

Fig.4. Gráfico descriptivo del trabajo distribuido del clúster.

Este tipo de distribución es **muy empleada por algunas de las empresas tecnológicas más relevantes del momento**, como son Google o Facebook, las cuales almacenan y procesan la gran cantidad de datos de los que disponen con computación distribuida.

Vídeo 1. "El ejemplo de Netflix"
https://bit.ly/3qIpqEJ

/ 4. Sistemas de almacenamiento distribuido

Las bases de datos distribuidas son unos sistemas de almacenamiento diseñados para **almacenar la información de varias computadoras conectadas**. Algunas de las características de estos sistemas de almacenamiento se detallan a continuación:

- La red de computadoras, denominada clúster, **no depende de un único sistema que centralice la información**.
- Su **funcionamiento es independiente del equipo, del sistema operativo, o de la red** a la que se conecta.
- Los nodos se conectan entre sí e **intercambian información de forma constante**, independientemente de su localización.

Además, por la característica distributiva de este tipo de sistemas, presentan **tolerancia a fallos**. Es decir, pueden seguir en funcionamiento en caso de que uno, o varios, de los nodos que componen el clúster no estén operativos.

Audio 1. "Tolerancia a fallos"
https://bit.ly/3Fjafb4

Si bien este tipo de sistemas plantea una serie de **ventajas** que ha incrementado su popularidad en el sector en los últimos años, también posee algunos **inconvenientes** asociados.

Ventajas	Inconvenientes
• Incrementa la disponibilidad, confiabilidad y eficiencia de acceso a la información. • Favorece la escalabilidad. • Permite acceder a la información desde cada nodo, independientemente de la localización.	• Es más dificultoso garantizar la seguridad de la información. • Complejidad de implementación. • Más susceptible a problemas de rendimiento.

Tabla 2. Ventajas e inconvenientes de sistemas de almacenamiento distribuido.

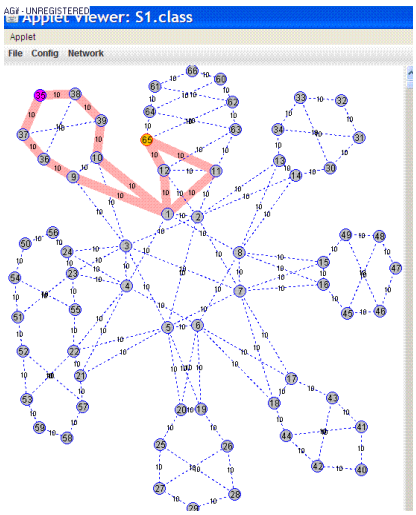

Fig.5. Arquitectura distribuida tolerante a fallos.

4.1. Hadoop

Actualmente, son muchas las soluciones de almacenamiento distribuido presentes en el ecosistema Big Data, no obstante, una de las principales, y sin duda la más popular, es **Hadoop**, que estudiaremos con más detenimiento en unidades posteriores.

Hadoop fue lanzado en 2006, y desde entonces, se ha posicionado como un proyecto de **código abierto creado para almacenar y procesar enormes cantidades de datos en base a su poder de cómputo distribuido.**

Hadoop presenta un amplísimo ecosistema de soluciones, entre las que destaca **Hadoop HDFS**, el sistema de almacenamiento de ficheros distribuido de Hadoop.

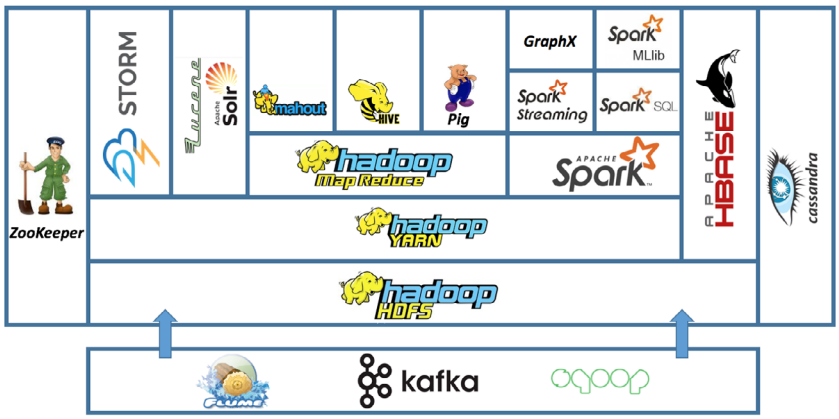

Fig.6. Ecosistema Hadoop.

Enlaces de interés...

En el siguiente enlace, encontrarás algunas pautas de Hadoop, como emblema del almacenamiento distribuido:
https://sitiobigdata.com/2019/06/25/hadoop-para-principiantes/#

/ 5. Caso práctico 1: "Sistema de almacenamiento distribuido para datos hospitalarios de la Junta de Andalucía"

Planteamiento: La Junta de Andalucía quiere actualizar su sistema de almacenamiento de información, considerando algunas de las tecnologías de mayor popularidad y relevancia en el mercado. En concreto, la información principalmente almacenada en estos sistemas es la relativa a los datos personales de los pacientes.

Nudo: ¿Recomendarías un sistema de almacenamiento distribuido para esta solución?

Desenlace: Inicialmente, se debe realizar una evaluación de las principales soluciones de almacenamiento habilitadas en el mercado. En esta línea, se especifica explícitamente la necesidad de evaluar las soluciones técnicas basadas en sistemas de almacenamiento distribuido. Partiendo de los principales requerimientos de negocio, entre los cuales, y más prioritarios, está garantizar la seguridad de los datos almacenados, ¿es una buena opción abordar la implantación de un sistema de almacenamiento distribuido?

Analizando las principales ventajas e inconvenientes asociados a la elección de un sistema de almacenamiento distribuido, encontramos como uno de sus principales inconvenientes el incremento de **dificultad para garantizar la seguridad de la información**. Además, errores de red pueden tener consecuencias graves para la **privacidad de la información** almacenada. Por tanto, contemplando que la privacidad y la seguridad de los datos personales de los pacientes son vitales para la Administración Pública, podría resultar realista **no considerar** un sistema de almacenamiento distribuido como la mejor opción para esta necesidad.

Fig.7. Clúster de nodos.

/ 6. Caso práctico 2: "Sistema de almacenamiento para empresa *data-driven*"

Planteamiento: Una empresa quiere pivotar hacia una estrategia *data-driven*. Para lo que necesita definir una solución tecnológica que le facilite el acceso a su información, incrementando la fiabilidad y accesibilidad de la misma.

Nudo: Para ello, la empresa requiere de un análisis exhaustivo de las diferentes tecnologías disponibles en el ecosistema Big Data, entre las cuales se encuentran los sistemas de almacenamiento distribuido. Partiendo de los principales requerimientos de negocio, donde la prioridad es garantizar la disponibilidad y accesibilidad de la información almacenada, ¿crees que es una buena opción abordar la implantación de un sistema de almacenamiento distribuido?

Fig.8. Disponibilidad de la información almacenada.

Desenlace: La respuesta es afirmativa. Como parte esencial de la propuesta de valor aportada por los sistemas de almacenamiento distribuido está la capacidad ofrecida por estos para facilitar el **acceso a la información**, garantizando el mismo desde cualquier nodo que conforme el clúster. Este planteamiento se refuerza con el incremento de **confiabilidad** de la información almacenada en el sistema.

/ 7. Resumen y resolución del caso práctico de la unidad

En esta unidad, hemos analizado los principales tipos de computación: concurrencia, paralelo y distribuido. A continuación, hemos profundizado en el concepto de computación distribuida, analizando el funcionamiento y modo de trabajo de los computadores que lo conforman.

También hemos analizado los sistemas distribuidos, conociendo algunas de sus principales ventajas e inconvenientes. De la misma forma, hemos determinado la correcta elección de un sistema de almacenamiento distribuido para un caso de uso determinado.

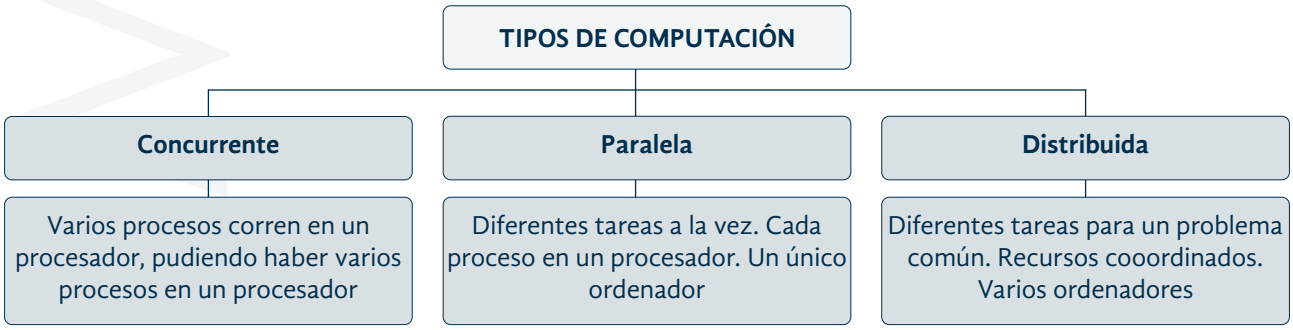

Fig.9. Esquema resumen del tema.

Resolución del caso práctico inicial

Por último, y con el objetivo de dar respuesta al caso práctico planteado al inicio del tema, podemos afirmar que los sistemas distribuidos son muy empleados en las investigaciones científicas, así como en la resolución de casos criptográficos por su modo de funcionamiento concreto. En el cual, varios nodos trabajan de manera coordinada para resolver un problema complejo común, para lo que se requiere de un enorme poder de cómputo, como es el caso de la resolución de casos criptográficos.

Por último, su capacidad para escalar los hace una muy buena elección en aquellos casos en los que los volúmenes de datos tienden a crecer de forma exponencial.

Vídeo 2. "Tipos de computación"
https://bit.ly/3FPCH4T

/ 8. Bibliografía

Programación Paralela. Disponible en:
http://ferestrepoca.github.io/paradigmas-de-programacion/paralela/paralela_teoria/index.html

Diferencia entre computación paralela y distribuida. Disponible en:
https://es.sawakinome.com/articles/programming/difference-between-parallel-and-distributed-computing.html

(Octubre 2015) *¿Qué es el almacenamiento distribuido y por qué Google está silenciosa?* Disponible en:
https://diarioti.com/brand/storpool/que-es-el-almacenamiento-distribuido-y-por-que-google-esta-silenciosa

Base de datos distribuida. ¿Qué es? Características. Disponible en:
https://ayudaleyprotecciondatos.es/bases-de-datos/distribuida/

SAS. Hadoop. ¿Qué es y por qué es importante? Disponible en: https://www.sas.com/es_es/insights/big-data/hadoop.html

(Octubre 2021) *¿Qué es HDFS? Introducción.* Disponible en: https://aprenderbigdata.com/hdfs/

Wikipedia. https://es.wikipedia.org/wiki/Wikipedia:Portada