MEDAC
Instituto Oficial de Formación Profesional

BIG DATA APLICADO

Ecosistema Hadoop

4

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. Breve historia de Hadoop 4

/ 3. Componentes Hadoop: HDFS y Map Reduce 4

3.1. Hadoop Distribuited File System (HDFS) 5

3.2. Map Reduce 5

/ 4. Otras herramientas del ecosistema Hadoop 6

4.1. Captura y manipulación de datos 6

4.2. Almacenamiento y programación distribuida 7

4.3. Planificación, Machine Learning y administración 8

/ 5. Caso práctico 1: "Elección de ecosistema" 9

/ 6. Caso práctico 2: "Selección de las herramientas más apropiadas para la necesidad específica" 9

/ 7. Resumen y resolución del caso práctico de la unidad 10

/ 8. Bibliografía 11

© MEDAC
Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Proveer de una visión general del ecosistema Hadoop.

Conocer las principales herramientas del ecosistema.

/ 1. Introducción y contextualización práctica

Uno de los ecosistemas Big Data más populares y relevantes de nuestros tiempos es Hadoop. Este es un ecosistema de herramientas con diferentes propósitos vinculados con Big Data. Está basado en **código abierto y computación distribuida**, y fue diseñado para almacenar datos y ejecutar aplicaciones en clústeres de hardware.

En el presente tema, vamos a profundizar en Hadoop, conociendo su breve historia, sus principales herramientas en cuestión de almacenamiento, Machine Learning, o bases de datos NoSQL, además de sus componentes principales, focalizándonos en **HDFS y Map Reduce**.

Fig.1. Hadoop.

A continuación, vamos a plantear un caso práctico a través del cual podremos aproximarnos de forma práctica a la teoría de este tema.

Escucha el siguiente audio donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

Audio intro. "Barreras para la implantación de Hadoop"

https://bit.ly/3esQlyR

/ 2. Breve historia de Hadoop

Todo empieza con Nutch, un buscador web de código abierto cuyo propósito era la realización de búsquedas más rápidas. Para ello, Nutch basaba su funcionamiento en la distribución de datos y cálculos en diferentes computadoras para ejecutar múltiples tareas de manera simultánea.

Para empezar esta breve historia, nos remontamos a 2006. En ese año, **Doug Cutting**, uno de los **fundadores de Nutch,** decidió unir su proyecto a Yahoo, añadiendo también ideas basadas en otro de los grandes buscadores del momento: Google.

Dos años más tarde, en 2008, Nutch se dividió en dos grandes proyectos:

- **Nutch**: Buscador web.
- **Hadoop**: Proyecto de cómputo y procesamiento distribuido.

Desde entonces, Hadoop se ha consolidado como uno de los principales ecosistemas Big Data con una serie de ventajas:

- **Amplias capacidades de almacenamiento y procesamiento** de grandes volúmenes de datos de diversa procedencia, resultantes de la computación distribuida inherente al ecosistema.
- Hadoop realiza **copias de seguridad** de forma automática de todos los datos que almacena.
- Gracias a su **escalabilidad** aportada por el modelo de computación distribuida empleado, Hadoop es **idóneo para sistemas asociados a negocios en expansión**.
- Es **open source**. Por tanto, de bajo coste.

Fig.2. Doug Cutting con Hadoop.

/ 3. Componentes Hadoop: HDFS y Map Reduce

Hadoop lo forman, principalmente, dos componentes: ***Hadoop Distributed File System*** **(HDFS),** centrado en el almacenamiento y en la distribución de información, y **Map Reduce,** más enfocado al **procesamiento de los datos** almacenados.

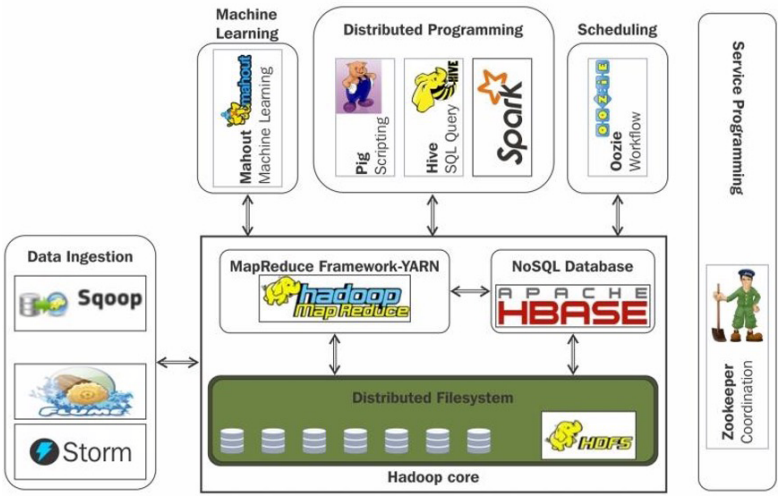

Fig.3. Ecosistema Hadoop.

3.1. *Hadoop Distribuited File System* (HDFS)

HDFS es un sistema de archivos distribuido que permite repartir la información a lo largo de los nodos que componen el clúster. HDFS divide los datos en bloques, de forma que la caída de un nodo específico no implique la pérdida de acceso sobre los datos almacenados en primera instancia sobre ese nodo.

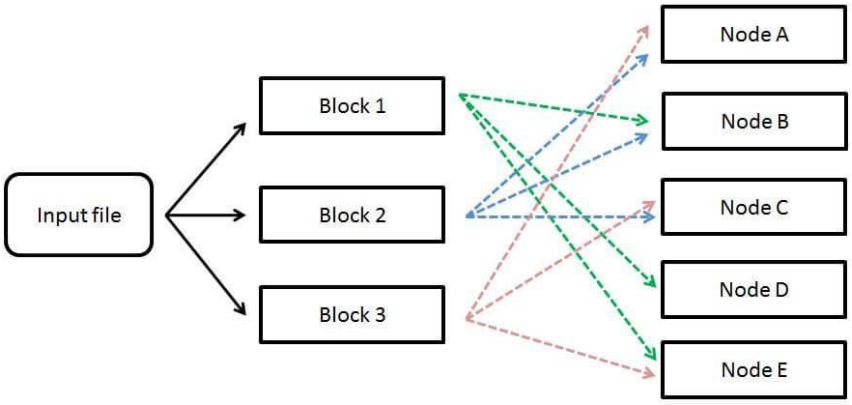

Fig.4. Esquema de funcionamiento de HDFS.

Enlaces de interés...

A continuación, en el siguiente enlace, encontrarás una descripción sobre HDFS y su funcionamiento: https://www.unir.net/ingenieria/revista/que-es-hdfs/

3.2. Map Reduce

Map Reduce es el framework de Hadoop que permite el procesado **paralelo** de grandes volúmenes de datos procedentes de diversos conjuntos.

Map Reduce es en sí una técnica de procesamiento basada en un modelo de computación distribuida. Emplea el lenguaje de programación de Java. Su modelo de funcionamiento consiste en **dividir el trabajo a desarrollar en pequeños problemas que, a su vez, acaban siendo tareas**, las cuales se resuelven de forma individual, permitiendo agrupar soluciones al final del proceso.

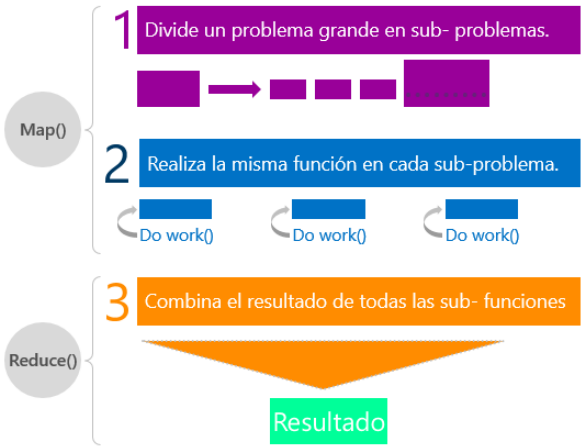

Fig.5. Funcionamiento de Map Reduce.

A continuación encontrarás el siguiente enlace de interés con información relevante para el tema:

Enlaces de interés...

En el siguiente enlace, encontrarás una descripción sobre Map Reduce y su funcionamiento: https://www.youtube.com/watch?v=GOJa5MqfQvY

/ 4. Otras herramientas del ecosistema Hadoop

Independientemente de los dos componentes principales previamente comentados (HDFS y Map Reduce), Hadoop cuenta con **más herramientas de aplicación específica** para distintos propósitos determinados, dentro del campo del Big Data, las cuales vamos a explorar a continuación. Estas herramientas las dividimos **según su propósito** en:

- **Captura y manipulación de datos.**
- **Almacenamiento.**
- **Programación distribuida.**
- **Planificación.**
- **Machine Learning.**
- **Administración.**

4.1. Captura y manipulación de datos

Dentro de esta categoría, podemos encontrar:

- **Sqoop**: Herramienta que permite a su usuario **transferir grandes cantidades de datos** entre Hadoop y bases de datos relacionales.

- **Flume**: Herramienta distribuida para la recolección y transmisión de datos de diversa procedencia. Ofrece una arquitectura basada en la transmisión de **datos por streaming altamente flexible**. Muy empleada en la obtención de datos desde **redes sociales** a mensajes de correo electrónico.

- **Apache Storm**: Herramienta tolerante a fallos y de alta disponibilidad que permite recopilar datos en tiempo real desde diversas fuentes de datos. Diseñado para procesar **datos en streaming.** Muy empleado en **proyectos IoT**.

- **Chukwa:** Proyecto construido para capturar y analizar grandes volúmenes de datos, principalmente **logs**. Hereda las características de Hadoop, pues usa HDFS y Map Reduce.

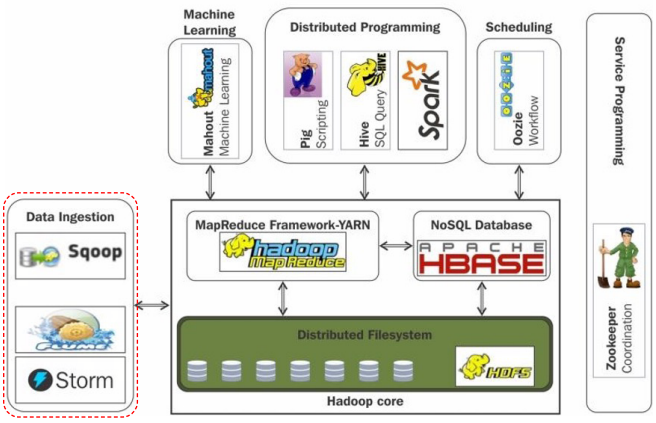

Fig.6. Herramientas de captura y manipulación de datos.

En el siguiente vídeo podrás encontrar información relevante para el tema:

Vídeo 1. "Cloudera"
https://bit.ly/3FPG8Ix

4.2. Almacenamiento y programación distribuida

A continuación, exponemos las herramientas de dos categorías:

A. Almacenamiento

HBASE: Base de datos distribuida de Hadoop. Dado que se basa, evidentemente, en Hadoop, funciona sobre HDFS y presenta gran escalabilidad. Es una base **NoSQL**, muy empleada para el **registro y consulta de datos en tiempo real**.

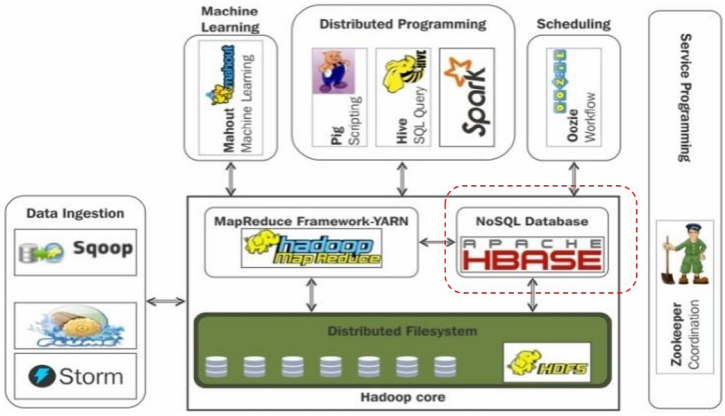

Fig.7. Herramientas de almacenamiento.

B. Programación distribuida

» **HIVE**: Herramienta de *Data Warehouse* empleada para la consulta y registro de datos. Cuenta con su propio lenguaje para consultas, **Hive QL**.

» **Pig**: Herramienta de Hadoop que permite analizar grandes volúmenes de datos procedentes de diversas fuentes. De la misma forma que HIVE, utiliza un lenguaje de programación propio de alto nivel, **PigLatin**.

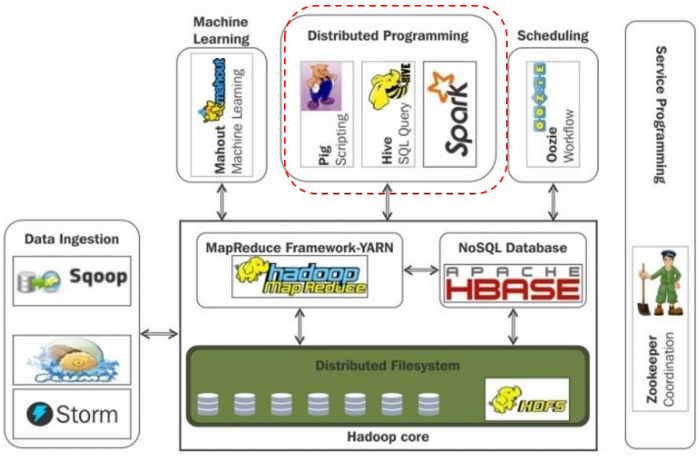

Fig.8. Herramientas de programación distribuida.

4.3. Planificación, Machine Learning y administración

Finalmente, concluimos esta sección con las tres últimas categorías:

A. Planificación

Oozie: Herramienta de Hadoop que permite **definir flujos de trabajo** para buscar soluciones a problemas planteados. Dado que permite definir itinerarios de trabajo complejos sobre los datos almacenados en HDFS, está muy orientado a usuarios principiantes en el ecosistema.

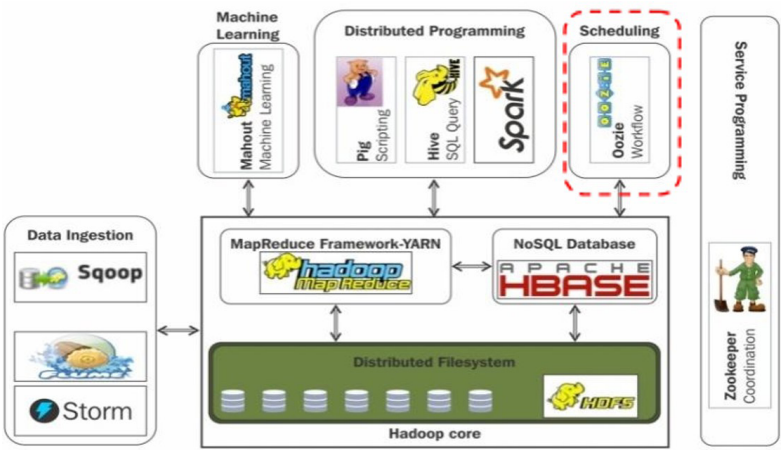

Fig.9. Herramienta de planificación.

B. Machine Learning

Mahout: Herramienta que proporciona una biblioteca de algoritmos para aplicar Machine Learning o aprendizaje automático. Soporta algoritmos de clasificación, regresión, clustering y recomendación.

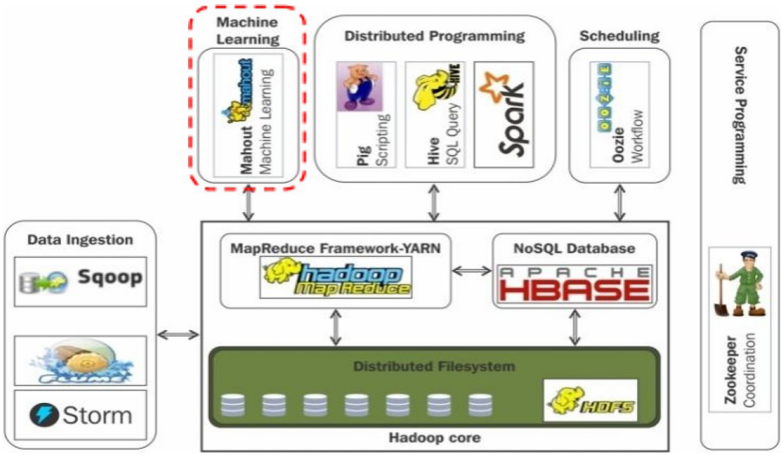

Fig.10. Herramienta de Machine Learning.

C. Administración

Zookeeper: Herramienta que provee una infraestructura centralizada y los servicios correspondientes, que permiten la sincronización del clúster, además de administrar y gestionar los distintos procesos de los sistemas distribuidos.

Además de Zookeeper, existen otras herramientas focalizadas a la administración, como **Hue o Avro.**

Audio 1. "Más herramientas del ecosistema Hadoop"
https://bit.ly/3peeizN

/ 5. Caso práctico 1: "Elección de ecosistema"

Planteamiento: Una empresa tiene como firme propósito empezar su estrategia *data-driven*. Para ello, **requiere de un framework, a ser posible libre de licencia, que permita responder a las diferentes necesidades prácticas contempladas** en proyectos de datos: recolección de grandes volúmenes de datos de diversa procedencia, administración de la infraestructura, almacenamiento y análisis estadístico y predictivo, entre otras.

Nudo: Como analista de la empresa, procedes a explorar las distintas opciones de mercado, buscando las principales opciones basadas en código abierto que provean de las capacidades necesarias para dar respuestas a los requerimientos fundamentales de un proyecto Big Data.

Desenlace: Naturalmente, con estos requerimientos de negocio, Hadoop pasa a posicionarse como una muy buena alternativa sobre la que pivotar la estrategia Data de la empresa. Como hemos visto en esta unidad, **Hadoop es un marco de trabajo muy eficiente sobre el que obtener el máximo beneficio posible del análisis de los datos, basado en código abierto.** De forma adicional, Hadoop cuenta con un amplio ecosistema de herramientas para dar soporte a diferentes funcionalidades en un proyecto Big Data. Algunas de estas funcionalidades se detallan a continuación, con las diferentes herramientas asociadas, cada una con su propuesta de valor y características específicas asociadas:

- **Captura y manipulación de datos:** Sqoop, Storm, Flume.
- **Almacenamiento:** HDFS, HBASE.
- **Programación distribuida:** HIVE, Pig.
- **Planificación:** Oozie.
- **Machine Learning:** Mahout.
- **Administración:** Zookeeper, Hue, Avro.

Fig.11. Apache Hadoop.

/ 6. Caso práctico 2: "Selección de las herramientas más apropiadas para la necesidad específica"

Planteamiento: La empresa del caso práctico anterior, finalmente, ha apostado por Hadoop. Ahora, lo que necesita es identificar las herramientas que más se adecúen a sus necesidades de negocio. Hadoop presenta un amplio catálogo de herramientas, cada una con unas particularidades, unas ventajas y unos inconvenientes específicos.

Nudo: En concreto, la empresa requiere de **un sistema de almacenamiento** para almacenar grandes volúmenes de datos, la mayoría de los cuales serán **recopilados por dispositivos IoT**. Por último, se requiere de la realización de algoritmos que provean de **predicciones en base al histórico de datos almacenados**.

¿Qué les recomendarías?

Desenlace: El ecosistema Hadoop provee de diferentes herramientas, cada una con un propósito determinado. Entre ellas se encuentran herramientas que habilitan el almacenamiento de grandes volúmenes de datos, otras que se encargan de recopilar y procesar datos en streaming y, naturalmente, otras para desarrollar algoritmos de Machine Learning sobre los grandes volúmenes de datos almacenados.

En este caso, lo ideal sería seleccionar **Hadoop HDFS** para el almacenamiento de los grandes volúmenes de datos **Apache Storm,** herramienta especializada en la recolección y procesamiento de datos en tiempo real, procedentes de dispositivos IoT, y **Mahout,** herramienta para el desarrollo de algoritmos de Machine Learning que cuenta entre sus algoritmos con algunos destinados a la clasificación, regresión, clustering o sistemas de recomendación.

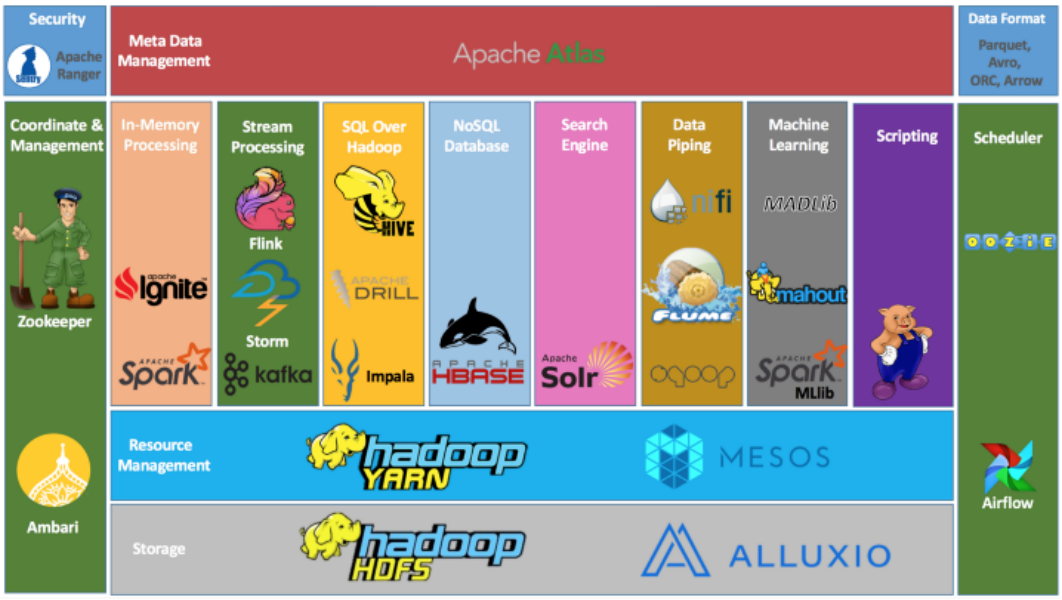

Fig.12. Diferentes herramientas del ecosistema Hadoop.

/ 7. Resumen y resolución del caso práctico de la unidad

En esta unidad, hemos conocido el ecosistema Hadoop, sus principales componentes y las herramientas específicas que lo conforman.

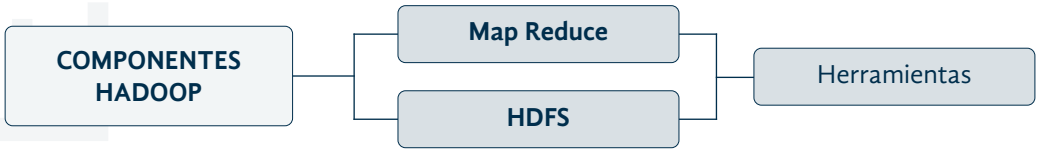

Fig.13. Mapa conceptual de los principales componentes de Hadoop.

Para las principales herramientas, hemos estudiado la tecnología y funcionalidad que la sustentan, así como su propuesta de valor y propósito.

De la misma forma, hemos planteado dos casos prácticos con el objetivo de asentar lo aprendido y explorado del ecosistema Hadoop.

Resolución del caso práctico inicial

Por último, en lo que se refiere al caso práctico propuesto en la introducción de la unidad, si bien Hadoop presenta innumerables ventajas para las empresas que quieran pivotar su estrategia tomando como base el análisis de sus datos, su utilización también plantea una serie de retos, como son:

- Contar con personal interno experto en el ecosistema Hadoop y en sus principales componentes para el desarrollo.
- El reto cultural que, aún en nuestros días, sigue suponiendo basar la estrategia en una herramienta de desarrollo open source, sin soporte de licencias.
- Dificultad de integración con la infraestructura propia de las empresas u organizaciones.
- El reto cultural de virar hacia una estrategia *data-driven*.

Vídeo 2. "Hadoop"
https://bit.ly/3t7SKYj

/ 8. Bibliografía

SAS. Hadoop. *¿Qué es y por qué es importante?* Disponible en: https://www.sas.com/es_es/insights/big-data/hadoop.html

(Octubre 2021) *¿Qué es HDFS? Introducción.* Disponible en: https://aprenderbigdata.com/hdfs/

(Agosto 2012) Verne Team. *¿Qué es Map Reduce?* Disponible en: https://blogvisionarios.com/e-learning/articulos-data/que-es-mapreduce/

Bejarano, P. G. *Hadoop, la plataforma open source que lidera Big Data.* Disponible en: https://blogthinkbig.com/hadoop-open-source-big-data

(Septiembre 2017) *Paloma Recuero de los Santos.* Disponible en: https://empresas.blogthinkbig.com/hadoop-por-dentro-ii-hdfs-y-mapreduce/

(Mayo 2016) Datahack. *Ecosistema Hadoop.* Disponible en: https://www.datahack.es/ecosistema-hadoop/