MEDAC
Instituto Oficial de Formación Profesional

BIG DATA APLICADO

Integridad de los datos

5

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. Integridad de los datos: ¿Qué es y qué supone? 4

/ 3. Riesgos asociados a la integridad lógica 5

/ 4. Principales mecanismos para garantizar la integridad 6

/ 5. Caso práctico 1: "Comprobación de integridad de los datos como fase previa" 7

/ 6. Caso práctico 2: "Riesgos sobre la integridad de los datos" 7

/ 7. Resumen y resolución del caso práctico de la unidad 8

/ 8. Bibliografía 9

© MEDAC
Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Conocer qué es la integridad de los datos y sus diferencias con la calidad de los mismos.

Conocer los principales mecanismos para garantizar la integridad de los datos.

Conocer las actividades más destacables que ponen en riesgo la integridad de los datos.

/ 1. Introducción y contextualización práctica

Los datos se posicionan como un importante recurso que las empresas ponen a disposición de su negocio, para asegurar una toma de decisiones objetiva y realista. Desde ese punto de vista, **garantizar la calidad de estos datos es una necesidad ineludible**.

En concreto, uno de los criterios más destacables en los que se basa la calidad del dato es la integridad, la temática esencial de la presente unidad. Conoceremos los **principales mecanismos para asegurar la integridad de los datos**, así como las **comprobaciones más relevantes a realizar** para garantizarla.

A continuación, vamos a plantear un caso práctico, a través del cual podremos aproximarnos de forma práctica a la teoría de este tema.

Escucha el siguiente audio, donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

Fig.1. Criterios de Calidad de Datos.

Audio intro. "Calidad de los datos. Riesgos"
https://bit.ly/33amhpp

/ 2. Integridad de los datos: ¿Qué es y qué supone?

En la introducción, hablábamos de la integridad de los datos como uno de los principales criterios que definen su calidad. No obstante, ¿qué es, en sí, la integridad de los datos y qué supone su ejecución?

Es el conjunto de capacidades que hacen referencia a la **precisión, integralidad y coherencia**. Dentro de estos aspectos, están incluidos, también, otros importantes aspectos, como el **cumplimiento en materia de normativa** (por ejemplo, en Europa la integridad está estrechamente vinculada con GDPR) y la **seguridad de acceso de terceros a la información**.

Sobre este último aspecto, a menudo, la integridad de los datos se confunde con la seguridad. **La seguridad es uno de los muchos aspectos que determinan la integridad** y, bajo ningún caso, es un sustitutivo de ella. De la misma manera, no es recomendable confundir la integridad con la calidad del dato. De igual forma que **la seguridad es un aspecto que determina la integridad, la integridad es uno de los criterios que determinan la calidad del dato**.

Cuando, sobre una serie de datos, se garantiza integridad, la información será **única, completa, precisa y fiable**, independientemente de aspectos tales como el tiempo de almacenamiento, los usuarios con acceso a los mismos, etc.

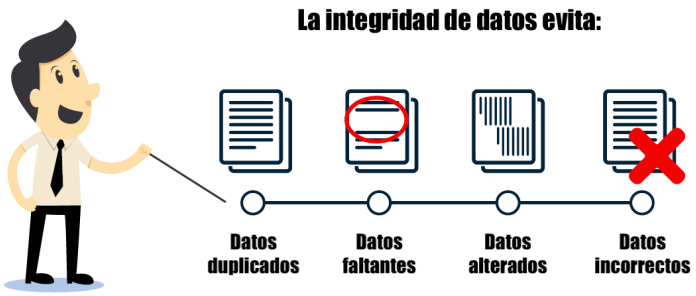

Fig.2. ¿Qué supone la integridad de los datos?

Enlaces de interés...

En el siguiente enlace, encontrarás un artículo acerca de cómo las empresas pueden asegurar la integridad de los datos y cómo controlan su información generada: Enlace.

Sobre el concepto global de integridad, existen una serie de tipos de integridad. Destacan **la integridad física** y la **integridad lógica** de los datos.

En concreto, **la integridad física obedece al estado de los datos tal y como se conservan**. Los principales riesgos que pueden poner en peligro esta integridad son, por ejemplo: un ataque informático, un daño en los servidores, etc.

La integridad lógica, sobre la cual vamos a pivotar principalmente los riesgos detallados a continuación, es el tipo de integridad que **protege a los datos de los errores humanos o los cometidos por ausencia de buenas prácticas** en su tratamiento.

/ 3. Riesgos asociados a la integridad lógica

Podemos destacar:

- **Integridad de la entidad:** La integridad de la entidad es la característica de la integridad encargada de garantizar que un registro existe una única vez en la base de datos. O lo que es lo mismo, que **la información no está duplicada en la base de datos**.

- **Integridad referencial:** Está **relacionada con las relaciones existentes entre las tablas de datos**. En otras palabras, si algún elemento está presente en más de una tabla, debe existir una relación entre ambas. De esta manera, se evita lo conocido como un **registro huérfano**.

- **Integridad del dominio:** Es el tipo de integridad que determina **los valores aceptables que una columna puede tener**, en función de una serie de variables: restricciones, tipos de información, etc.

- **Integridad definida por el usuario:** Tipo de integridad asociada a las reglas lógicas que los propios usuarios aplican sobre los datos.

El incumplimiento de estos diferentes tipos de integridad puede verse en riesgo por algunos de los siguientes factores:

- **Error humano**: Gran parte de los incumplimientos de integridad se dan como resultado del error de un usuario eliminando datos, añadiendo muestras duplicadas o incumpliendo los protocolos de seguridad definidos.

- **Virus, *bugs* en el código y brechas de seguridad**: Uno de los principales riesgos más conocidos en nuestros tiempos es el provocado por las **brechas de seguridad y los ataques de los ciberdelincuentes**, quienes pueden borrar datos, alterarlos e incluso apropiarse de estos.

- **Fallos en las transferencias y migraciones de información**: A menudo, pueden darse errores, en procesos de migración de grandes fuentes de datos, que lleven asociados pérdidas de datos o inconsistencia de los mismos. Algunos de estos fallos suelen darse por errores de planificación, por políticas de migración inseguras y poco robustas o por falta de estrategia de mantenimiento posterior a la migración.

- **Hardware en peligro**: Riesgos resultantes de averías o anomalías en los servidores donde se almacena la información.

Enlaces de interés...

En el siguiente enlace, encontrarás un artículo de IBM exponiendo su visión sobre integridad de los datos: https://www.ibm.com/es-es/topics/data-integrity

Vídeo 1. "Integridad de datos y COVID-19"

https://bit.ly/3LACRAr

/ 4. Principales mecanismos para garantizar la integridad

Si bien garantizar la integridad de los datos lleva asociada una serie de riesgos, existen también **mecanismos mitigadores con los que paliar al máximo el impacto y exposición a estos riesgos y los efectos de los mismos**. A continuación, vamos a conocer algunas de estas acciones mitigadoras.

Fig.3. Integridad de la información.

- **Restringir el acceso humano a los datos y establecer un sistema de permisos** robusto, para evitar el acceso a personal externo no autorizado.
- **Proceder a validaciones de los datos almacenados**, prioritariamente, en el mismo instante de la recolección, aunque, también, a modo de doble chequeo, en el momento del procesamiento y empleo.
- **Generar copias de seguridad con una periodicidad establecida**. Automatizarlas, siempre y cuando sea posible.
- Llevar a cabo **auditorías con una periodicidad determinada**.
- **Emplear software con funcionalidades para la detección y control de errores**, con el fin de evitar fallos de seguridad por *bugs* en el código.
- Especial mención a una de las principales técnicas para la detección de cambios en los datos: la **suma de verificación**, también denominada checksum.

Consiste en la realización de una comprobación (chequeo) en el punto de partida y otra después de las modificaciones o al final de un proceso. De tal forma que, en el caso de que coincidan dichas verificaciones (a través de mecanismos de sumas), se puede certificar la integridad completa de los datos.

Audio 1. "DPO y DQM"
https://bit.ly/3HGrpR7

/ 5. Caso práctico 1: "Comprobación de integridad de los datos como fase previa"

Planteamiento: Una empresa tiene, ante sí, la oportunidad de ejecutar un proyecto para el cual necesita explotar datos propios almacenados a lo largo de los últimos años. Como particularidad, estos se han ido tomando a lo largo de diferentes etapas de la compañía. En algunas (las más remotas), sin políticas estrictas definidas para la recolección, en otras (las más recientes), garantizando una toma de datos estructurada y organizada a través de sus sistemas.

Nudo: Dado que el proyecto requiere del histórico completo de los datos analizados, para su ejecución serán necesarios los datos tanto de la primera etapa como de la más reciente. En este punto, con el objetivo de asegurar un buen resultado del proyecto, surge la necesidad de garantizar la coherencia de los datos. En otras palabras, la integridad de los mismos. No obstante, ¿qué comprobaciones se requerirá hacer para garantizar dicha integridad?

Desenlace: Con el objetivo de garantizar la integridad de los datos almacenados, como paso previo a la ejecución del proyecto, se llevarán a cabo las siguientes comprobaciones:

- Las muestras guardadas en el histórico de datos de la empresa deben estar **registradas una única vez**. Es decir, no deben existir muestras duplicadas.
- En los datos tomados, especialmente en los relativos a años anteriores, **no debe haber muestras incompletas**.
- No deben existir características relativas a **muestras incoherentes**, ya sea por formato o por valores.

Fig.4. Integridad de los datos.

/ 6. Caso práctico 2: "Riesgos sobre la integridad de los datos"

Planteamiento: Una empresa quiere hacer un chequeo de las principales políticas internas que, vinculadas con sus empleados, ponen en riesgo la integridad de los datos y, con ello, la calidad de los mismos. Para esto, requiere de una auditoría.

Nudo: El auditor que va a llevar a cabo las comprobaciones oportunas establece los siguientes objetivos de verificación:

- *Bugs* en los desarrollos software que realizan interacciones sobre el conjunto de datos almacenados.
- Control de los usuarios con acceso a la modificación y eliminación de los datos almacenados.
- Control de las prácticas y procedimientos de la empresa, para el registro y tratamiento de datos, por parte de sus empleados.

Se realizan las comprobaciones prioritarias previamente detalladas y se extraen las siguientes conclusiones:

- No se detectan *bugs* de resolución crítica vinculada con el tratamiento y la iteración sobre los datos almacenados.
- Sin embargo, se determina que no hay un control de usuarios apropiado ni una gestión de permisos por roles. Dicho de otra manera, cualquier empleado de la compañía puede acceder a todos los datos de la misma, y podría modificarlos y eliminarlos.
- Se determina que la forma de llevar a cabo el registro de datos en la empresa se efectúa mediante los distintos formularios que proveen los sistemas. Por tanto, la manera de adquirirlos se determina acotada y controlada.

Fig.5. Riesgos para la integridad de los datos.

Como conclusión, con estos resultados, ¿se puede garantizar que la empresa cumple con lo requerido para asegurar la integridad de sus datos?

Desenlace: Evidentemente, por el segundo de los puntos expuestos, **podemos afirmar que no**.

/ 7. Resumen y resolución del caso práctico de la unidad

En esta unidad hemos profundizado en el concepto de integridad de los datos. Sobre este término, hemos conocido los tipos de integridad que existen, además de los riesgos asociados para garantizarla.

Hemos concluido el tema con algunas acciones mitigadoras que las empresas deben llevar a cabo para paliar los potenciales riesgos asociados a la integridad de los datos.

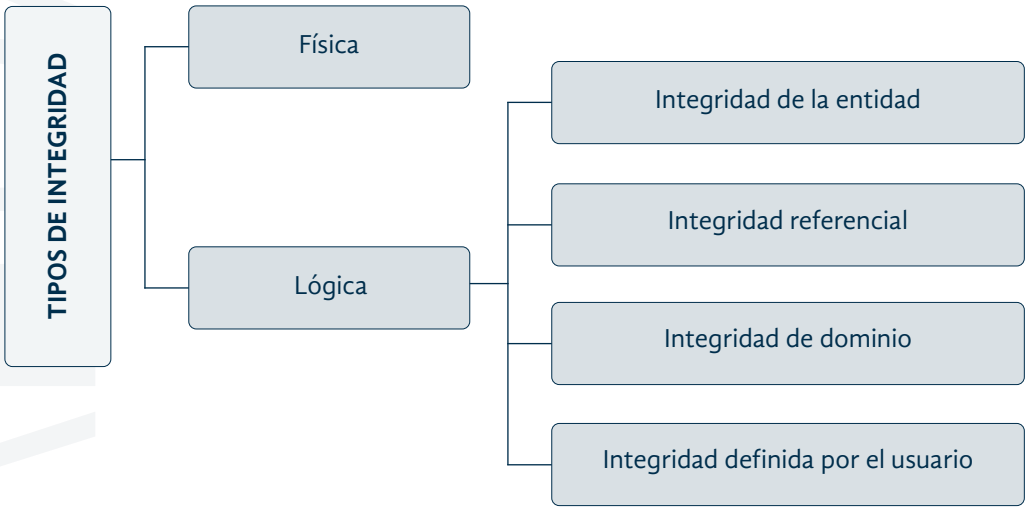

Fig.6. Esquema de la unidad.

Resolución del caso práctico

Con el objetivo de dar respuesta al caso práctico inicial propuesto, pasamos a enumerar algunos ejemplos de riesgos que pueden poner en peligro la integridad de los datos almacenados.

- Acceso a la información no restringida y expuesta de forma pública, con independencia del rol que desempeñe el individuo sobre los datos.
- *Bugs* o errores en los códigos de los programas desarrollados.
- Falta de un procedimiento adecuado para el registro de nuevos datos.
- Ausencia de control de errores sobre valores y formatos, de los datos almacenados.
- Mantenimiento inapropiado de los equipos de hardware donde se almacena la información.

Vídeo 2. "Integridad de datos"
https://bit.ly/33bTp0b

/ 8. Bibliografía

Talend. *¿En qué consiste la integridad de los datos y por qué es importante?* Recuperado de: https://www.sas.com/es_es/insights/big-data/hadoop.html

Tecnologías Información. *Integridad de Datos*. Recuperado de: https://www.tecnologias-informacion.com/integridaddatos.html

Oqotech (abril 2019). *Causas de los problemas de integridad de datos identificados*. Recuperado de: https://www.oqotech.com/blog/data-integrity/causas-de-los-problemas-de-integridad-de-datos-identificados-por-las-agencias-reguladoras/

Tehreem Naeem (octubre 2020). *¿Qué es la integridad de los datos en una base de datos? ¿Por qué lo necesitas?* Recuperado de: https://www.astera.com/es/type/blog/data-integrity-in-a-database/

PowerData (febrero 2016). *Introducción a la Calidad de Datos: Definición, Control y Beneficios*. Recuperado de: https://blog.powerdata.es/el-valor-de-la-gestion-de-datos/bid/368784/introducci-n-a-la-calidad-de-datos-definici-n-control-y-beneficios