MEDAC
Instituto Oficial de Formación Profesional

SISTEMAS DE APRENDIZAJE AUTOMÁTICO

Introducción al Machine Learning

2

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. ¿Qué es el Machine Learning? 4

/ 3. Aprendizaje supervisado 5

/ 4. Caso práctico 1: “Aprendizaje supervisado” 5

/ 5. Aprendizaje no supervisado 6

/ 6. Aprendizaje por refuerzo 6

/ 7. Caso práctico 2: “Predecir pérdida de clientes” 7

/ 8. Resumen y resolución del caso práctico de la unidad 8

/ 9. Bibliografía 8

© MEDAC

Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Definir qué es el aprendizaje automático.

Conocer las principales técnicas para desarrollar el aprendizaje automático.

Presentar las principales técnicas de aprendizaje automático.

/ 1. Introducción y contextualización práctica

Uno de los principales campos de mayor desarrollo de la Inteligencia Artificial (AI) es el aprendizaje automático (en inglés, *Machine Learning*). De hecho, gran parte de los cambios que la adopción de la AI está provocando en la sociedad vienen propiciados por el desarrollo del Machine Learning, desde las recomendaciones de Netflix hasta el sistema de spam de Gmail o los asistentes virtuales como Siri.

A lo largo de esta unidad introductoria de este campo, tendremos un primer contacto con el Machine Learning, abordando sus características básicas, las principales técnicas para realizarlo y los tipos existentes.

A continuación, vamos a plantear un caso práctico a través del cual podremos aproximarnos de forma práctica a la teoría de este tema.

Escucha el siguiente audio donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

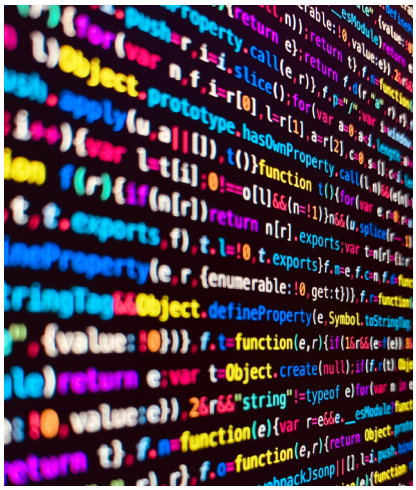

Fig.1. Código para programar el Machine Learning.

Audio intro. "La fiebre del Machine Learning"

https://bit.ly/3H1H90y

/ 2. ¿Qué es el Machine Learning?

El **Machine Learning** es una rama de la Inteligencia Artificial que **permite que las máquinas aprendan sin ser expresamente programadas para ello**. Este aprendizaje se realiza **a través de la experiencia**, que a nivel programático se traduce en **datos**. Es la combinación de un mayor poder computacional con la mayor disponibilidad de datos gracias al Big Data lo que ha permitido el desarrollo meteórico del Machine Learning en las últimas décadas.

El Machine Learning se daba en el reconocimiento de patrones ocultos en los datos. La metodología a seguir consiste en **'entrenar' un algoritmo con datos para que pueda identificar patrones** y luego poder extraer inferencias o predicciones de nuevos conjuntos de datos para los que no fue inicialmente entrenado.

Aunque el Machine Learning ha adquirido una enorme popularidad en los últimos años, sus principios teóricos se remontan al siglo XIX, siendo la estadística su base fundamental. A partir de los años 50 del siglo XX, el desarrollo de la informática permitió llevar la estadística a los ordenadores.

El mayor logro del Machine Learning ha sido **formular reglas sin estar explícitamente programado para ello**, sino que estas reglas se aprenden a partir de ejemplos con los que entrena la máquina. Este logro ha supuesto un cambio de paradigma en la programación, pasando de la programación basada en reglas (que parte de la creencia de que las máquinas pueden aprender si tienen reglas precisas y exhaustivas) a la programación donde **las reglas son inferidas a partir de los datos**.

La última década ha estado protagonizada por los logros del aprendizaje profundo (*Deep Learning*, en inglés), un subcampo del Machine Learning basado en el uso de **redes neuronales artificiales para la resolución de problemas complejos**.

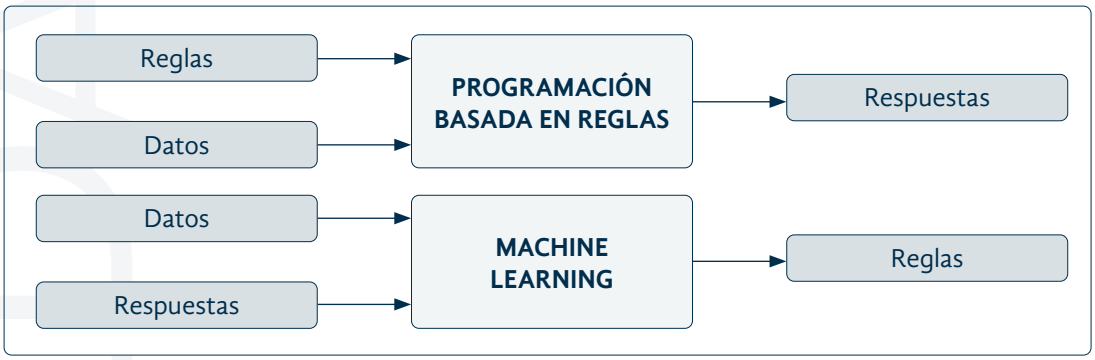

Fig.2. Machine Learning: un nuevo paradigma.

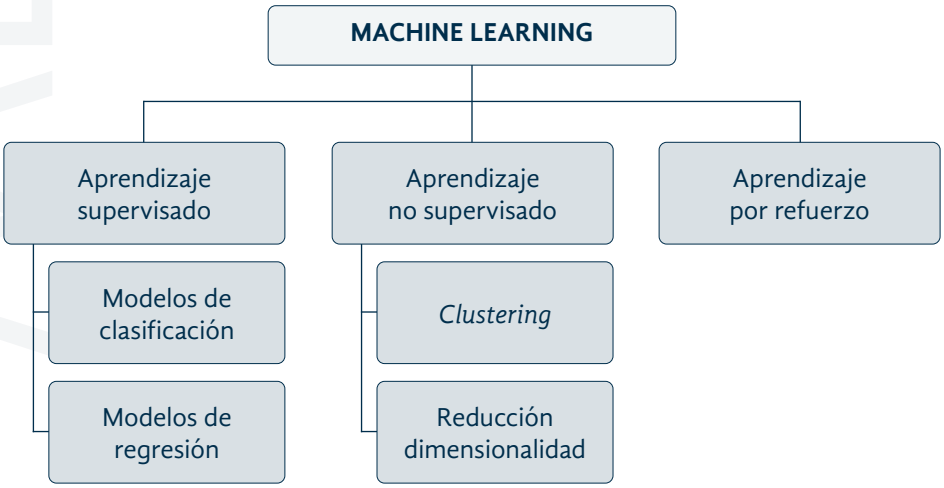

Fig.3. Tipos de Machine Learning.

/ 3. Aprendizaje supervisado

El Machine Learning permite a las máquinas aprender sin ser explícitamente programadas para ello. Dependiendo de la forma que tienen las máquinas de aprender, podemos distinguir **tres tipos de Machine Learning**: aprendizaje supervisado, aprendizaje no supervisado y aprendizaje por refuerzo.

Hablamos de **aprendizaje supervisado** cuando **se entrenan a los algoritmos de Machine Learning con datos etiquetados**. Se denomina 'supervisado' porque el uso de **etiquetas** hace que el algoritmo solo pueda aprender la relación de los datos que conducen a los resultados que marcan dichas etiquetas. Como estas etiquetas han sido seleccionadas por los investigadores, decimos que el aprendizaje del algoritmo está siendo 'supervisado'.

Por ejemplo, correos electrónicos con etiquetas que indican si son spam o no spam. Al estudiar estos datos, el algoritmo es capaz de identificar patrones entre los datos de entrada (los correos) y los datos de salida (spam o no spam), de tal forma que, una vez entrenado, cuando reciba nuevos correos sin etiquetar, el algoritmo podrá utilizar los patrones aprendidos para predecir si los nuevos correos son spam o no.

Dependiendo del tipo de valor de salida que se quiere predecir, podemos trazar una subcategoría dentro del aprendizaje supervisado que distingue entre **modelos de clasificación**, si la salida es un valor categórico (bien valores dicotómicos, bien un conjunto finito de valores) y **modelos de regresión**, si la salida es un número en un espacio continuo.

Vídeo 1. "Las aplicaciones del Machine Learning"

https://bit.ly/3EOYmsk

/ 4. Caso práctico 1: "Aprendizaje supervisado"

Planteamiento: Una empresa de nutrición quiere desarrollar una app que, mostrando el código de barras de un artículo de un supermercado, pueda indicar si se trata de un producto sano o insano.

Nudo: La empresa podría crear un catálogo de normas para que el algoritmo sepa cuándo está ante un producto sano o uno insano. En este caso, estaríamos trabajando con un paradigma de programación basado en reglas. Sin embargo, ¿existe alguna alternativa para diseñar la aplicación?

Desenlace: La empresa podría utilizar una base de datos con información nutricional sobre productos y etiquetar cada uno diciendo si es sano o insano. Con esos datos, el algoritmo podría identificar los patrones que hacen que una comida sea sana o insana. Por ejemplo, si el algoritmo está bien diseñado, cabe esperar que la verdura salga como sana y la comida basura como insana.

Sin embargo, podemos encontrar varios problemas en el diseño de esta app. En primer lugar, hay muchos productos pueden ser tanto buenos como malos para la salud, siendo la cantidad consumida lo que marque la diferencia.

Por otra parte, puede que un modelo de clasificación dicotómica (sano o insano) no sea el más propicio para puntuar un producto. Quizá sería más conveniente dar una puntuación en una escala (de 0 a 10, de 0 a 100, por ejemplo), lo que daría una idea más aproximada de lo bueno o malo que es un producto. En este caso, estaríamos diseñando un modelo de regresión, no de clasificación.

Por último, y quizá lo más importante, para que el algoritmo funcione, lo primero que necesitamos son buenos datos en grandes cantidades. Así, lo primero que debería preguntarse la empresa es si esos datos existen y, en caso afirmativo, cómo va a obtenerlos.

Como vemos, diseñar Machine Learning parece sencillo en el plano teórico, pero en cuanto bajamos a la práctica, el asunto se vuelve más peliagudo.

Casos de éxito...

Una de las apps más populares para saber lo que comemos es Yuka, la cual ofrece una puntuación del 1 al 100 sobre si un producto es saludable o no a partir del código de barras. Lee este artículo para saber en base a qué criterios crea sus recomendaciones. ¿Se trata de Machine Learning? Link.

/ 5. Aprendizaje no supervisado

Mientras que en el aprendizaje supervisado se busca que el algoritmo prediga un resultado conocido por sus diseñadores a través de las etiquetas, en el caso del aprendizaje no supervisado lo que se busca es el **descubrimiento** de nuevos patrones o resultados.

En este caso, esperamos que el algoritmo aprenda sin decirle exactamente el qué. Para ello, este buscará **relaciones ocultas entre los datos**. Se trata de una versión optimizada de la técnica de minería de datos, con la que el algoritmo tratará de **encontrar conjuntos de datos similares y que se puedan agrupar**.

Un ejemplo sería el reconocimiento facial. En este problema, la máquina no busca rasgos concretos, sino una serie de patrones comunes (disposición de los rasgos faciales, color de piel, tipo de pelo...) que le indican al algoritmo que estamos ante el mismo rostro.

Se han destacado dos tipos de circunstancias donde el aprendizaje no supervisado ha resultado ser muy útil:

- **Segmentación** (*clustering*, en inglés): En este caso, los algoritmos de aprendizaje no supervisado pueden ayudarnos a buscar agrupaciones de observaciones similares entre ellas y lo más distintas posibles del resto de grupos. De esta forma, el aprendizaje no supervisado nos puede aportar un conocimiento inicial muy útil sobre un grupo de datos que no conocemos.

- **Dimensión de dimensionalidad:** La reducción de dimensionalidad permite reducir el número de variables de una base de datos, reduciendo así la complejidad del modelo y mejorando su rendimiento computacional. Esta técnica se suele aplicar como paso previo para desarrollar modelos de Machine Learning.

Audio 1. "El potencial del aprendizaje no supervisado"

https://bit.ly/33PkINK

/ 6. Aprendizaje por refuerzo

El tercer tipo de Machine Learning es el aprendizaje por refuerzo (o aprendizaje reforzado). En este caso, **las máquinas aprenden mediante un sistema de prueba y error hasta alcanzar la forma óptima de resolver una tarea determinada**.

La base de este tipo de aprendizaje es que **la máquina se enfrente a un problema sin guía o conocimiento previo** y, dependiendo de la decisión que tome, reciba una 'recompensa' o un castigo. Así, en el aprendizaje por refuerzo, la máquina se encuentra siempre en un bucle de estado-acción-recompensa.

Por ejemplo, imagina que creamos un programa para que aprenda a jugar al Tetris. Un primer enfoque sería utilizar programación basada en reglas, de manera que el programa supiese las reglas básicas del Tetris. El segundo enfoque sería diseñar el programa que aprenda a jugar por medio del ensayo y error. De este modo, en las primeras partidas la máquina estaría totalmente perdida; no sabría siquiera que la partida se pierde cuando una de las piezas que se van acumulando desde el techo llega al suelo. Sin embargo, a medida que jugara más partidas, el programa recibiría recompensas al eliminar filas de piezas, de manera que miles de partidas después (que podría jugar sin descanso, ya que las máquinas no se cansan ni se aburren), posiblemente, sería mucho mejor que cualquier jugador humano.

El aprendizaje por refuerzo ha tenido gran desarrollo en el mundo de los videojuegos. **La combinación de este tipo de aprendizaje con redes neuronales** se ha denominado aprendizaje por **refuerzo profundo** (*deep reinforcement learning*, en inglés). Esta metodología está detrás, por ejemplo, de AlphaGo, el ordenador diseñado por Google DeepMind que consiguió batir al campeón del mundo de Go en 2016.

Fig.4. El aprendizaje por refuerzo en los videojuegos.

/ 7. Caso práctico 2: "Predecir pérdida de clientes"

Planteamiento: Un desarrollador de Machine Learning tiene como tarea diseñar un algoritmo de aprendizaje supervisado para predecir la probabilidad de abandono de los clientes de una empresa de telefonía móvil.

Nudo: Como siempre, lo primero son los datos con los que se entrenará el algoritmo. Y justo aquí empieza el problema. Cuando el desarrollar recibe la base de datos con información de los clientes de la empresa de telefonía, se echa las manos a la cabeza: la base de datos es demasiado grande, con miles de columnas que hacen que hasta la operación más simple sea computacionalmente pesada.

Desenlace: Este es un problema típico al que se enfrentan los desarrolladores de Machine Learning. Cuando los algoritmos tienen que entrenar con bases de datos con cientos o miles de columnas, la complejidad del modelo aumenta (lo que dificulta su diseño) y el gran volumen de datos hace que su coste computacional aumente, lo que se traduce en mayores tiempos de procesamiento, un peor rendimiento y una factura de la luz más alta.

Para solventar el problema, nuestro desarrollador podría aplicar a la base de datos un modelo de reducción de dimensionalidad, un algoritmo de aprendizaje no supervisado que, basándose en el conjunto de datos original, cree un subespacio sintético de menor dimensión que permita hacer una descripción de los datos a menor coste.

Fig.5. Muchos datos, a veces, es igual a problemas.

¡! Sabías que...

Los diversos fenómenos que surgen al analizar y organizar datos de espacios de múltiples dimensiones (cientos y miles de dimensiones) que no suceden en el espacio físico descrito, generalmente con solo tres dimensiones, se conoce como el efecto Hughes.

/ 8. Resumen y resolución del caso práctico de la unidad

A lo largo de esta unidad, hemos tenido una primera introducción al Machine Learning. En primer lugar, hemos definido el término, analizando cómo el Machine Learning ha supuesto un nuevo paradigma en la programación.

En el resto de la unidad, hemos visto los tres tipos principales de Machine Learning: aprendizaje supervisado, aprendizaje no supervisado y aprendizaje por refuerzo. Cada tipo de Machine Learning tiene sus peculiaridades y campos de aplicación, que abordaremos con más detalle en las próximas unidades.

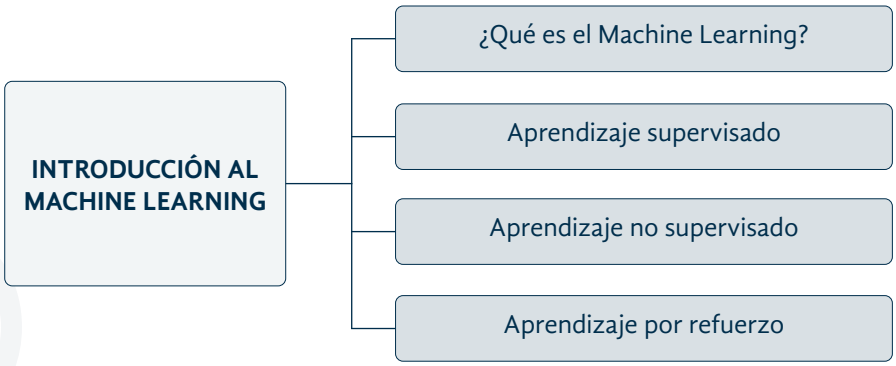

Fig.6. Esquema resumen del tema.

Resolución del caso práctico inicial

Vivimos una época convulsa. Las tecnologías de la Cuarta Revolución Industrial están transformando rápidamente nuestras sociedades. Son tiempos de destrucción creativa, en los que muchas empresas sucumbirán ante el ritmo trepidante de progreso, mientras que otras liderarán los mercados gracias a los nuevos modelos de negocio basados en tecnologías punteras. Una de ellas es el Machine Learning.

El potencial del Machine Learning en el mundo empresarial es enorme. Muchas empresas, especialmente aquellas con la suficiente capacidad financiera, han iniciado ya su adopción de esta revolucionaria (y costosa) tecnología. Sin embargo, el miedo de quedarse atrás ha hecho que muchas empresas hagan marketing sobre el uso que hacen del Machine Learning, cuando realmente sus dinámicas empresariales y su modelo de negocio no han cambiado. Esto ha contribuido a la creación de una burbuja mediática sobre el Machine Learning.

Lo cierto es que esta tecnología no es buena por sí misma. Todo depende de las necesidades y recursos de cada actor. Cualquier empresa que decida apostar por el Machine Learning debería estudiar antes si realmente lo necesita y si es solvente para afrontar los costes de implementación de esta tecnología. Es la recomendación que deberíamos hacerle al dueño de la empresa de comercio electrónico.

/ 9. Bibliografía

BBVA (2019). *Machine learning: ¿qué es y cómo funciona?* Disponible en: https://www.bbva.com/es/machine-learning-que-es-y-como-funciona/

Merino, M. (2019). *Conceptos de inteligencia artificial: qué es el aprendizaje por refuerzo.* Xataka. Disponible en: https://www.xataka.com/inteligencia-artificial/conceptos-inteligencia-artificial-que-aprendizaje-refuerzo