MEDAC
Instituto Oficial de Formación Profesional

SISTEMAS DE APRENDIZAJE AUTOMÁTICO

Aprendizaje supervisado

3

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. Tipos de aprendizaje supervisado 4

/ 3. Cuantificar problemas de clasificación 4

/ 4. Regresión lineal en problemas de regresión 5

/ 5. Caso práctico 1: "Selección del mejor algoritmo a emplear" 6

/ 6. Regresión. Regularización de datos, Lasso y Ridge 7

/ 7. Clasificación. Regresión logística 8

/ 8. Clasificación. Árboles de decisión 8

/ 9. Clasificación: Los K vecinos más cercanos 9

/ 10. Caso práctico 2: "Validación de algoritmos" 10

/ 11. Clasificación. *Support vector machines* 11

/ 12. Resumen y resolución del caso práctico de la unidad 12

/ 13. Bibliografía 13

© MEDAC

Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Entender los principales tipos de aprendizaje supervisado.

Estudiar los principales métodos de regresión y sus usos.

Entender el concepto de regularización.

Conocer los principales métodos de clasificación y sus aplicaciones.

/ 1. Introducción y contextualización práctica

Machine Learning es una de las tecnologías emergentes más en boga en lo que respecta al ecosistema de tecnologías exponenciales del momento actual, entre las que se encuentra la Inteligencia Artificial. Para su aplicación, Machine Learning recurre a una serie de **algoritmos matemáticos**, los cuales se dividen según sus características en una serie de **métodos**.

Dentro de los diferentes métodos empleados para la clasificación de los algoritmos destacan, principalmente, los siguientes: **aprendizaje supervisado, aprendizaje no supervisado y aprendizaje reforzado**.

En este tema, nos vamos a focalizar en el método de aprendizaje supervisado: aquel en el que **tratamos de predecir una característica externa basada en nuestros datos,** es decir, que durante el entrenamiento, **tendremos tanto las características de nuestros datos como el objetivo que buscamos predecir**.

Presentaremos y analizaremos algunas de las técnicas más comunes de este aprendizaje.

A continuación, vamos a plantear un caso práctico a través del cual podremos aproximarnos de forma práctica a la teoría de este tema.

Escucha el siguiente audio donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

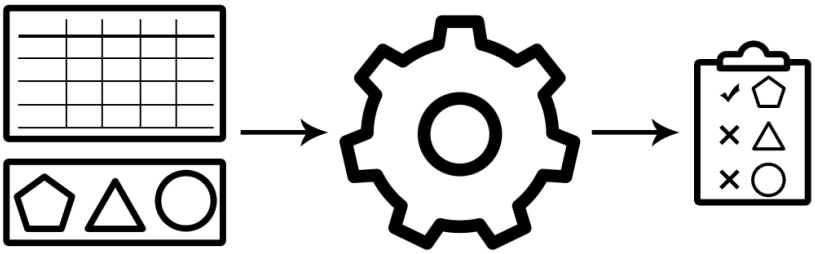

Fig.1. Aprendizaje supervisado.

Audio intro. "El concepto de aprendizaje supervisado"
https://bit.ly/3EbKWXe

/ 2. Tipos de aprendizaje supervisado

En aprendizaje supervisado, buscamos una predicción externa a nuestros datos, pero, dependiendo de cuál sea nuestro objetivo, podemos diferenciar entre **dos grandes tipos de aprendizaje supervisado**:

- **Regresión:** En los problemas de regresión, buscamos predecir un **valor continuo**, es decir, se asume que nuestro objetivo puede ser cualquier número. Un ejemplo clásico es tratar de predecir el precio de una vivienda basándonos en sus características (número de habitaciones, m^2, año de construcción, pisos, barrio, etc.).

- **Clasificación:** En los problemas de clasificación, buscamos **predecir una variable que solamente puede tomar un número definido de valores o etiquetas**. Por ejemplo, podríamos tratar de identificar tipos de setas en función del color, peso, tamaño, etc., o tratar de identificar un dígito manuscrito a partir de una imagen (nótese que podemos reducir el número de dígitos posibles a 10 categorías: {0, 1, 2, 3, 4, 5, 6, 7, 8, 9}).

  » **Clasificación binaria:** El objetivo solo puede tomar 2 valores.
  » **Clasificación multivariante:** El objetivo puede tomar más de 2 valores distintos.

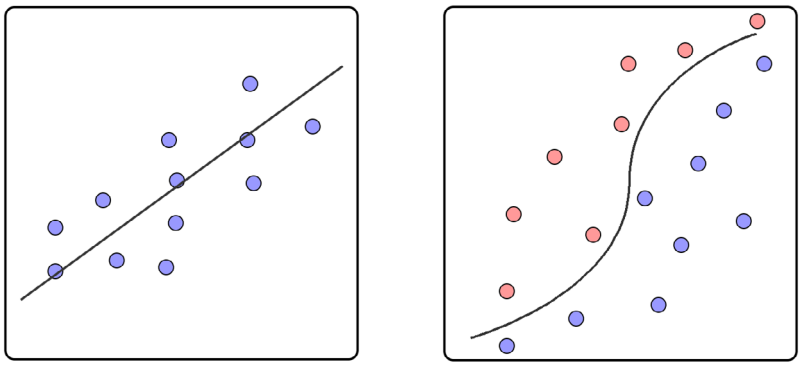

Fig.2. Regresión vs. clasificación.

/ 3. Cuantificar problemas de clasificación

En los problemas de clasificación es común que los datos vayan asociados a una **etiqueta calificativa**. Algunos de los métodos que veremos están pensados para predecir valores y, por lo tanto, será necesario traducir esas etiquetas a números.

En clasificación binaria, lo más habitual es traducir una de las etiquetas como 0 y la otra como 1. Por ejemplo, imaginemos que estamos tratando de identificar si un animal es un perro o un gato, podríamos asignar a perro el valor 0 y a gato el valor 1.

Pero ¿qué pasa cuando tenemos más de 2 valores? Lo más común es convertir un problema con un único objetivo de clasificación multivariante a un problema con varios problemas de clasificación binaria usando varios objetivos del tipo '¿Pertenece a la clase ___?' Donde 0 sería **no** y 1 sería **sí**.

Clasificación binaria

TIPO
Perro
Gato

→

TIPO
0
1

Fig.3. Conversión de etiquetas a valores en clasificación binaria.

Por ejemplo, supongamos que, en lugar de solamente predecir perros y gatos, también tenemos hámster y pez como posibles valores, y que podemos asegurar que cada entrada de nuestros datos pertenece a una de estas 4 categorías. Una posible solución sería convertir nuestro objetivo, '¿Qué tipo de animal es?', a 3 preguntas: '¿Es un perro?', '¿Es un gato?', '¿Es un hámster?'.

Nótese que, en este caso, la pregunta '¿Es un pez?' es innecesaria, ya que si no es un perro, un gato o un hámster, automáticamente es un pez. Por lo general, el número de preguntas binarias será 1 menos que el número de posibles valores.

Clasificación multivariante

TIPO
Perro
Gato
Hámster
Pez

→

PERRO	GATO	HÁMSTER
1	0	0
0	1	0
0	0	1
0	0	0

Fig.4. Conversión de etiquetas a valores en clasificación multivariante.

/ 4. Regresión lineal en problemas de regresión

La regresión lineal es probablemente la técnica más simple y clásica de regresión. Aquí, tratamos de **predecir la variable dependiente en función de una serie de variables independientes asumiendo que esa relación puede expresarse como** una **función lineal**.

En el caso más simple de tener una variable dependiente (Y) y una variable independiente (X), esto puede expresarse mediante la ecuación:

$$Y = a \cdot X + b$$

Recordemos que, en aprendizaje automático supervisado, tenemos un conjunto de datos (X) con sus etiquetas relacionadas (Y) y lo que buscamos es determinar las reglas que las relacionan, en este caso, buscamos las constantes (a & b).

Por ejemplo, imaginemos que buscamos predecir el peso de un grupo de jugadores de baloncesto en función de su altura. En este caso, tendríamos una lista de alturas de cada jugador (X) y una lista con el peso de cada jugador (Y) y nuestro objetivo sería encontrar la expresión que los relaciona (siguiente figura).

Esta técnica se puede generalizar para datos con múltiples categorías (múltiples variables independientes). Así, la ecuación que trataríamos de aproximar sería de la forma:

Y = a0 + acat_1 · Xcat_1 + acat_2 · Xcat_2 + ... + aúltima_cat · Xúltima_cat

Las principales **ventajas** de utilizar regresión lineal para aproximar nuestros datos es que es una técnica con baja complejidad, es sencilla de implementar y es relativamente rápida a nivel de cálculo.

Por **contra**, cabe tener en cuenta que es una técnica muy sensible a valores anómalos que se alejan bastante del comportamiento de la mayoría, y que, en casos prácticos, asumir que la relación es puramente lineal suele ser una simplificación de la realidad.

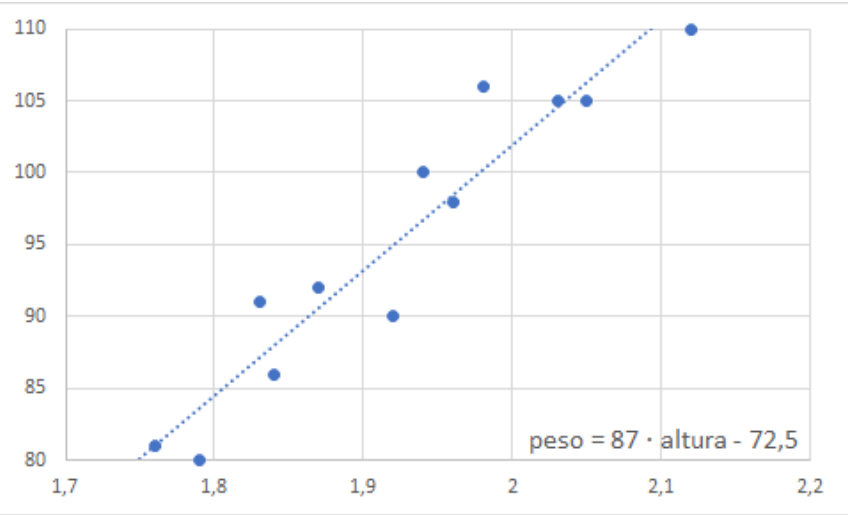

Fig.5. Ejemplo de regresión lineal que relaciona pesos y alturas.

/ 5. Caso práctico 1: "Selección del mejor algoritmo a emplear"

Planteamiento: Una empresa de publicidad que gestiona un extenso catálogo de productos de varios clientes quiere usar aprendizaje automático para dirigir anuncios a distintos usuarios en redes sociales.

El objetivo es poder predecir la valoración que puede hacer un usuario de uno de los productos, utilizando una escala de valores sin decimales del 0 al 10 en función de sus intereses, que se pueden obtener de forma nativa con herramientas propias de las plataformas o analizando sus interacciones.

Nudo: Aún sin conocer las herramientas que estudiaremos en esta unidad, nuestra primera intuición podría ser tratar de utilizar algún método de regresión, ya que el dato objetivo es un número en lugar de una etiqueta calificativa y redondear a la nota más cercana para obtener la predicción.

Otra opción sería considerar que las notas solamente pueden tomar 11 valores discretos y, por lo tanto, plantear este problema como un problema de clasificación multivariante.

Por lo general, en este tipo de ocasiones, los modelos de clasificación suelen presentar mejores resultados. Una posible intuición al respecto es que los métodos de clasificación ya establecen de forma nativa las fronteras entre un valor discreto, y pueden tener más juego que el mero hecho de redondear, y que discretizando, lo que estamos haciendo es reducir el espacio de posibilidades de nuestros objetivos.

Desenlace: Por lo general, a nivel práctico se tiende a utilizar métodos de clasificación siempre que el problema lo permita. Hoy en día encontramos problemas de clasificación con centenares o incluso miles de etiquetas distintas.

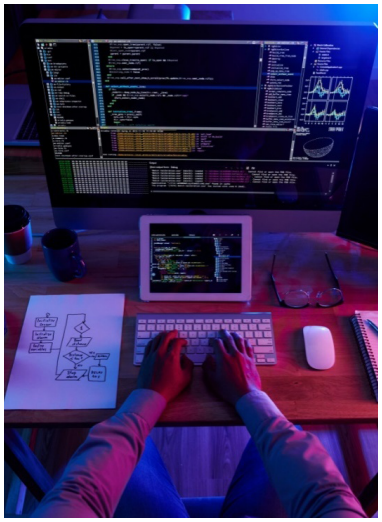

Fig.6. Elección de algoritmo.

/ 6. Regresión. Regularización de datos, Lasso y Ridge

Como hemos visto en apartados anteriores, uno de los grandes problemas que tiene la regresión lineal es que es muy sensible a pequeñas variaciones en los datos de entrenamiento y, en especial, a la aparición de anomalías. En ciencia de datos, en estos casos se suele decir que se sobreestiman (*overfitting* en inglés) los datos de entrenamiento.

Una manera de **reducir la tendencia a sobreestimar los datos** es tratar de **ajustar el modelo y/o los datos para reducir la variabilidad de las predicciones**.

Por ejemplo, con respecto a datos es común que aquellas categorías cuyas magnitudes son mayores acaben teniendo un impacto mayor en las predicciones. En estos casos se suele estandarizar cada categoría por separado. Es decir, a cada valor le restamos el valor medio de su categoría y dividimos por la desviación estándar de su categoría. Así, conseguimos que todas las categorías tengan un valor central de 0 y estén repartidas de una forma más uniforme.

A nivel de modelo, por ejemplo, podemos utilizar **la regularización Ridge** que trata de **forzar que las constantes que buscamos sean lo más pequeñas posibles y esto fuerza al modelo a ser más robusto**.

Intuitivamente, lo que hace este método es poner un 'impuesto' a la importancia que le podemos dar a cada constante y, por lo tanto, trataremos de dar importancia solamente a aquellas que sean importantes para 'pagar' lo menos posible. De ese modo, aquellas categorías donde haya más variabilidad o tengamos valores anómalos les daremos menos importancia porque no aportan información muy relevante, el modelo será menos sensible a esas categorías y, en consecuencia, será más robusto.

La **regularización Lasso** es muy parecida a la regularización Ridge. La principal diferencia práctica es que mientras Ridge busca reducir el valor de las constantes en función de la importancia de cada categoría, Lasso **es capaz de reducir la importancia a 0 y considerar algunas categorías**.

Así, si tenemos categorías fuertemente relacionadas entre sí, si Ridge modulaba su importancia en conjunto, Lasso sería capaz de descartarlas todas excepto una.

/ 7. Clasificación. Regresión logística

Una primera aproximación que podríamos hacer para tratar de aproximar problemas de clasificación sería adaptar técnicas que ya hemos visto en regresión para este tipo de problemas.

En el caso de regresión binaria, por ejemplo, hemos visto que es común asignar valor 0 a una etiqueta y valor 1 a la otra, así que podríamos tratar de aproximar una función para predecir estos valores. El problema es que la línea que hemos visto en apartados anteriores puede acabar tomando cualquier valor y nos gustaría poder limitarlo para facilitar esa aproximación.

La regresión logística **es una extensión de los métodos de regresión para utilizarlos en modelos de clasificación binaria** que, en lugar de utilizar una recta, utiliza como función objetivo una función en forma de 'S' que, por un lado, bordea el 0 y, por el otro, tiende a 1.

Otra manera de ver la regresión logística es que, **en lugar de tratar de predecir la etiqueta, lo que se busca es determinar la probabilidad de que esa entrada tenga la etiqueta positiva**.

La regresión logística es una técnica que se puede calcular de forma rápida y eficiente, y es capaz de aproximar problemas cuya separación entre etiquetas es muy marcada. Para problemas más elaborados, puede funcionar bien transformando los datos, pero este proceso puede no ser evidente.

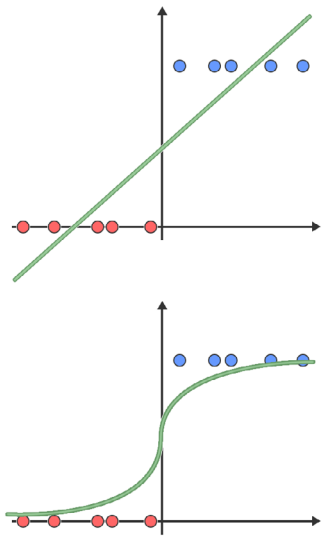

Fig.7. Regresión lineal vs. regresión logística.

/ 8. Clasificación. Árboles de decisión

Una forma bastante común de afrontar un problema es aquello de 'divide y vencerás'. **En el mundo del aprendizaje automático, esto puede traducirse en tratar de dividir el problema base del que partimos en problemas más pequeños**, los cuales se dividen en otros más pequeños e ir repitiendo este proceso hasta tener muchos problemas pequeños cuya solución es evidente.

Una vez tenemos esos pequeños problemas de solución evidente, definiremos nuestro sistema para asignar etiquetas siguiendo los criterios que hemos utilizado para ir dividiendo el problema base.

En otras palabras, los árboles de decisión es un algoritmo para clasificación donde **se busca ir subdividiendo el conjunto de datos mediante 'preguntas'** que maximicen en cada paso la adquisición de información hasta conseguir grupos donde todos los integrantes tengan la misma clase (grupos homogéneos).

La gran ventaja de los árboles de decisión es que son fáciles de comunicar: se puede extraer un sistema de lista de preguntas que un usuario puede seguir para hacer predicciones *in situ*. Es decir, es sencillo extraer el razonamiento que establece el algoritmo para hacer predicciones.

Audio 1. "Los árboles de decisión"
https://bit.ly/3spRpLK

El siguientge árbol de decisión sirve para comunicar sus ventajas, fundamentos y pasos a seguir para su ejecución.

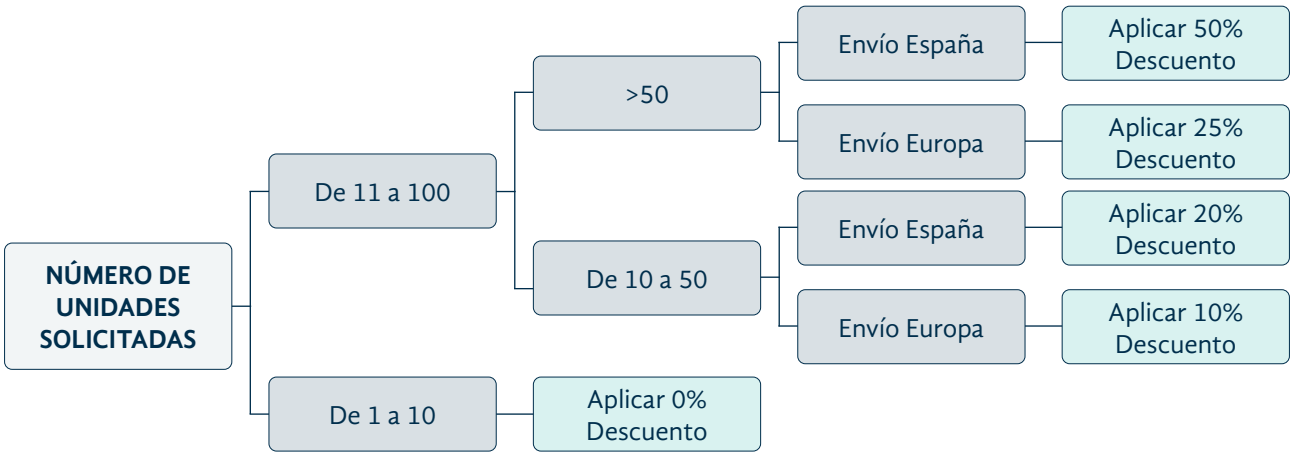

Fig.8. Predicción de descuento a aplicar en función de una serie de variables.

/ 9. Clasificación: Los K vecinos más cercanos

K-NN (por las siglas en inglés de *K-Nearest Neighbours*) es un algoritmo de clasificación que trata de **predecir la etiqueta de una entrada desconocida en función de los K vecinos más cercanos** (donde K es un número).

En otras palabras, supongamos que tenemos un conjunto de datos donde tenemos perros y gatos etiquetados en función de su peso y estatura. Posteriormente, nos dan el peso y la estatura de una nueva entrada desconocida y queremos determinar según un algoritmo 5-NN (los 5 vecinos más cercanos) si este nuevo animal es un perro o un gato.

Para ello, lo que haríamos es calcular para cada uno de nuestros datos de entrenamiento la distancia que los separa de este nuevo dato, buscaríamos los 5 que tengan la distancia más pequeña y le asignaremos la etiqueta mayoritaria. Por ejemplo, si los 5 más cercanos fueran 4 perros y 1 gato, le asignaremos la categoría perro.

Este tipo de algoritmo tiene una complejidad baja y asume que las características están fuertemente segmentadas. Debido a que para cada predicción se deben calcular todas las distancias, en conjuntos de datos con muchas características, las predicciones pueden ser excesivamente lentas.

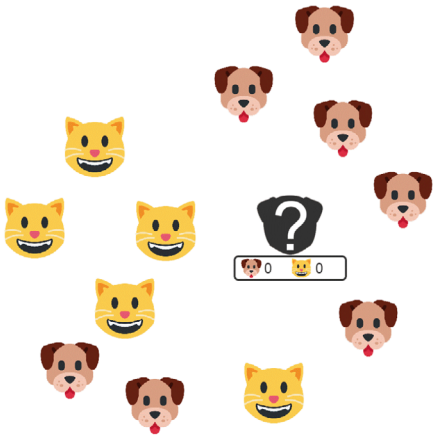

Fig.9. Ejemplo de clasificación de un animal desconocido utilizando los 5 vecinos más cercanos.

Vídeo 1. "Alcohol y predicción de mortalidad por Covid"

https://bit.ly/3EPxJUb

/ 10. Caso práctico 2: "Validación de algoritmos"

Planteamiento: Los modelos de aprendizaje automático no son perfectos. Una de las responsabilidades más importantes del científico de datos es ser capaz de utilizar herramientas para tratar de identificar qué tipo de errores comete un sistema para poder diseñar los pasos a seguir para mejorar su rendimiento.

Nudo: El recurso más común para evaluar modelos es dividir nuestro conjunto de datos ya etiquetados. La mayoría se destinan al entrenamiento (datos de entrenamiento) del modelo y el resto se reservan para cuando el modelo está entrenado.

Con estos datos reservados (o datos de validación), podemos utilizar el modelo para predecir su etiqueta y comparar esa predicción con la etiqueta real que conocemos. Esto nos permite cuantificar el error que comete el modelo.

La manera más intuitiva de cuantificar cuán bueno es el modelo es lo que se conoce como exactitud (o, en inglés, *accuracy*), que no es nada más que el porcentaje de aciertos.

Dicho de otra forma, la exactitud es un valor que se obtiene al dividir el número de aciertos entre el número de datos de ese conjunto y que estará en el rango entre 0 y 1.

Con el modelo entrenado, podemos hacer predicciones sobre los datos de entrenamiento y los datos de validación por separado, y, así, calcular la exactitud en entrenamiento y en validación. Comparando esos dos valores, podemos realizar un primer diagnóstico informado de cuán bueno es nuestro modelo.

Desenlace:

- **La exactitud de entrenamiento y validación son altas:**
  - » El modelo es capaz de aproximar bien los datos de entrenamiento y generaliza bien a datos no conocidos. Este es el comportamiento deseado.
- **La exactitud en entrenamiento es alta, pero en validación es baja:**
  - » El modelo está sobreestimando los datos de entrenamiento y no generaliza bien. Una posible solución es aplicar métodos de regularización para reducir la variabilidad.
- **La exactitud en entrenamiento y validación es baja:**
  - » El modelo no es capaz de aprender los datos de entrenamiento (subestimación). Una posible solución es utilizar modelos más complejos.
- **La exactitud en entrenamiento es baja, pero en validación es alta:**
  - » Los resultados son anómalos. Esto puede deberse a que el método usado para crear los dos conjuntos provoca que el conjunto de validación no refleje los mismos datos que el de entrenamiento.

MEDIA

/ 11. Clasificación. *Support vector machines*

En general, los métodos de clasificación buscan poder **predecir una etiqueta para cualquier posible valor que pueda tomar un dato**. Si esto lo imaginamos en 2 dimensiones, los métodos de clasificación crearán zonas del espacio donde todo lo que quede en su interior tomará una etiqueta y todo lo que haya fuera, tomará la otra. Las líneas que separan estas zonas se denominan **fronteras de decisión**.

Por ejemplo, en el caso de los vecinos más cercanos, podríamos buscar para cada punto del espacio cuál es la etiqueta más cercana entre sus K vecinos y asignarle un color. Nótese que dependiendo del número de vecinos considerados, la forma de las regiones puede cambiar.

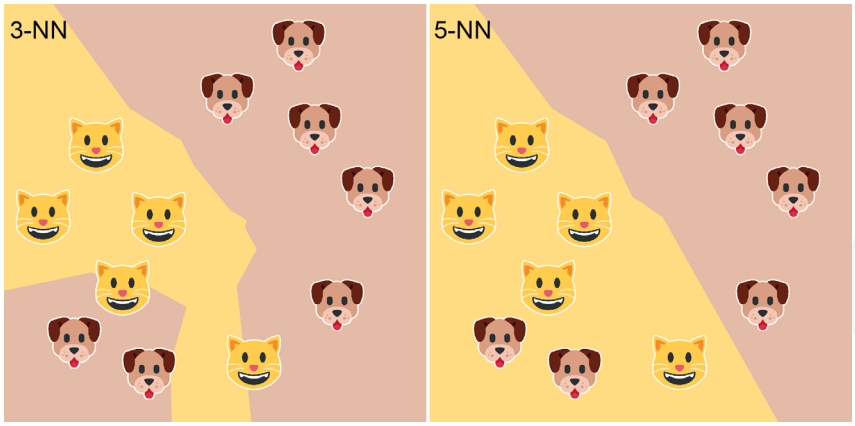

Fig.10. Fronteras de decisión para 3 vecinos más cercanos y 5 vecinos más cercanos.

Las *support vector machines* son un método cuyo objetivo es **establecer una frontera de decisión de manera que la separación entre etiquetas sea máxima.**

Una ventaja que tienen las *support vector machines* es que pueden usar diferentes funciones como base para poder generar fronteras de decisión con distintas formas. Eso le da una cierta flexibilidad a la hora de tratar de aproximar datos más complejos.

Volviendo al contexto de 2 dimensiones y utilizando una frontera lineal, una *support vector machine* tratará de generar la mejor separación posible usando una recta 'lo más ancha posible'.

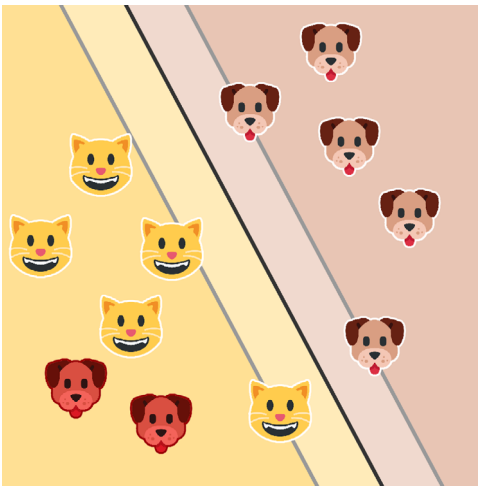

Fig.11. Frontera de decisión usando una SVM lineal con datos erróneamente clasificados marcados en rojo.

/ 12. Resumen y resolución del caso práctico de la unidad

El aprendizaje supervisado es una categoría de aprendizaje automático donde buscamos entrenar un modelo que sea capaz de realizar predicciones en base a un conjunto de datos etiquetados. En esta lección, hemos visto que existen dos grandes tipos de problemas en el aprendizaje supervisado (regresión y clasificación) y algunas de las técnicas más populares usadas en estos campos.

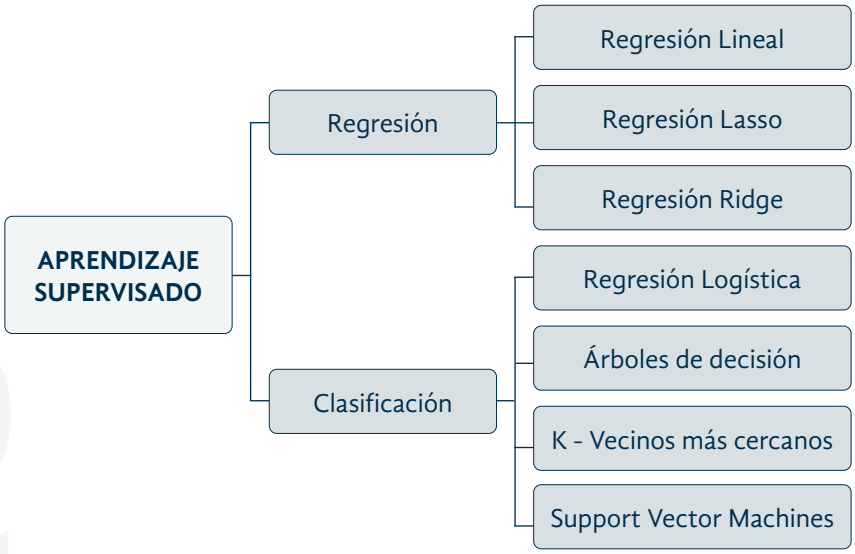

Fig.12. Esquema resumen del tema.

Vídeo 2. "Recorrido por el aprendizaje supervisado"

https://bit.ly/32BVAdb

Resolución del caso práctico inicial

En el caso práctico inicial, planteábamos la pregunta de qué casos conocidos requiriesen de datos históricos para poder realizar predicciones.

A continuación, proponemos varios ejemplos, tanto de clasificación como de regresión.

En **clasificación**, un ejemplo práctico de clasificación binaria sería determinar por parte de un banco la concesión de un préstamo a un potencial cliente. Naturalmente, es una decisión basada en el resultado de los casos pasados en los que a clientes de ese tipo se les concedió el préstamo o no.

Con respecto a la **clasificación multiclase**, un buen ejemplo podría ser la clasificación de la calidad del vino (del 0 al 10) en función de una serie de variables, como la añada, la composición del vino, etc.

Por otra parte, un problema de **regresión** sería determinar el precio de un determinado valor en bolsa en función de los datos históricos, o, por ejemplo, el número de goles que va a meter un futbolista en función de su demarcación, minutos jugados, si es año de Mundial o no, etc.

/ 13. Bibliografía

Román, V. (marzo 2019). *Aprendizaje Supervisado: Introducción a la Clasificación y Principales Algoritmos.* Disponible en: https://medium.com/datos-y-ciencia/aprendizaje-supervisado-introducci%C3%B3n-a-la-clasificaci%C3%B3n-y-principales-algoritmos-dadee99c9407

Aprende IA. *Diferencia entre algoritmos de clasificación y regresión.* Disponible en: https://aprendeia.com/diferencia-entre-algoritmos-de-clasificacion-y-regresion/

Aprende IA. *¿Cuál es la diferencia entre Regresión Lineal y Regresión Logística?* Disponible en: https://aprendeia.com/diferencia-entre-regresion-lineal-y-regresion-logistica-machine-learning/

UNIR. *Árboles de decisión: en qué consisten y aplicación en Big Data*. Disponible en: https://www.unir.net/ingenieria/revista/arboles-de-decision/

Pupale, R. (junio 2017). *Support Vector Machines (SVM)*. An Overview. Disponible en: https://towardsdatascience.com/https-medium-com-pupalerushikesh-svm-f4b42800e989

MEDAC