MEDAC
Instituto Oficial de Formación Profesional

SISTEMAS DE APRENDIZAJE AUTOMÁTICO

Aprendizaje no supervisado

4

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. Aprendizaje no supervisado: qué es y sus principales características 4

/ 3. Principales algoritmos involucrados 5

3.1. K-Means 5

3.2. Clustering jerárquico 5

3.3. Análisis de componentes principales 5

3.4. Modelos de mezcla gaussiana (MMG) 6

/ 4. Caso práctico 1: "¿Aprendizaje automático de tipo no supervisado o aprendizaje supervisado?" 6

/ 5. Casos de uso 7

/ 6. Caso práctico 2: "Segmentación de clientes" 7

/ 7. Resumen y resolución del caso práctico de la unidad 8

/ 8. Bibliografía 9

© MEDAC
Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Profundizar en el concepto de aprendizaje no supervisado.

Conocer los principales algoritmos involucrados en este concepto de aprendizaje no supervisado.

/ 1. Introducción y contextualización práctica

En el tema anterior**, ya adelantamos que Machine Learning** es una de las tecnologías emergentes más en boga en lo que respecta al ecosistema de tecnologías exponenciales del momento actual, que recurre a una serie de **algoritmos matemáticos**, los cuales se dividen en una serie de **métodos** según sus características.

Dentro de los diferentes métodos empleados para la clasificación de los algoritmos, al igual que en la unidad anterior nos detuvimos en el método de aprendizaje supervisado, en esta, nos centraremos en el **aprendizaje no supervisado.**

Vamos a poner el foco en las principales características de este aprendizaje, los algoritmos involucrados más destacados, y en algunos casos de uso basados en este método.

A continuación, vamos a plantear un caso práctico a través del cual podremos aproximarnos de forma práctica a la teoría de este tema.

Escucha el siguiente audio donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

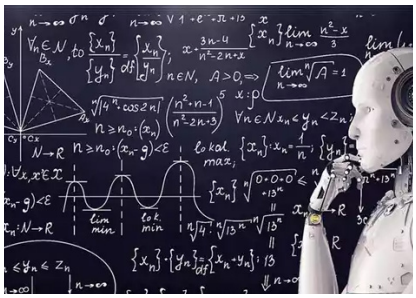

Fig.1. Aprendizaje basado en la observación.

Audio intro. "Agrupación de individuos"
https://bit.ly/3FkM6AT

/ 2. Aprendizaje no supervisado: qué es y sus principales características

En la unidad anterior, estudiamos el aprendizaje supervisado como un modelo basado en el conocimiento de una serie de muestras determinadas, y en esta, procederemos al estudio del aprendizaje no supervisado, un método de aprendizaje automático centrado en **modelos que se ajustan a las observaciones, sin muestras de conocimiento previo.**

A modo de ejemplo ilustrativo de **aprendizaje supervisado**, tenemos el caso de regresión para obtener una predicción de las ventas en una determinada tienda, donde este aprendizaje **se basa en el histórico de ventas en fechas anteriores** en función de una serie de variables específicas.

Por otra parte, un ejemplo de **aprendizaje no supervisado** sería **la segmentación de clientes según unas características comunes no identificadas a simple vista**. Aquí, como puede comprobarse, no existe conocimiento previo.

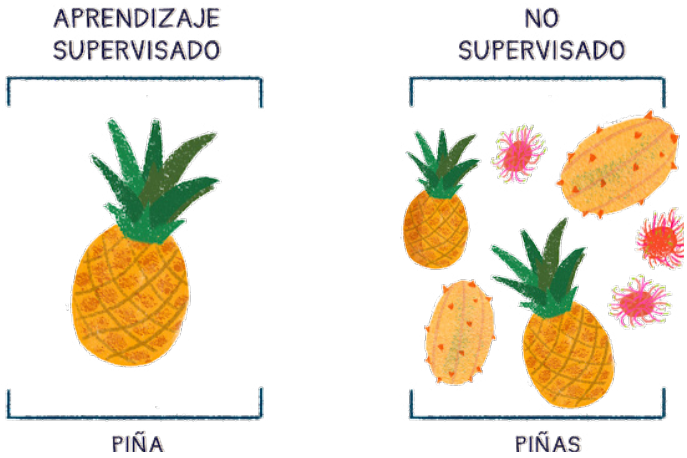

Fig.2. Ejemplos de aprendizajes no supervisados y supervisados.

Algunas de las principales características asociadas a este tipo de aprendizaje automático se detallan a continuación:

Audio 1. "Características específicas de las técnicas de aprendizaje no supervisado"
https://bit.ly/3qesA2M

- **No necesitan de muestras externas ni de históricos** para la realización de predicciones.
- Cuentan con la capacidad de **autoorganización.**
- Presentan **autonomía** para descubrir **patrones y características en los datos de entrada**. Algunos ejemplos son: correlaciones entre variables y muestras, categorías, colores, patrones de comportamiento, formas, etc.
- Requieren de **menos tiempo de entrenamiento** que las técnicas de aprendizaje supervisadas.

MEDAC

/ 3. Principales algoritmos involucrados

Dentro de los métodos de aprendizaje supervisado ya sabemos que destacan los **algoritmos de clasificación**, como, por ejemplo: lineal, clasificación multi-clase, clasificación basada en árboles de decisión, etc., y **algoritmos de regresión**, como, por ejemplo: lineal, polinómica o Support Vector Machine.

Dentro de los métodos de aprendizaje no supervisado también existen una serie de algoritmos principales, los cuales vamos a explorar a continuación.

3.1. K-Means

Posiblemente, es el algoritmo de aprendizaje no supervisado **más popular para los científicos de datos**. Su principal objetivo es llevar a cabo **agrupación de datos que comparten características o patrones** de comportamiento similares. Es muy popular su uso dada su **amigabilidad de empleo y su facilidad de interpretación** por parte de los analistas de negocio.

Los diferentes grupos en los que se dividen los datos serán un valor de entrada a dar por el usuario. Pudiendo interpretarse por el analista que cuanto más cerca está un dato de otro, más probable es que pertenezcan al mismo grupo.

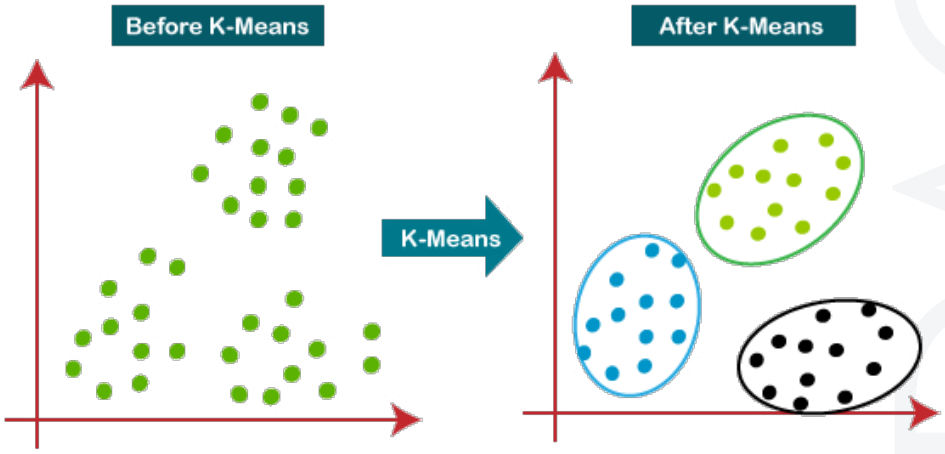

Fig.3. Ejemplo de K-Means aplicado.

3.2. Clustering jerárquico

Es otro de los algoritmos de agrupación, el cual no es tan popular como el K-Means, aunque presenta una importante ventaja sobre este: **el usuario no tiene necesidad de especificar el número de grupos** con el que requiere la clasificación.

3.3. Análisis de componentes principales

También conocido como PCA, es una técnica de clustering basada en la **reducción de dimensionalidad** de los datos con el objetivo de identificar agrupaciones y correlaciones entre estos.

3.4. Modelos de mezcla gaussiana (MMG)

Algoritmos de propósito de agrupación que se centran en la idea de que **cada dato tiene unas probabilidades de pertenecer a cada uno de los grupos** a partir de los cuales se realiza la segmentación.

Fig.4. Modelos de mezcla gaussiana de ejemplo.

Además de estos modelos, el aprendizaje no supervisado contempla otros muchos algoritmos, como son: Agrupación Espacial de Aplicaciones Basadas en la Densidad con Ruido (DBSCAN), *Singular Value Decomposition* (SVD) o Análisis de Componentes Independientes (ICA).

/ 4. Caso práctico 1: "¿Aprendizaje automático de tipo no supervisado o aprendizaje supervisado?"

Planteamiento: Un prestigioso equipo de fútbol quiere involucrar en su estrategia de planificación las aportaciones resultantes del empleo de tecnologías Big Data y de Analítica Avanzada. En concreto, la principal necesidad del equipo será predecir el tipo de lesiones que van a tener sus jugadores en función de los datos históricos almacenados con el paso de las temporadas.

Nudo: Para obtener respuesta a esta pregunta, el analista de datos contratado por el club empieza formulándose una serie de preguntas: 'En los datos históricos que tengo de los futbolistas, ¿tengo conocimiento previo del tipo de lesiones que han sufrido?, ¿tengo datos históricos sobre los que testear el buen funcionamiento de mi modelo?'.

Desenlace: Obviamente, la respuesta a estas preguntas es sí. Resulta obvio que estamos ante un problema en el que tenemos conocimiento previo de los resultados históricos, según los cuales nos resultará posible dar respuesta al problema planteado.

Por tanto, es realista determinar que es un problema de aprendizaje automático supervisado, el cual tendrá respuesta mediante alguno de los algoritmos que conforman este método de Machine Learning.

Fig.5. Futbolista lesionado.

¡! Sabías que...

En el siguiente enlace, encontrarás una noticia de cómo la AI puede ayudar a predecir las lesiones de los deportistas. https://www.larazon.es/atusalud/salud/la-inteligencia-artificial-es-capaz-de-predecir-el-riesgo-de-lesion-DF23267114/

/ 5. Casos de uso

De acuerdo con lo estudiado, hemos visto que los algoritmos de aprendizaje no supervisado tienen lugar en aquellos casos, muy usuales en el mundo real, en los que las muestras de datos aportados no tienen etiquetas conocidas previamente. Esto provoca que los algoritmos de aprendizaje no supervisado tengan una importante aplicación en los siguientes **casos de uso genéricos**:

- **Agrupación, o segmentación, de grandes conjuntos de datos** en grupos con los que comparten una serie de características definidas de forma específica.

- **Identificación de datos que no comparten características comunes** con ningunos de los grupos predefinidos, sino que presentan una serie de características específicas que podrían clasificarlos como anómalos.

A continuación, vamos a proponer ejemplos prácticos más específicos:

- **Segmentación de clientes** según los productos y servicios que contraten. Este caso concreto tuvo especial repercusión en lo llevado a cabo por la cadena de supermercados **WalMart**, la cual determinó que cuando **ciertos varones iban a la compra en fin de semana con el objetivo de adquirir pañales, muy a menudo, se hacían con un producto más: ¡cerveza!** Por tanto, el propio supermercado publicó una oferta para los fines de semana que incluía el pack: pañales y cerveza. Fue todo un éxito para las ventas de WalMart y uno de los principales casos de uso de aplicación de Machine Learning en Retail.

- **Agrupación de películas en base a los criterios de selección de los usuarios de Netflix** y al *feedback* de estos, con el objetivo de establecer recomendaciones basadas en los gustos de los clientes.

- **Agrupación de noticias o publicaciones del BOE**, entre otros tipos de publicaciones en formato de texto, en función de su contenido y temáticas específicas y de otras variables.

Vídeo 1. "Big Data y supermercados"
https://bit.ly/3mNEkbt

Enlaces de interés...

En el siguiente enlace, encontrarás un cass de uso basado en aprendizaje no supervisado muy popular en el ecosistema del aprendizaje automático promocionado por WalMart: https://www.esan.edu.pe/conexion/actualidad/2016/07/12/panales-y-cerveza/

/ 6. Caso práctico 2: "Segmentación de clientes"

Planteamiento: De sobra son conocidos los innumerables servicios y productos con los que cuentan las operadoras (además de la enorme competencia que existe en el mercado para comercializarlos). A este respecto, los datos de los clientes (gustos, preferencias y necesidades) resultan un atractivo que aporta un valor diferencial a la empresa que los utilice frente a su competencia.

Nudo: Una operadora concreta quiere evitar las conocidas llamadas masivas a sus potenciales clientes para ofrecerles el amplio catálogo de productos que tienen, y así eludir su hartazgo y la poca receptividad a las propuestas. En concreto, el principal objetivo de esta operadora es ofrecer a cada cliente los productos o servicios que le puedan interesar o ajustarse a sus necesidades, aumentando su ratio de ventas respecto de los intentos realizados.

Desenlace: Para ello, la operadora recopila los incontables datos de sus clientes, por ejemplo: los productos que consumen, su edad, perfil socioeconómico, sexo, procedencia, etc.

Sobre estos datos se aplican algoritmos basados en aprendizaje no supervisado para identificar agrupaciones de clientes y, por tanto, obtener visibilidad de los productos aún no contratados que podrían interesar a cada usuario de cada grupo. Sin duda, un importante avance en lo que respecta a incrementar la experiencia de venta en los clientes.

Fig.6. Usuario de operadora hablando por teléfono.

/ 7. Resumen y resolución del caso práctico de la unidad

En esta unidad, hemos estudiado los métodos de aprendizaje automático de tipo no supervisado. En concreto, hemos tomado como punto de partida su definición y proseguido con sus características asociadas y particularidades hasta llegar a los principales algoritmos asociados a este enfoque de Machine Learning.

A continuación, hemos aportado una visión específica de algunos casos de aplicación de este tipo de métodos, los cuales hemos asentado con la aportación de dos casos prácticos de aplicación.

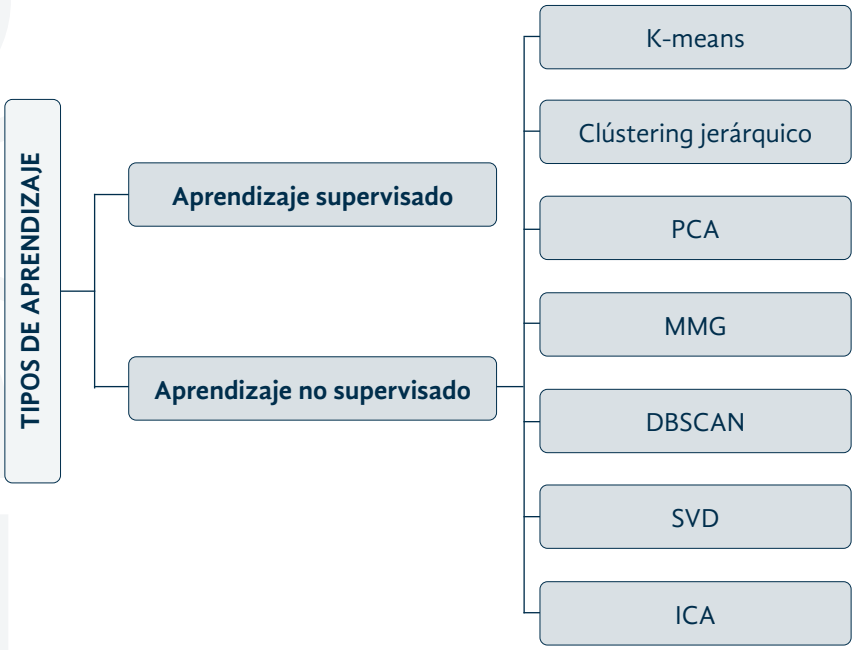

Fig.7. Mapa conceptual del tema.

Vídeo 2: "Recorrido por el aprendizaje no supervisado"

https://bit.ly/3EOJLxd

MEDAC

Resolución del caso práctico inicial

Por último, a modo de resolución, aportamos algunas formas de clasificar individuos u según características o patrones similares sin necesidad de conocer etiquetas, muchas de ellas muy empleadas en nuestra vida cotidiana:

- **Agrupación de personas en función del acento:** En España, rara vez necesitamos la etiqueta para reconocer si un ciudadano pertenece a una zona del país u otra, e incluso a una comunidad autónoma u otra.

- **Agrupación de monumentos en base a la época en la que fueron construidos:** El arte deja una serie de huellas en la arquitectura, huellas que permiten, de una manera o de otra, agrupar los monumentos según sus patrones de construcción.

- **Segmentación de clientes** con respecto a los productos contratados y al poder adquisitivo que denotan la contratación de los mismos.

- **Segmentación de vinos en función de su calidad** según una serie de patrones de composición identificados de forma autónoma por el algoritmo.

/ 8. Bibliografía

Víctor Román (junio 2019). *Aprendizaje No Supervisado en Machine Learning: Agrupación*. Disponible en: https://medium.com/datos-y-ciencia/aprendizaje-no-supervisado-en-machine-learning-agrupaci%C3%B3n-bb8f25813edc

Aprende IA. Disponible en: https://aprendeia.com/aprendizaje-no-supervisado-machine-learning/

Víctor Román (marzo 2019). *Aprendizaje Supervisado: Introducción a la Clasificación y Principales Algoritmos*. Disponible en: https://medium.com/datos-y-ciencia/aprendizaje-supervisado-introducci%C3%B3n-a-la-clasificaci%C3%B3n-y-principales-algoritmos-dadee99c9407

UNIR. *Clustering: qué es y cuál es su uso en Big Data*. Disponible en: https://www.unir.net/ingenieria/revista/clustering/

MEDAC