MEDAC
Instituto Oficial de Formación Profesional

SISTEMAS DE APRENDIZAJE AUTOMÁTICO

Deep Learning

5

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. ¿Qué es *Deep Learning*? 4

/ 3. ¿Cómo funciona *Deep Learning*? 4

/ 4. Casos de aplicación de *Deep Learning* 5

/ 5. Herramientas para el desarrollo de *Deep Learning* 6

/ 6. Caso práctico 1: "Clasificación de flores setosa, versicolor y virginia" 7

/ 7. Caso práctico 2: "Configuración de los parámetros propios de la red neuronal" 8

/ 8. Resumen y resolución del caso práctico de la unidad 9

/ 9. Bibliografía 9

© MEDAC
Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Conocer los principios en los que se basan las redes neuronales y las principales técnicas de Deep Learning.

Descubrir los diferentes tipos de redes neuronales que hay, sus principales casos de aplicación y las herramientas fundamentales para su desarrollo.

/ 1. Introducción y contextualización práctica

La Inteligencia Artificial es una de las tecnologías emergentes de mayor tendencia y repercusión en la sociedad actual.

En este contexto, ***Deep Learning* es una de las técnicas de Inteligencia Artificial más populares y empleadas** por los científicos de datos. Esto es por su rendimiento y los innumerables casos de uso desarrollados por las grandes tecnológicas sobre ella.

En la presente unidad, vamos a partir del concepto, procedente del cuerpo humano, que inspiró a este modelo de IA para conocer las principales aplicaciones y casos de uso en los que se emplea.

De forma adicional, descubriremos las principales herramientas para el desarrollo de redes neuronales.

A continuación, vamos a plantear un caso práctico a través del cual podremos aproximarnos de forma práctica a la teoría de este tema.

Escucha el siguiente audio, donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

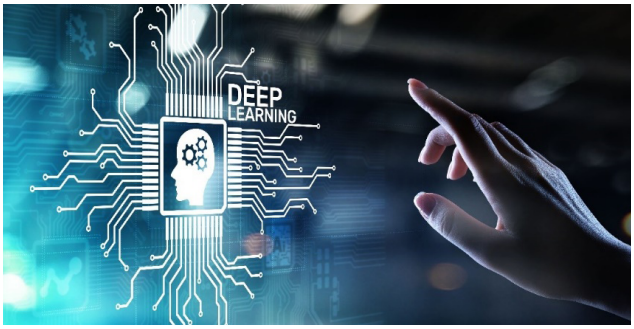

Fig.1. Deep Learning.

Audio intro. "Datos no estructurados"
https://bit.ly/3onrBx4

/ 2. ¿Qué es *Deep Learning*?

Deep Learning, en castellano **Aprendizaje Profundo**, representa **un conjunto de algoritmos de *Machine Learning*** cuyo funcionamiento se basa en el reconocimiento de características y patrones de los datos mediante capas de procesamiento de parámetros configurables.

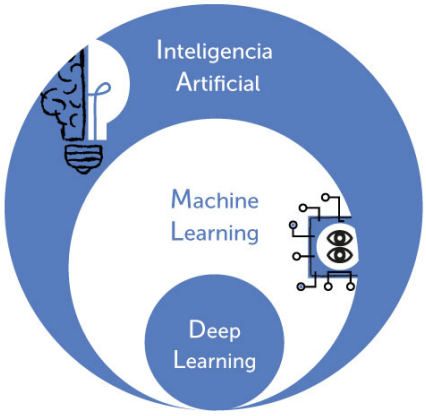

Fig.2. Deep Learning, modelos de IA.

Esta técnica está basada en el concepto de **red neuronal artificial**, formada por **un conjunto de nodos**, conocidos en términos de *Deep Learning* como neuronas, que, interconectados entre sí, **establecen la configuración completa de la red**.

Tomando como base este concepto de red neuronal artificial, **existen diversas arquitecturas** que, en su conjunto, determinan la práctica tecnológica de *Deep Learning*. Algunas de estas arquitecturas de aprendizaje profundo son: redes neuronales convolucionales, redes neuronales recurrentes, etc.

Todas ellas basan su configuración en **el cerebro humano**, el cual es capaz de identificar una serie de características y patrones basándose en el **trabajo colaborativo realizado por sus neuronas**, interconectadas entre sí.

Vídeo 1. "Deep Learning vs. Machine Learning"

https://bit.ly/34DSQN6

/ 3. ¿Cómo funciona *Deep Learning*?

De acuerdo con lo estudiado en el apartado anterior, *Deep Learning* y las redes neuronales artificiales que conforman sus modelos están basados en el funcionamiento del cerebro humano.

En este contexto, de la misma forma que las neuronas en las redes neuronales de nuestro cerebro, también cuentan con una serie de **datos de entrada** y una serie de **resultados de salida**. Estos dependerán del caso de aplicación (clasificación de colores, elegir entre sí o no, predecir una medida concreta, etc.).

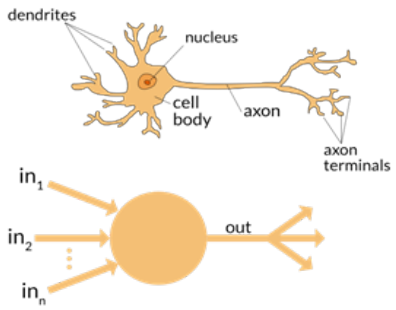

Fig.3. Diferencia entre una neurona normal y artificial.

Es, precisamente, la combinación de los datos de entrada y de salida, además de otras aportaciones adicionales incluidas en el modelo entre las neuronas de la red, lo que determinará **la configuración completa de la red y, por tanto, del modelo de *Deep Learning***.

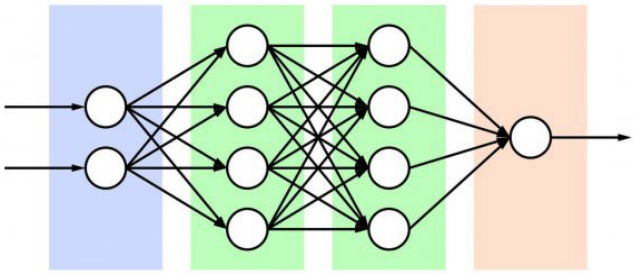

Fig.4. Arquitectura de red neuronal.

En concreto, las redes neuronales profundas se conforman principalmente de los siguientes componentes específicos:

- **Capa de entrada**: Relativa a la capa azul de las representadas en la figura anterior. Es aquí donde se localizan las **neuronas encargadas de recoger los datos de entrada** de la red. Sus salidas corresponderán a las entradas de las capas ocultas, detalladas a continuación.

- **Capas ocultas**: Son las encargadas de procesar los datos de entrada mediante una serie de ponderaciones variables para llegar a la/s neurona/s correspondientes a las capas de salida.

- **Capas de salida**: Relativa a la capa roja de la imagen anterior. Es donde **se sitúan las neuronas necesarias para dar respuesta a los campos de destino**. Por ejemplo, en los casos en los que se requiera predecir un valor concreto, estaremos ante un problema de regresión y, por tanto, necesitaremos una única neurona. En cambio, si estamos ante un problema de clasificación multiclase, tendremos tantas neuronas de salida como clases haya.

/ 4. Casos de aplicación de *Deep Learning*

La popularidad de los algoritmos de *Deep Learning* se ha incrementado de forma exponencial desde que Google, en 2012, aplicase redes profundas para identificar gatos en vídeos de YouTube. Y este, precisamente, es **uno de los principales casos de aplicación** de estos tipos de algoritmos: **el reconocimiento de imágenes**.

En concreto, las redes neuronales, mediante su arquitectura de redes profundas de **convolución**, consiguen imitar el procedimiento del cerebro para detectar colores, formas y, en definitiva, las características específicas que conforman una imagen.

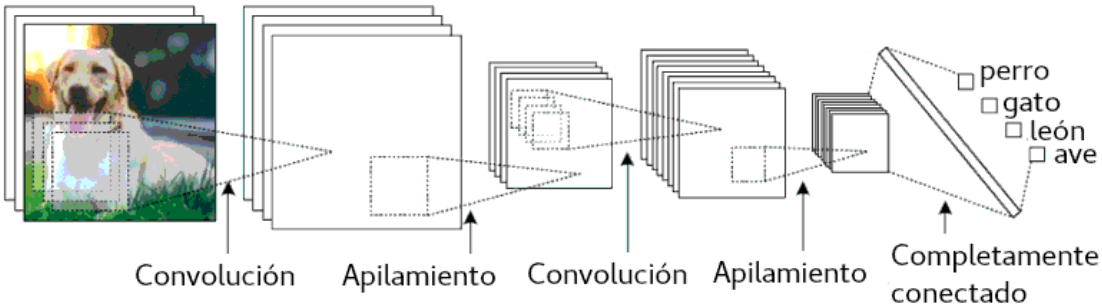

Fig.5. Ejemplo de red de convolución para reconocer perros.

Este caso de aplicación tiene innumerables ejemplos de proyectos reales en la actualidad. Destacan iniciativas como **Shazura**, una *startup* que, mediante redes neuronales de convolución, identifica logos y marcas en vídeos e imágenes; o las funcionalidades aportadas por **WhoCamera** para identificar los rostros de celebridades de una forma ágil y eficaz.

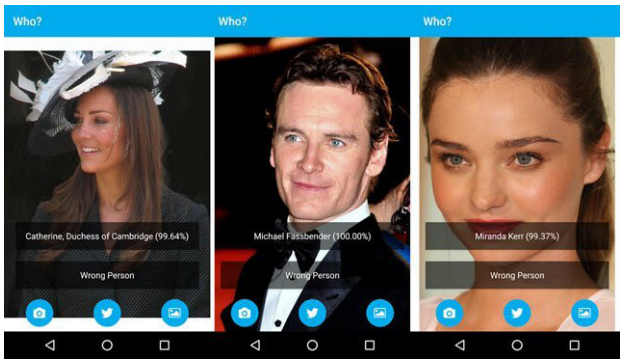

Fig.6. Ejemplo práctico de cómo funciona WhoCamera.

Independientemente de que el caso de aplicación relativo al reconocimiento de imágenes es de los más conocidos y populares de *Deep Learning*, el empleo de redes neuronales no se cierra únicamente a este tipo de uso.

Las redes neuronales también pueden ser empleadas desde para **predecir resultados continuos relativos a problemas de regresión**, hasta resolver **problemas de clasificación, binarios y multiclases**. Un ejemplo práctico de aplicación de *Deep Learning* en un problema de clasificación binario es **la identificación de correos *spam*, desarrollada por Google**.

Deep Learning también se emplea para proyectos de Procesamiento del Lenguaje Natural (NLP). Algunos ejemplos son los aportados por Google, como su herramienta de reconocimiento de voz de **Google Now** o las traducciones de **Google Translate**, tal y como hemos visto en otro módulos.

Audio 1. "Imágenes y rostros en Deep Learning"
https://bit.ly/3uqTuIC

/ 5. Herramientas para el desarrollo de *Deep Learning*

A la hora de hablar de las principales herramientas disponibles para que los científicos de datos generen algoritmos de *Deep Learning*, resulta realista poner el foco en, principalmente, las tres específicamente detalladas a continuación:

- **TensorFlow**: ***Framework* de código abierto** muy flexible, **su enorme popularidad se basa en sus facilidades para customizar modelos** y adaptarlos a las necesidades específicas del proyecto. Tiene muy buena receptibilidad para investigadores. Fue desarrollado por el equipo de Google y lanzada en noviembre de 2015.

- **Keras: *Framework* de código abierto escrito en Python**. Está diseñado para ser ejecutado sobre TensorFlow y otros *frameworks* de desarrollo quizá menos populares como Microsoft Cognitive Toolkit. **Destaca por su amabilidad de empleo para el usuario**. Fue diseñado por François Chollet, ingeniero de Google.

- **PyTorch: *Framework* de código abierto** muy empleado en el Procesamiento del Lenguaje Natural y *Deep Learning*. Fue desarrollado por el *AI Research Lab* de Facebook. A menudo, los partidarios de PyTorch defienden su posicionamiento frente a TensorFlow por la **significativa de reducción de los tiempos de entrenamiento**.

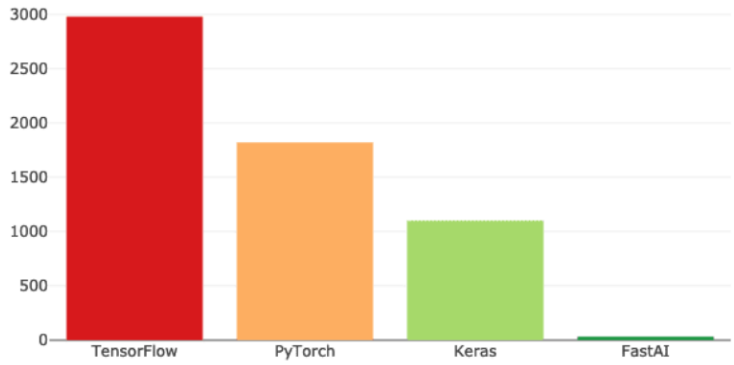

Fig.7. Popularidad de frameworks de Deep Learning en los últimos años.

Enlaces de interés...

En el siguiente enlace, se aporta información acerca de las principales diferencias entre Keras y PyTorch: https://www.datacamp.com/es/tutorial/pytorch-vs-tensorflow-vs-keras

/ 6. Caso práctico 1: "Clasificación de flores setosa, versicolor y virginia"

Planteamiento: Existen tres tipos de flores setosa, versicolor y virginia; a simple vista pueden resultar exactamente iguales dado su color, forma, tamaño, etc. No obstante, presentan una serie de diferencias específicas que permiten su identificación, por parte de los expertos en la materia, con un elevado nivel de precisión.

Nudo: Con el objetivo de aplicar tecnologías de Inteligencia Artificial sobre algunos aspectos de la naturaleza, se plantea el reto de identificar los tipos de flores previamente comentadas mediante un algoritmo de *Machine Learning*, sin contar con la involucración directa de ningún experto en la materia. Para ello, surge la pregunta: entre todos los algoritmos de *Machine Learning* disponibles, ¿cuál será el más apropiado para dar respuesta a esta necesidad?

Iris Versicolor **Iris Setosa** **Iris Virginica**

Fig.8. Las flores previamente comentadas.

Desenlace: Dado que los principales datos de entrada los tenemos en formato de imágenes, necesitaremos un modelo que permita, a partir del reconocimiento de imágenes, extraer una serie de características que habiliten a la clasificación de cada muestra con su grupo respectivo. Naturalmente, en este contexto, surge la opción de considerar las **redes neuronales de convolución**, debido a su buen rendimiento a la hora de procesar y extraer información de imágenes.

Una vez seleccionado este tipo de modelo, surgirá la duda de configurar los parámetros propios de la red: el número de capas, el número de neuronas por capas, etc.

A continuación, en el siguiente enlace, encontraréis un artículo sobre clasificación con *Deep Learning*.

Enlaces de interés...

En el siguiente enlace, encontrarás un artículo acerca de la clasificación de flores con Deep Learning. Es algo realmente interesante que te animamos a leer: https://www.neuraldesigner.com/learning/examples/iris-flowers-classification

/ 7. Caso práctico 2: "Configuración de los parámetros propios de la red neuronal"

Planteamiento: Un equipo de trabajo de científicos de datos se enfrenta a dos problemas a los que dar respuesta con algoritmos de *Deep Learning*. Uno de ellos va focalizado a la predicción de una cifra concreta, es decir, un problema de **regresión**. Otro de ellos consiste en realizar una predicción multiclase, eligiendo entre siete tipos de grupos diferentes.

Nudo: Dado que tenemos dos problemas específicos, requeriremos de dos redes, una para cada problema. En este punto, surge la necesidad de definir los diferentes parámetros para iniciar el entrenamiento y validación de cada una de las redes. En primera instancia, nos centraremos en definir el número de neuronas que formarán la capa de salida de la red neuronal específica.

Desenlace: En este contexto, basta con focalizarnos y acotar el tipo de problemas que se nos presentan.

El primero de ellos es un proyecto en el que requerimos predecir un valor continuo concreto. Es decir, se trata de un **problema de regresión**, para el que solamente necesitaremos una única neurona en la capa de salida de la red.

En el segundo de ellos, dado que tenemos que predecir entre siete clases diferentes, necesitaremos **una neurona por cada una de las clases** en las que buscamos predecir los datos. Cada una de esas siete neuronas calculará la probabilidad de que la muestra pertenezca al tipo de clase concreta.

Fig.9. Una red neuronal.

/ 8. Resumen y resolución del caso práctico de la unidad

En esta unidad, hemos profundizado en el concepto de *Deep Learning*, una de las técnicas más avanzadas de Inteligencia Artificial y de mayor popularidad en el momento actual.

Más en concreto, hemos conocido su funcionamiento y el origen del mismo. También, los principales casos de aplicación en los que los científicos de datos recurren a esta tecnología.

Por último, hemos aportado una visión global de las principales herramientas empleadas para el desarrollo de casos de uso sobre *Deep Learning*.

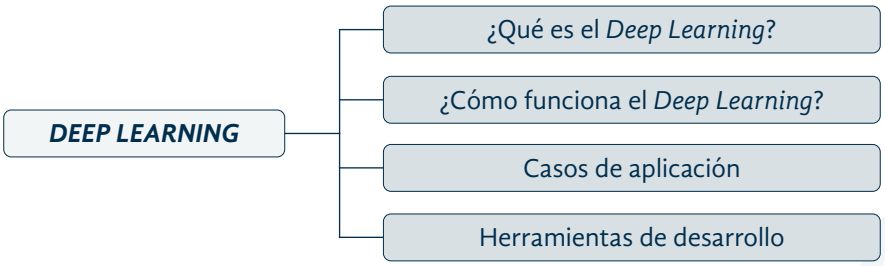

Fig.10. Esquema resumen del tema.

Resolución del caso práctico

En el caso práctico inicial, se cuestiona acerca de diferentes tipos de datos no estructurados generados en la actualidad y que, correctamente analizados, pueden aportar enorme conocimiento acerca de negocios específicos.

Algunos ejemplos son **las imágenes y los vídeos**, los cuales, procedentes, por ejemplo, de redes sociales, pretenden aportar una visión muy aproximada sobre los usuarios de las redes y los intereses de los potenciales clientes y consumidores.

Otro ejemplo práctico puede ser el caso del **almacenamiento y análisis de mensajes de texto**. Es el caso de los **correos electrónicos**, que pueden aportar información de interés acerca de la temática o del redactor de los mismos.

Por último, otro tipo puede ser el **análisis de documentos**, con el objetivo de poder clasificarlos e incluso de detectar valores que puedan ser organizados a su vez con formato de datos estructurados.

Vídeo 2. "Deep Learning"
https://bit.ly/3AUhTaE

/ 9. Bibliografía

SAS *¿Qué es Deep Learning y por qué es importante?* Disponible en:
https://www.sas.com/es_es/insights/analytics/deep-learning.html

Diego Calvo (julio 2017). *Clasificación de redes neuronales artificiales*. Disponible en:
https://www.diegocalvo.es/clasificacion-de-redes-neuronales-artificiales/

Iñaki Ladero (noviembre 2018). *Deep Learning: qué es y cómo se está usando*. Disponible en:
https://www.baoss.es/que-es-deep-learning-usos/

Aurelien Geron (2017). *Hands–On Machine Learning with Scikit–Learn and TensorFlow*.