MEDAC
Instituto Oficial de Formación Profesional

SISTEMAS DE APRENDIZAJE AUTOMÁTICO

Aprendizaje por refuerzo

6

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. ¿Qué es el aprendizaje por refuerzo? 4

/ 3. Elementos de aprendizaje por refuerzo 4

/ 4. Caso práctico 1: “Tres en raya” 5

/ 5. Exploración y explotación 6

/ 6. Aplicaciones del aprendizaje reforzado 7

/ 7. Caso práctico 2: “El camino hacia la conducción autónoma” 8

/ 8. Resumen y resolución del caso práctico de la unidad 8

/ 9. Bibliografía 9

© MEDAC
Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Definir qué es el aprendizaje por refuerzo.

Analizar las técnicas principales del aprendizaje por refuerzo.

Conocer las principales aplicaciones de aprendizaje por refuerzo.

/ 1. Introducción y contextualización práctica

El aprendizaje por refuerzo o reforzado (*reinforcement learning,* en inglés) es una rama del aprendizaje automático.

Es empleado por varios tipos de *software* y máquinas para encontrar el mejor comportamiento o ruta posible a tomar en una situación específica.

En esta unidad, analizaremos con más detalle en qué consiste el aprendizaje reforzado, estudiando los componentes que permiten su funcionamiento, así como sus diversas aplicaciones.

A continuación, escucha el siguiente audio, donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

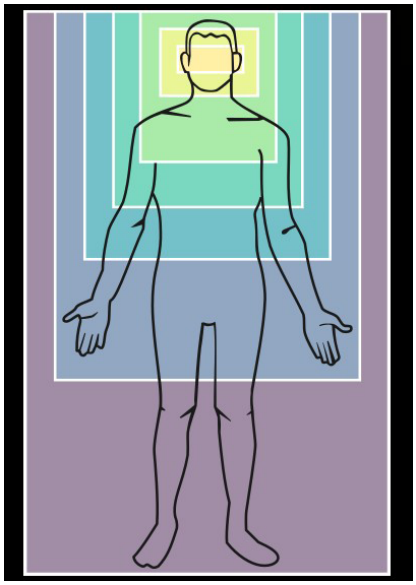

Fig.1. Aprendizaje por refuerzo y visión artificial.

Audio intro. "Turismo en tiempos de pandemia"

https://bit.ly/3Hv1OKh

/ 2. ¿Qué es el aprendizaje por refuerzo?

El aprendizaje por refuerzo es uno de los tres tipos de *Machine Learning*. El fin del aprendizaje por refuerzo es conseguir que una máquina tome medidas adecuadas para maximizar la recompensa, en una situación particular. El agente no está programado o entrenado para tomar determinadas decisiones, sino que debe experimentar siguiendo una lógica de **ensayo y error**, hasta encontrar las acciones que le lleven a conseguir una mayor recompensa.

En el aprendizaje por refuerzo, sus desarrolladores establecen un método para **recompensar los comportamientos deseados y castigar los comportamientos negativos**. Este método asigna valores positivos a las acciones deseadas para estimular la máquina (agente) y valores negativos a conductas no deseadas. De esta manera, el agente busca una recompensa general máxima y a largo plazo, para lograr una solución óptima. Estos objetivos a largo plazo ayudan a evitar que el agente se detenga en objetivos menores.

A diferencia del aprendizaje supervisado, donde el algoritmo aprende las reglas a partir de los datos etiquetados con los que se entrena (la solución está, por tanto, en los propios datos), en el aprendizaje por refuerzo, no hay una solución predeterminada, sino que la máquina (agente) tiene que actuar hasta encontrar, tras múltiples iteraciones, una solución. Así, mientras que, en el aprendizaje supervisado, cada decisión es independiente y se basa en el dato de entrada, en el aprendizaje por refuerzo, las decisiones son secuenciales y dependientes de la decisión inmediatamente anterior.

En cuanto a las diferencias con el aprendizaje no supervisado, mientras que los algoritmos de este se emplean para encontrar estructuras y relaciones ocultas en datos no etiquetados, el aprendizaje reforzado se centra en aumentar la señal de recompensa.

	APRENDIZAJE SUPERVISADO	APRENDIZAJE NO SUPERVISADO	APRENDIZAJE POR REFUERZO
Objetivo	Predecir	Encontrar relaciones en datos	Optimizar toma de decisiones
Aprendizaje	Entrenamiento con datos etiquetados	Sin entrenamiento	Experiencia
Decisiones	Independiente	Independiente	Secuencial y dependiente
Estrategia de mejora	Reducir error	Reducir error	Aumentar recompensa

Tabla 1. Tipos de Machine Learning.

Enlaces de interés...

En este artículo, conocerás la historia de MENACE, el primer algoritmo de aprendizaje por refuerzo, diseñado para aprender a jugar al tres en raya: https://www.iic.uam.es/noticias/primer-algoritmo-de-aprendizaje-por-refuerzo-menace/

/ 3. Elementos de aprendizaje por refuerzo

El aprendizaje por refuerzo propone un enfoque alternativo para conseguir que un agente aprenda. Podemos distinguir dos elementos fundamentales:

- **Agente**: Es la máquina que entrenaremos para que aprenda a tomar decisiones que maximicen su recompensa.
- **Entorno**: Es el medio ambiente con el que el agente interacciona. El agente recibe las acciones del entorno y evoluciona. Su comportamiento suele ser desconocido. Es el responsable de generar las recompensas asociadas a las acciones y cambios de estado.

Entre el agente y el entorno hay siempre una relación de retroalimentación, que va variando con cada una de las decisiones que toma el agente, mediante los siguientes nexos:

- **Acción**: La decisión que toma un agente en un momento determinado, basándose en una política o estrategia.
- **Estado**: Es el conjunto de indicadores que informan al agente de la situación de los diversos elementos del entorno, en un momento determinado.
- **Recompensa**: Representa el premio o la penalización que recibirá un agente como consecuencia de una acción.

Además del agente y el medio ambiente, podemos destacar otros elementos esenciales:

- **Política**: Define la estrategia del agente. Es un mapeo de todas las acciones posibles que puede tomar un agente, en un momento determinado. La política establece las reglas de asociación entre el estado del entorno y la acción a tomar.
- **Función de valor**: Refleja una estimación de la recompensa a largo plazo que se va a recibir, partiendo de un cierto estado y siguiendo una política determinada. Esta función es clave para que el agente aprenda a buscar la recompensa máxima.
- **Modelo del entorno**: En caso de estar presente en el sistema, estos modelos permiten simular y predecir la evolución del medio ambiente, ayudando al agente a resolver el problema.

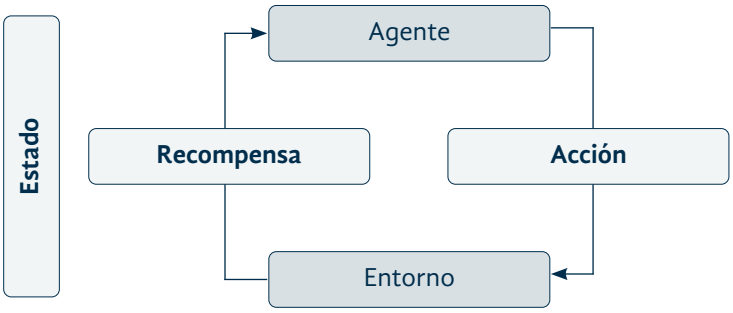

Fig.2. Aprendizaje por refuerzo.

Audio 1. "Elementos básicos del aprendizaje por refuerzo"
https://bit.ly/3vuEQ3u

/ 4. Caso práctico 1: "Tres en raya"

Planteamiento: Queremos diseñar un modelo de aprendizaje por refuerzo en el que el agente aprenda a jugar al clásico juego de tres en raya.

Nudo: ¿Cómo lo haríamos?

Desenlace: A nivel conceptual, podemos considerar que el agente es uno de los jugadores, y el entorno incluye el juego de mesa con sus reglas y el otro jugador. El algoritmo se encarga de analizar movimientos y comprobar cuáles producen recompensas. Para el algoritmo, no sería difícil encontrar los movimientos que ganan la partida, en un estado determinado. Para ello, podemos utilizar una tabla de recompensas que muestre como filas los diferentes estados y como columnas las acciones posibles, determinando en cada celda si hay recompensa.

Así, será fácil identificar aquellas acciones que, para un determinado estado, permiten al agente hacer tres en raya y recibir la recompensa. Sin embargo, hay muchas acciones sin recompensa, pues se requiere un cierto número de estados y acciones hasta llegar al fin de la partida. ¿Cómo puede aprender el algoritmo qué hacer en estas jugadas intermedias?

En este caso, podemos utilizar las llamadas recompensas mixtas, que son recompensas a corto plazo. De esta forma, podemos definir que existe una recompensa en las jugadas intermedias, cuya cuantía es menor que la recompensa de las acciones ganadoras. Así, cada experiencia, en el juego, constituiría cuatro elementos: el estado en un momento determinado, la acción del agente, una recompensa asociada (mixta o ganadora) y un estado siguiente, resultante de la acción de otro jugador.

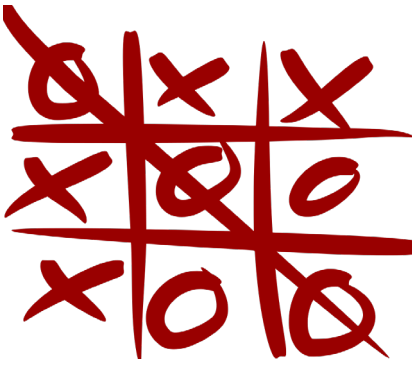

Fig.3. Tres en raya.

De este modo, el algoritmo puede aprender a jugar en todas las fases del juego. La estrategia de aprendizaje del algoritmo dependerá de dos parámetros: la velocidad de aprendizaje (*learning rate*) y el factor de descuento (*discount factor*).

/ 5. Exploración y explotación

En algún momento, todos nos hemos enfrentado a este dilema vital: ¿Debería seguir haciendo lo que hago, aunque me dé buenos resultados, o debería intentar algo nuevo? ¿Debería ir a mi restaurante de confianza, donde tengo la garantía de que la comida es de calidad, o debería probar un nuevo restaurante? ¿Mantenerme en mi trabajo actual o perseguir nuevas aventuras profesionales?

En el aprendizaje por refuerzo, esta tesitura se conoce como el **dilema de la exploración y la explotación**.

El fin último de un algoritmo de aprendizaje por refuerzo es maximizar su recompensa. Para ello, el algoritmo aprende por medio de ensayo y error. Tras una serie de iteraciones, el algoritmo puede decantarse por repetir acciones que ya ha intentado en el pasado y que sabe que son efectivas para producir recompensas. Dicho de otro modo, el algoritmo decide explotar las acciones que ya conoce. Sin embargo, esta estrategia conservadora —al fin y al cabo, la exploración es un proceso costoso, en términos de recursos, tiempo y oportunidades— puede hacer que el algoritmo pierda la oportunidad de probar nuevas acciones que nunca antes había seleccionado y que podrían resultar en una recompensa más grande, especialmente en situaciones de mayor incertidumbre, donde el entorno es inexplorado.

Encontrar un equilibrio entre la explotación de las acciones y estrategias que aprendió el agente y explotar nuevas acciones para maximizar la recompensa en el futuro, es un tema crucial y recurrente en la investigación y el diseño de modelos de aprendizaje por refuerzo.

Fig.4. Explorar o explotar, esa es la cuestión.

/ 6. Aplicaciones del aprendizaje reforzado

El aprendizaje por refuerzos es una de las áreas de la Inteligencia Artificial con mayor proyección. Muchos de los avances y aplicaciones más recientes en este ámbito están vinculados al desarrollo del aprendizaje profundo. La combinación del aprendizaje por refuerzo y las redes neuronales se conoce como aprendizaje profundo por refuerzo (*deep reinforcement learning)*. Mientras que, en el aprendizaje por refuerzo tradicional, la política o estrategia del agente se basa en algoritmos más o menos complejos, en el aprendizaje profundo por refuerzo, la capacidad de aprendizaje de un agente viene dada por una red neuronal artificial, que le permite alcanzar unos niveles de optimización mayores.

Enlaces de interés...

En este artículo encontrarás ejemplos de algunos modelos basados en aprendizaje por refuerzo: https://medium.com/aprendizaje-por-refuerzo-introducci%C3%B3n-al-mundo-del/aprendizaje-por-refuerzo-introducci%C3%B3n-al-mundo-del-rl-1fcfbaa1c87

Uno de los ámbitos donde el aprendizaje por refuerzo ha tenido un impacto más mediático es el mundo de los videojuegos. Los juegos han sido, durante décadas, un lugar idóneo para el desarrollo de los modelos de aprendizaje por refuerzo. La victoria de Deep Blue frente al campeón de mundo de ajedrez, Gary Kaspárov, en 1996, supuso el pistoletazo inicial de una serie de hitos en los que las máquinas han vencido a jugadores profesionales en juegos cada vez complejos, gracias, una vez más, al desarrollo del aprendizaje profundo.

Algunos sectores donde el aprendizaje reforzado ofrece grandes oportunidades son:

- **Conducción autónoma**: El agente suele ser un coche y el entorno, una carretera. El objetivo es encontrar una política que permita al agente circular sin chocarse y respetando las reglas de circulación. Todo ello sin necesidad de un conductor.

- **Robótica**: Las aplicaciones son muy variadas, desde robots industriales que consigan moverse por una fábrica sin colisionar con los objetos hasta robots aspiradora capaces de aprender las características espaciales de una casa para optimizar las labores de limpieza.

- **Atención médica**: El aprendizaje reforzado cada vez ofrece más oportunidades en el sector médico, donde las decisiones de diagnóstico o los regímenes de tratamiento, generalmente, se caracterizan por un procedimiento prolongado y secuencial. Algunos casos de uso se han dado en el desarrollo de regímenes de tratamiento dinámicos, en enfermedades crónicas o en cuidados intensivos.

- **Visión artificial**: Cada día se desarrollan nuevas aplicaciones en el campo del procesamiento de imágenes basadas en modelos de aprendizaje profundo por refuerzo, como la detección de objetos, la segmentación de imágenes, el análisis de vídeo o la localización de puntos de referencia.

Vídeo 1. "Hacia la conducción autónoma"

https://bit.ly/3K4SZZ2

/ 7. Caso práctico 2: "El camino hacia la conducción autónoma"

Planteamiento: El siempre polémico director de un gigante tecnológico acaba de anunciar, por X, un nuevo proyecto en el que la empresa destinará miles de millones de dólares: construir coches autónomos.

Nudo: Gracias a los recientes avances en el campo del aprendizaje profundo por refuerzo, hoy es posible entrenar agentes que, por medio de sensores, consigan captar la información sobre la escena de tráfico y tomar decisiones pertinentes, que permitan al coche circular sin chocarse ni provocar accidentes.

Después de experimentar durante varios años, el director anuncia que han conseguido crear un primer prototipo; cuenta que este, pese a su uso no comercial, ha dado muy buenos resultados, siendo capaz de recorrer 200 kilómetros sin ningún percance. Pletórico, el director publica un tuit en el que dice que la conducción, tal y como la conoces, está al borde de la muerte. ¿Qué opinas al respecto?

Desenlace: Pese a los avances extraordinarios, en el campo de la conducción autónoma, los analistas coinciden en que todavía queda un largo camino para alcanzar la conducción autónoma plena. Esta tecnología todavía presenta riesgos, que deben ser considerados y mitigados, antes de cualquier salida al mercado.

Por ejemplo, los investigadores han demostrado que es muy fácil confundir a los sensores que reconocen la escena de tráfico a través de imágenes —por ejemplo, dificultando la capacidad de identificar personas—, lo que induce a fallos, en la toma de decisión, que pueden ser mortales.

Fig.5. El coche autónomo.

Enlaces de interés...

Lee este artículo sobre los problemas que tienen por delante los coches autónomos:
https://fesvial.es/luis-montoro-alerta-de-los-problemas-del-coche-autonomo/

Igualmente, estos agentes necesitan más entrenamiento para poder funcionar eficazmente en entornos de mayor riesgo. Así, estos prototipos suelen probarse en carreteras amplias, con poco tráfico y escasos peatones. Sin embargo, su eficacia puede reducirse en entornos urbanos, donde hay más vehículos, peatones y, en general, estímulos a tener en cuenta para evitar accidentes.

/ 8. Resumen y resolución del caso práctico de la unidad

En esta unidad, hemos hecho una primera introducción al aprendizaje por refuerzo, uno de los tres tipos de aprendizaje automático.

En los dos primeros apartados, hemos abordado la definición y características de este tipo de aprendizaje, así como los elementos que lo constituyen.

Posteriormente, hemos analizado una cuestión clave en el desarrollo de estos modelos: el dilema entre exploración y explotación. Por último, hemos enumerado algunos campos en los que el aprendizaje por refuerzo y el aprendizaje profundo por refuerzo están teniendo un amplio desarrollo.

En la siguiente imagen encontrarás el esquema resumen del tema:

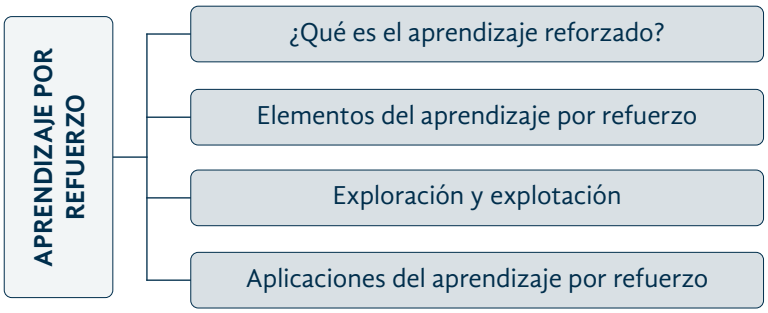

Fig.6. Esquema resumen del tema.

Resolución del caso práctico de la unidad

Muchos algoritmos de recomendación se basan en datos de experiencias pasadas, para predecir las preferencias de los usuarios. Se necesitan muchos datos para que estos algoritmos funcionen eficazmente. Esto hace que, en muchas ocasiones, los algoritmos no consigan captar las preferencias cambiantes de los usuarios, a menos que se vuelvan a entrenar con datos nuevos, lo cual es muy costoso, además, no siempre hay datos disponibles para reentrenar.

Esta situación se vuelve problemática cuando hay cambios radicales en las preferencias de los usuarios por causas imprevistas. La pandemia es un claro ejemplo. El riesgo de contagio y la situación epidemiológica de una región o país pueden tener una clara influencia en las preferencias de los usuarios, que quizá ahora prefieran destinos cercanos con poca afluencia, en lugar de grandes hoteles en zonas muy turísticas.

Utilizar el aprendizaje por refuerzo puede ser una solución para adaptarse a las preferencias cambiantes de los usuarios. Este enfoque permite, al agente, interactuar por ensayo y error y a tiempo real, para adaptarse, con más flexibilidad, a las necesidades de los usuarios. Esto permitiría predecir preferencias con mayor exactitud. Por esa razón, cada día más empresas están apostando por ello.

/ 9. Bibliografía

Langston, J. (2020). *Con aprendizaje de refuerzo, Microsoft lleva una nueva clase de soluciones de IA a los clientes*. Microsoft. Disponible en: https://news.microsoft.com/es-xl/features/con-aprendizaje-de-refuerzo-microsoft-lleva-una-nueva-clase-de-soluciones-de-ia-a-los-clientes/

Geeks for Geeks (2021). *Reinforcement Learning*. Disponible en: https://www.geeksforgeeks.org/what-is-reinforcement-learning/

Carew, J. *Reinforcement Learning*. TechTarget. Disponible en: https://searchenterpriseai.techtarget.com/definition/reinforcement-learning

Aprende Machine Learning. *Aprendizaje por Refuerzo*. Disponible en: https://www.aprendemachinelearning.com/aprendizaje-por-refuerzo/

Silva, M. (2019). *Aprendizaje por Refuerzo: Introducción al mundo del RL*. Medium. Disponible en: https://medium.com/aprendizaje-por-refuerzo-introducci%C3%B3n-al-mundo-del/aprendizaje-por-refuerzo-introducci%C3%B3n-al-mundo-del-rl-1fcfbaa1c87

Torres, J. (2020). *A gentle introduction to Deep Reinforcement Learning*. Medium, Towards Data Science. Disponible en: https://towardsdatascience.com/drl-01-a-gentle-introduction-to-deep-reinforcement-learning-405b79866bf4