MEDAC
Instituto Oficial de Formación Profesional

SISTEMAS DE BIG DATA

Técnicas de integración, procesamiento y análisis de la información

1

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. Introducción a la integración de los datos 4

2.1. Técnicas de integración de datos 5

2.2. Metologías de integración 6

/ 3. Caso práctico 1: “Perritos calientes” 7

/ 4. Procesamiento y análisis en Big Data 8

4.1. Análisis descriptivo 8

4.2. Análisis predictivo 8

4.3. Análisis prescriptivo 8

/ 5. Caso práctico 2: “Rolls-Royce” 9

/ 6. Resumen y resolución al caso práctico de la unidad 10

/ 7. Bibliografía 11

© MEDAC

Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Integración de datos.

Procesamiento de datos.

Análisis de datos.

/ 1. Introducción y contextualización práctica

A continuación, se introducen los conceptos a tratar a lo largo de la unidad:

- La **integración de Big Data,** como veremos**,** consiste en agregar datos diferentes procedentes de distintas fuentes para obtener una visión de 360°. Estos serán cargados en repositorios dedicados específicamente a grandes volúmenes de información.
- El **procesamiento de Big Data** es el conjunto de técnicas o modelos de programación para acceder a grandes volúmenes de datos.
- El **análisis de Big Data** se centra en emplear técnicas de analítica avanzada para extraer conocimiento implícito en las fuentes de datos que aún no han sido explotadas.

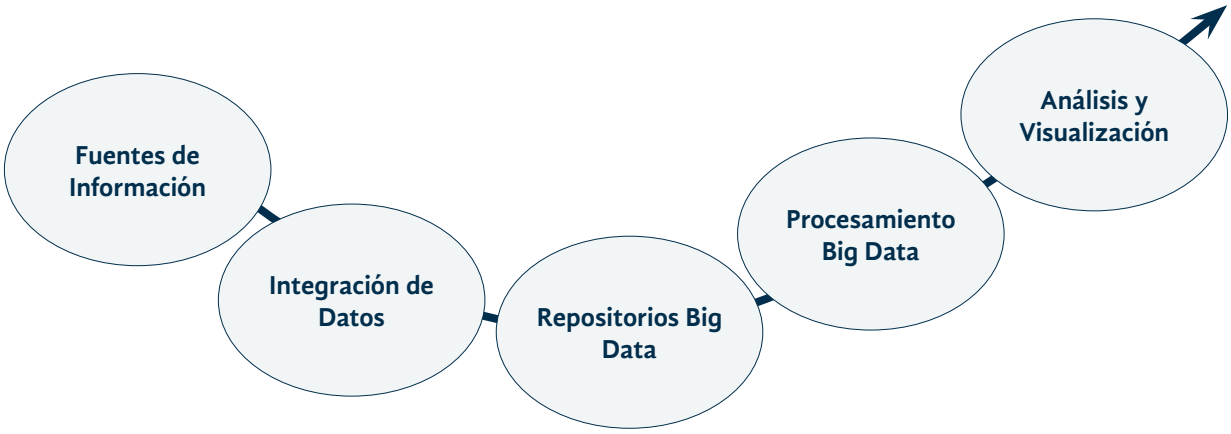

Fig.1. Grupos de procesos en Big Data.

A continuación, vamos a plantear un caso práctico a través del cual podremos aproximarnos de forma práctica a la teoría de este tema. Escucha el siguiente audio donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

Audio intro. "Proyecto Big Data para Análisis Coste Beneficio para un operador del sector aviación"

https://bit.ly/3H5c8c9

/ 2. Introducción a la integración de los datos

La integración de datos se lleva a cabo sobre flujos de información procedentes de diferentes fuentes para minimizar los gastos de almacenamiento, así como para dar una visión unificada de los datos. Permite tomar decisiones de acuerdo con datos esclarecedores en lugar de hacerlo según asunciones.

Los retos técnicos para implementar esto residen en las cinco V's:

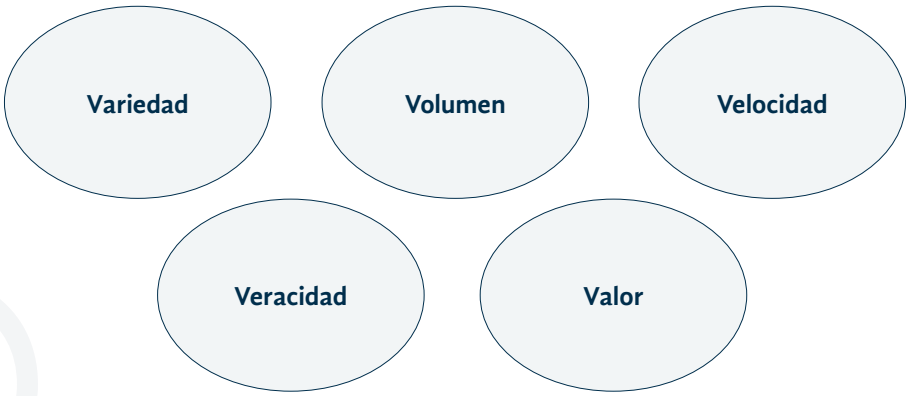

Fig.2. Las 5 V's del Big Data.

- **Variedad:** Existen muchos tipos de datos (estructurados, semiestructurados, no estructurados, datos de sensores...), por lo que la herramienta de integración que se use debe ser capaz de mapear y transformarlos en algo útil para el usuario. La herramienta ha de ser adaptable a los nuevos tipos de datos futuros.

- **Volumen:** El volumen de los datos está en continuo crecimiento. Hay que asegurarse de que el hardware y los sistemas encargados de esta tarea son fácilmente escalables para manejar grandes volúmenes de datos en distintas plataformas, y que disponen de espacio libre para futuras expansiones.

- **Velocidad**: Los datos en tiempo real son vitales en proyectos de Big Data (mantenimiento predictivo, detección de fraude...).

- **Veracidad:** El mayor impacto positivo que se puede hacer durante el proceso de integración de los datos es el de asegurar la calidad del dato. La falta de precisión del dato lleva al usuario a cuestionar cualquier resultado proporcionado por el sistema.

- **Valor:** Estudia lo que aportan esos datos en términos de coste y beneficios. Hay que asegurarse de que añadan valor y que son algo más que un coste extra.

Fig.3. Plataformas de integración Big Data.

¡! Sabías que...

Según José María Álvarez Pallete, presidente ejecutivo de Telefónica, "los recursos más valiosos en el futuro serán los datos". Según Telefónica, el volumen de datos en los próximos años se multiplicará por once.

2.1. Técnicas de integración de datos

La técnica elegida para la integración de datos depende de las especificaciones del negocio, así como de los requisitos tecnológicos y de las restricciones presupuestarias.

Existen diferentes técnicas:

- **Push**: Consisten en actualizaciones continuas y en línea del entorno de destino mediante aplicaciones de integración de datos, que capturan los cambios en la fuente de origen y los transmiten a destino para su almacenamiento.

- **Pull**: Proporciona los datos mediante procesos por lotes o *batch* en intervalos previamente fijados.

- **Propagación de datos**: Los datos se distribuyen de una fuente X a una fuente Y, permitiendo que la información en ambas esté sincronizada. Como punto positivo, comentar que puede usarse en tiempo real o casi real.

- **Change Data Capture (CDC)**: Permite identificar los datos que han sido modificados; los captura y envía dichas variaciones a las fuentes de datos. Las cuatro técnicas principales de CDC son:

  » Por aplicación.

  » Por *timestamp*.

  » Por *triggers*.

  » Por captura de log.

- **Consolidación de datos**: Consiste en guardar en un repositorio central único los datos provenientes de distintas fuentes. Su aplicación tiene como inconveniente la aparición de un retraso, o latencia.

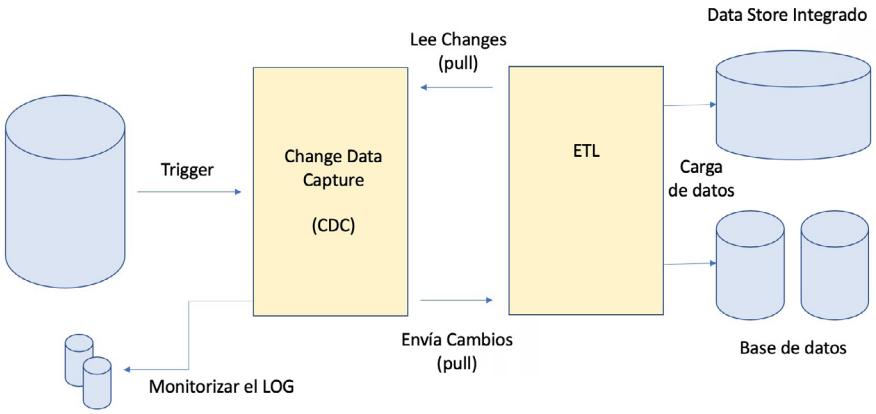

Fig.4. Solución CDC junto ETL.

- **Federación de datos**: A partir de los datos extraídos de diferentes fuentes de datos, proporciona una única imagen virtual. El uso de esta técnica asegura que la información siempre esté actualizada debido a la integración en tiempo real que se lleva a cabo. Por el contrario, no es posible recuperar cantidades de datos grandes ni realizar transformaciones importantes a estos. Por ello, se recomienda usarlos con cautela y solo cuando se necesiten pequeños volúmenes de información.

- **Técnicas híbridas**: Emplea varias técnicas de integración para constituirla.

2.2. Metodologías de integración

En base a las técnicas presentadas, existen las siguientes tecnologías:

- **ETL:** Dentro de las tecnologías de integración, es de las más populares. ETL es el acrónimo de Extraer, Transformar y Cargar. Esta tecnología se encarga de extraer información de las fuentes y pasarla por una serie de procesos de transformación para, finalmente, cargarlos en un repositorio central o data warehouse.

Audio 1. "Fases del proceso ETL"
https://bit.ly/3ecnEpI

- **EII:** Viene del inglés, Integración de Información Empresarial. A partir de la información de distintas fuentes de datos que está dispersa se genera una vista virtual. Esta tecnología pone a etapa intermedia de servicios de datos, que realizan consultas a los diferentes sistemas de información.

- **EDR**: Son las siglas en inglés de Replicación de Datos Empresariales. Distribuye los datos para que la información en dos fuentes esté sincronizada y, con frecuencia, aplica CDC para replicar solo los datos modificados en origen.

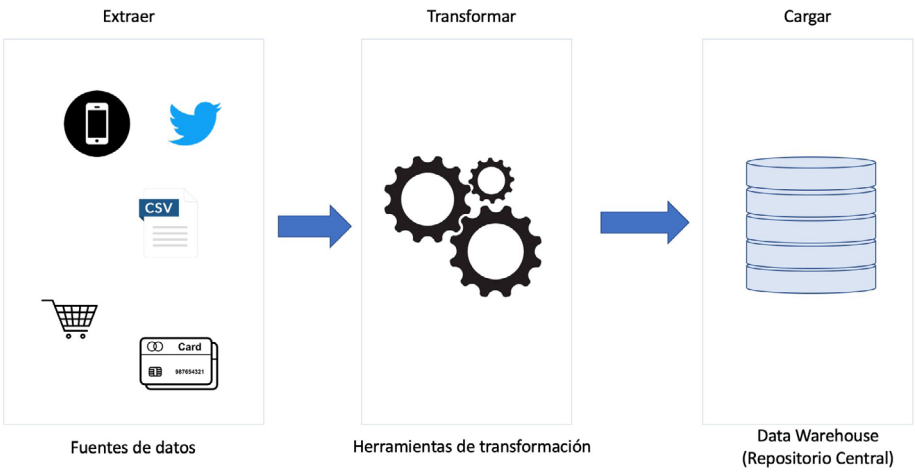

Fig.5. Extracción, transformación y carga de datos (ETL).

¡! Sabías que...

Se estima que el 80 % del trabajo con datos está relacionado con la preparación de los mismos y no con su análisis. En los 90 y principios del año 2000, esa cifra estaba en torno al 70 %.

Vídeo 1. "Procesos de integración ETL"
https://bit.ly/3qDjOvs

MEDAC

/ 3. Caso práctico 1: "Perritos calientes"

Planteamiento: La empresa See Food Technologies, Inc. (SFI) tiene un producto que consiste en una aplicación móvil donde los usuarios pueden hacer fotos de distintos elementos e identificar si estos son o no un perrito caliente. Para desarrollar su negocio, SFI se alimenta de diferentes fuentes de datos:

- Anuncios de Facebook y Google para captar nuevos usuarios.
- Google Analytics para monitorizar eventos en su página web y en la app móvil.
- Base de datos MySQL para almacenar información de los usuarios y metadatos de las fotos.
- Marketo para enviar e-mails de marketing y nutrir a los líderes.
- Zendesk para dar soporte a los usuarios.
- Netsuite para llevar la contabilidad y la monitorización financiera de la empresa.

Nudo: Cada una de estas aplicaciones llevan asociadas unas cantidades de datos inmensas relacionadas con el funcionamiento de la empresa SFI. Para que Seafood Technologies Inc. consiga una visión de 360° del negocio, es necesario que todos estos datos se combinen en un solo lugar. A ese proceso es lo que denominamos integración de los datos en entornos Big Data. ¿Qué consideraciones crees que habría que tener en cuenta antes de elegir un proyecto de integración?

Desenlace: Antes de lanzar cualquier proyecto de integración, es fundamental tener claro el retorno de la inversión del mismo (ROI, *return of investment*). Cuando se lleve a cabo en la vida real, el retorno de la inversión sufrirá cambios respecto a la estimación, pero, al menos, la persona que tiene que tomar la decisión puede hacerse una idea del valor que la integración de datos proporciona.

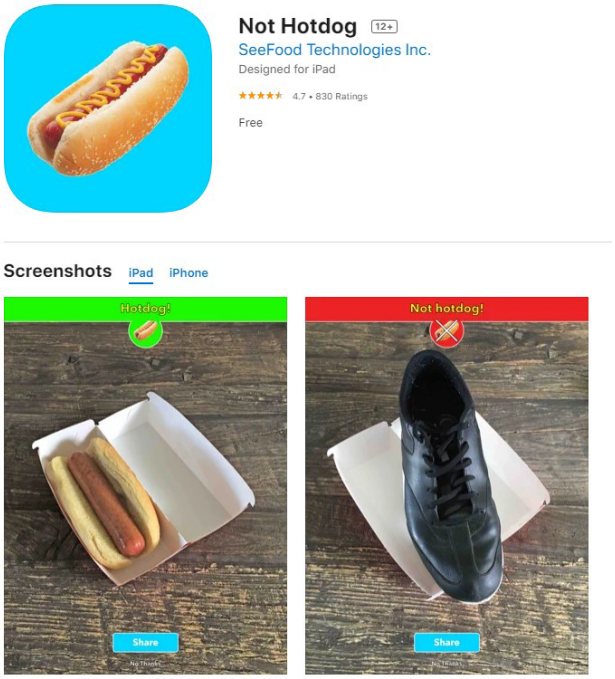

Fig.6. Producto de la empresa SeaFood Technologies, Inc.

¡! Sabías que...

El Big Data tiene muchas cosas buenas que ofrecer, pero no debemos caer en la trampa de 'hacer lo mismo que hacen los demás' simplemente porque es tendencia. Asegúrate de que la implantación de estas nuevas tecnologías reportará beneficios tangibles.

/ 4. Procesamiento y análisis en Big Data

Escucha el siguiente audio que nos dará una visión general de en qué consiste el procesamiento, y pasaremos a detallar aspectos relacionados con el análisis.

Audio 2. "Procesamiento Big Data"
https://bit.ly/3GWeKZC

4.1. Análisis descriptivo

La analítica descriptiva consiste en almacenar y realizar agregaciones de datos históricos, visualizándolos de forma que puedan ayudar a la compresión del estado actual, o pasado, de cualquier temática a través de múltiples utilidades. Los principales usos de los análisis descriptivos con Big Data son, entre otros: detectar, visualizar, observar, identificar, calcular, averiguar, etc.

4.2. Análisis predictivo

La analítica predictiva proporciona herramientas para estimar aquellos datos desconocidos o inciertos, o que requieren de un proceso manual o costoso para su obtención. El análisis predictivo permite anticipar, detectar o describir grupos afines. Las predicciones se hacen en base a probabilidades.

4.3. Análisis prescriptivo

Mediante la analítica prescriptiva no solo se perciben varios futuros escenarios, sino que se proporcionan recomendaciones sobre las acciones que se han de seguir para mejorar esos escenarios.

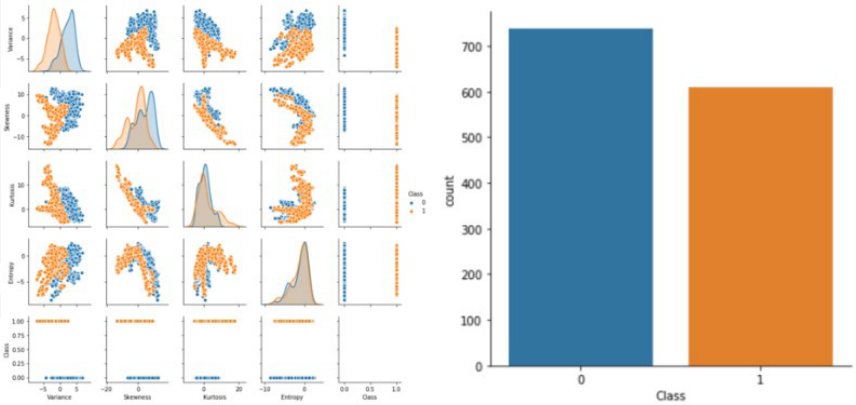

Fig.7. Ejemplo de análisis descriptivo en Python.

```python
# El pipeline seguirá la siguiente secuencia: estandarización y KNeighborsClassifier
# Consideraremos el numero de vecimos a contemplar como hiperparámetro (n_neighbors)
# Cross Validation con 10 elementos

from sklearn.neighbors import KNeighborsClassifier

pipeline_vecinos = Pipeline([('estandar', StandardScaler()),
                             ('vecinos', KNeighborsClassifier())])

grid_hyper_vecinos = {'vecinos__n_neighbors': np.arange(1,50,2),
                      'vecinos__metric':['euclidean', 'manhattan', 'chebyshev', 'minkowski']}

gs_vecinos = GridSearchCV(pipeline_vecinos,
                          param_grid=grid_hyper_vecinos,
                          cv=10,
                          scoring='roc_auc',
                          verbose=3)

gs_vecinos.fit(train_y_validacion[names_features], train_y_validacion['Class'])
```

	Variance	Skewness	Kurtosis	Entropy	Class	predicciones_MLP
296	0.051979	7.052100	-2.05410	-3.15080	0	0
835	-0.942550	0.039307	-0.24192	0.31593	1	1
833	-2.826700	-9.040700	9.06940	-0.98233	1	1
841	-3.885800	-12.846100	12.79570	-3.13530	1	1
1098	-1.804600	-6.814100	6.70190	1.16810	1	1

Fig.8. Modelo de Machine Learning con Python Scikit Learn.

Continuación de las imagenes en el punto anterior.

```python
# Seleccionamos nuestra película favorita para determinar las recomendaciones con respecto a esta

pelicula = cos_sim_df.loc["Harry Potter and the Goblet of Fire"]
```

```python
# Ordenamos los valores de mayor similitud a menor

similitud_ordenada = pelicula.sort_values(ascending = False)
similitud_ordenada.head(10)
```

```
Titulo
Harry Potter and the Goblet of Fire              1.000000
Harry Potter and the Deathly Hallows: Part 2     0.600590
Harry Potter and the Deathly Hallows: Part II    0.600590
Harry Potter and the Order of the Phoenix        0.600310
Harry Potter and the Half-Blood Prince           0.568929
Harry Potter and the Philosopher's Stone         0.525247
Harry Potter and the Sorcerer's Stone            0.525247
Harry Potter and the Deathly Hallows: Part I     0.470658
Harry Potter and the Deathly Hallows: Part 1     0.470658
Harry Potter and the Chamber of Secrets          0.346600
Name: Harry Potter and the Goblet of Fire, dtype: float64
```

Fig.9. Motor de recomendación de películas con Python.

/ 5. Caso práctico 2: "Rolls-Royce"

Planteamiento: Rolls-Royce es un gigante en el sector de fabricación de motores. Estos son usados por más de 500 aerolíneas y más de 150 fuerzas armadas. Sus motores generan grandes cantidades de potencia, por lo que no sorprende que una empresa que trabaja con grandes números en todos los ámbitos haya adaptado metodologías Big Data. Es una empresa tecnológica de alto nivel donde un fallo o error puede costar muchos millones, y lo que es peor, vidas humanas.

Nudo: ¿Dónde crees que aplican Big Data Analytics?

Desenlace: Aplican Big Data en tres ámbitos:

1. Diseño.
2. Fabricación.
3. Soporte posventa.

En la etapa de diseño, emplean un enorme clúster de alto nivel computacional, pues durante el modelado de los motores, generan muchos TB de datos. Después, aplican técnicas avanzadas para analizar estos datos y determinar si el diseño es bueno o malo.

Desde fabricación, monitorizan sus procesos para asegurar el perfecto funcionamiento del sistema de control de calidad. Para ello, están aplicando metodologías orientadas al *Internet of Things* (IoT).

Sus productos están provistos de un gran número de sensores que registran cada pequeño detalle de la operación en tiempo real y que transmiten a los ingenieros, los cuales deciden qué acción es más adecuada en cada caso. Rolls-Royce tiene *Operational Service Centers* por todo el mundo para analizar los *feedbacks* de datos que reciben de sus productos. Con esa información, determinan qué clientes necesitan mantenimiento. En algunos casos, ciertas personas tienen que participar en la solución de problema, aunque están trabajando para que la mayoría de las intervenciones las realicen los ordenadores.

La implementación de Big Data Analytics en su día a día los ha llevado a mejorar el proceso de diseño, minimizar el tiempo de desarrollo y mejorar la calidad y puesta en servicio de sus productos.

El uso de algoritmos predictivos para detectar fallos, que se corrigen y previenen su nueva aparición, ha reducido los costes significativamente.

La utilización de estas herramientas ha abierto un nuevo campo de negocio llamado Total Care. Este permite al cliente reducir los intervalos de mantenimiento (minimizando costes a su vez, ya que las paradas están planificadas y no implican detención de los activos) y maximizando la potencia de vuelo de los motores (al reducir el número de fallos).

/ 6. Resumen y resolución al caso práctico de la unidad

En esta unidad, hemos estudiado tres procesos fundamentales en un proyecto de Big Data: integración de datos, procesamiento de datos y análisis de datos.

Destacamos las ideas principales descritas a lo largo del tema:

- Los datos provienen de fuentes diversas y, por ello, son necesarias herramientas de integración que los almacenen en un repositorio, generando una visión de 360° de los mismos.
- El Big Data necesita de sistemas de procesamiento distribuido, operando en múltiples clústeres para paralelizar las tareas y que la computación sea más rápida.
- Los datos tienen un valor incalculable oculto. Hay que 'masajearlos', para lo que existen distintos tipos de análisis en función del objetivo a conseguir (sacar información, predecir, clasificar, agrupar, recomendar, etc.).

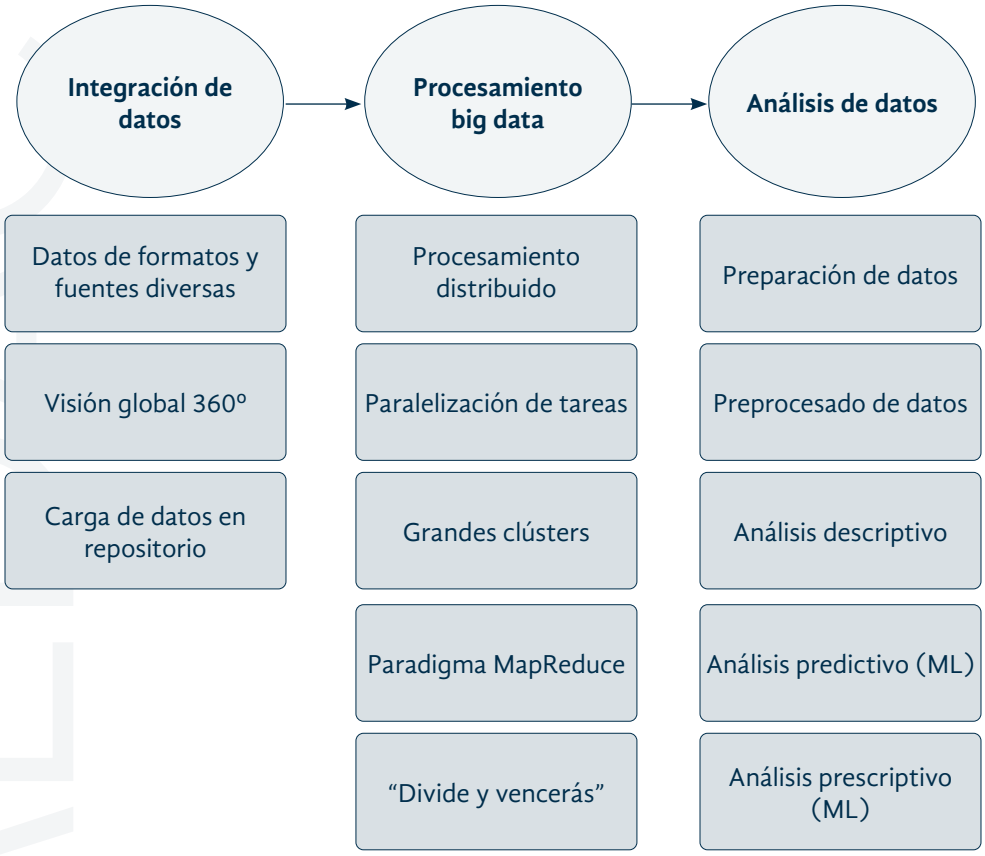

Fig.10. Esquema de la unidad.

Vídeo 2. "Grupos de procesos en Big Data"

https://bit.ly/3FXaide

Resolución caso práctico inicial

Se recomiendan los siguientes pasos a seguir:

- Recopilar datos de distintas fuentes. Para ello, se propone el uso de técnicas de *Web Scrapping* (técnicas capaces de descargar datos de forma masiva simulando las acciones de un humano). Se obtendrán datos meteorológicos, niveles de decisión para el aterrizaje de cartas aeronáuticas, listas de operadores que trabajan en Europa, aeródromos europeos, histórico del número de aterrizajes por año de cada operador, etc. Posteriormente, aplicar una de las tecnologías de integración descritas en la unidad y almacenar en repositorio central.

- Para gestionar el Big Data frente a esta cantidad de datos masivos, el sistema Big Data tendrá sistemas distribuidos para la ejecución de aplicaciones y el acceso paralelo a los datos: utilización de *MapReduce* para repartir el procesamiento, pasando de tener una tarea de gran volumen a tener muchas tareas más pequeñas paralelizadas.

- Análisis de los datos haciendo *feature engineering* Calcular probabilidades de aterrizaje con sistemas de precisión y no precisión en base a la meteorología. Hacer cálculos para completar un análisis coste-beneficio para el operador en cuestión. Se propone usar Python para el análisis descriptivo y los algoritmos de procesado avanzado.

- Los datos de salida son complejos para alguien que no ha masajeado los datos, por lo que se visualizarán en Power BI.

/ 7. Bibliografía

Josep Curto Díaz. *Introducción al Business Intelligence.* UOC.

Carlos Maté Jiménez. *Big data. Un nuevo paradigma de análisis de datos. Anales de mecánica y electricidad* (nov-dic 2014).

David Villaseca Morales. *De Silicon Valley a tu negocio: Innovación, data e inteligencia artificial*. ESIC.

Alberto de Vega Luna. *Historias de developers,*

Enrique Martín y Rafael Caballero. *Las Bases de Big Data.* Catarata (Universidad Complutense Madrid).

Javier de la Torre. *Nuevas tecnologías y su impacto en la sanidad del siglo XXI.* Universidad de Comillas.

Carlos Merlo. *Data Science Electoral.* Anderson.

MEDAC