MEDAC
Instituto Oficial de Formación Profesional

SISTEMAS DE BIG DATA

Matemática aplicada al análisis de datos

2

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. Conceptos de probabilidad y estadística 4

2.1. Medidas estadísticas 4

/ 3. Caso Práctico 1: "Ejemplo de modelo lineal" 5

/ 4. Conceptos de álgebra 7

4.1. Transformaciones lineales 8

4.2. Determinantes y ecuaciones matriciales 8

4.3. Descomposición de matrices 9

/ 5. Caso Práctico 2: "Principal Component Analysis (PCA)" 10

/ 6. Resumen y resolución del caso práctico de la unidad 11

/ 7. Bibliografía 12

© MEDAC
Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Manejar con soltura los conceptos de matemática discreta.

Relacionarlos con aplicaciones Big Data.

/ 1. Introducción y contextualización práctica

Es importante recordar los distintos **tipos de números** que se pueden presentar en las operaciones matemáticas: *i*) naturales (0, 1, 2); *ii*) enteros (-2, 0, 1); *iii*) racionales (687/100); *iv*) irracionales (p), *v*) reales (el conjunto de los irracionales más los racionales); *vi*) complejos (1 + 2i, no se suelen usar en ciencia de datos)...

No debemos olvidar que las operaciones se realizan en un **orden** y siguiendo estas reglas: *i*) resolución de paréntesis; *ii*) realización de multiplicaciones y divisiones; *iii*) cálculo de sumas y restas.

Por otra parte, recordar que las **funciones** establecen relaciones entre dos o más variables. Estas se pueden representar en el plano 2D (y=x lineal; $y=x^2$ cuadrática) o en el espacio 3D (f(x,y) = x + y). Las **derivadas** permiten determinar la pendiente de la recta tangente a una curva en un punto. Esto es muy útil para cuantificar los cambios en funciones. Las **integrales** se usan principalmente para determinar el área bajo las funciones de probabilidad.

A continuación, vamos a plantear el caso práctico del tema. Escucha el siguiente audio con el planteamiento del problema y revisa la solución en el apartado 'Resumen del tema y solución al caso práctico'.

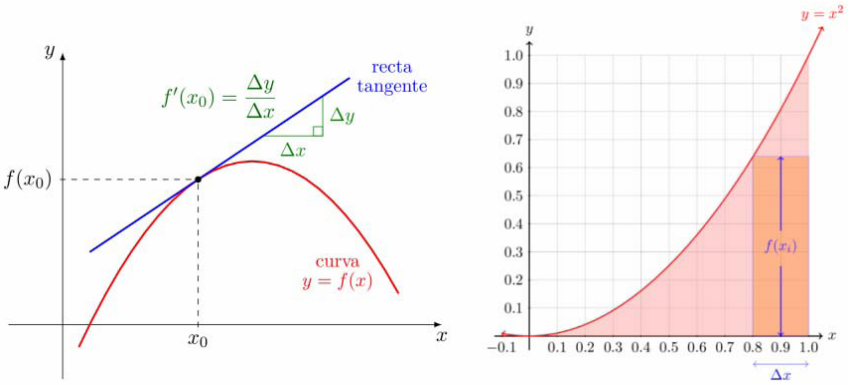

Fig.1. Aplicación de la derivada y la integral.

Audio intro. "Uso del cálculo integral"
https://bit.ly/3H3ViKF

/ 2. Conceptos de probabilidad y estadística

En este punto se introducirán los conceptos estadísticos fundamentales que todo profesional que trabaje con datos debe conocer para realizar análisis descriptivos de conjuntos de datos.

El cálculo de probabilidad determina básicamente cómo de probable es que ocurra un evento. P(X) es la probabilidad de que ocurra un suceso X y su valor varía entre 0 (muy improbable) y 1 (muy probable).

La **probabilidad conjunta** es la probabilidad de que dos sucesos A y B ocurran de forma conjunta. Para sucesos independientes:

$$P(A \text{ y } B) = P(A \cap B) = P(A) \cdot P(B)$$

La **probabilidad de la unión** es la probabilidad de que ocurra el suceso A o el suceso B. Si A y B son incompatibles P(A Ç B) = 0.

$$P(A \text{ o } B) = P(A) + P(B) - P(A \cap B)$$

La **probabilidad condicionada** es la probabilidad de que ocurra el suceso A cuando se da un suceso B.

$$P(A|B) = P(A \cap B) / P(B)$$

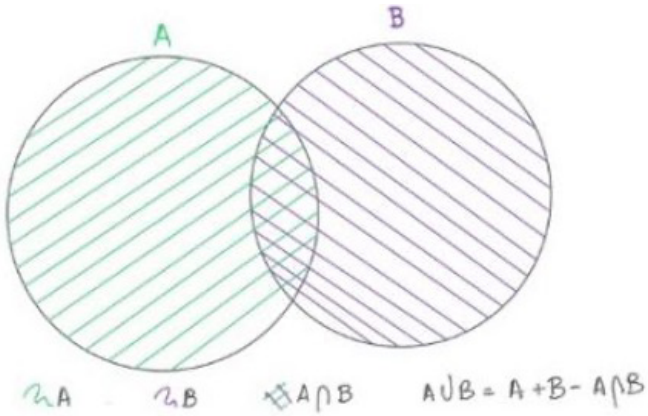

Fig.2. Diagrama de sucesos (probabilidad).

En estadística se habla de estadística descriptiva cuando se pretende resumir los datos e inferenciar (deducir) atributos de una población grande a partir de una muestra.

2.1. Medidas estadísticas

Escucha el siguiente audio de introducción al epígrafe:

Audio 1. "Medidas estadísticas"
https://bit.ly/3pcoDfC

MEDAC

Tal y como hemos adelantado en el audio, los estadísticos de tendencia central que expondremos serán:

Media: Valor medio del conjunto de valores.

$$\bar{X} = \frac{\Sigma_{i=1}^{n} x}{N}$$

Mediana: Valor de la posición central con el conjunto ordenado. Dependiendo de si el número de valores N es par o impar:

$$\text{par} \longrightarrow Me = x_{(n+1)/2}$$

$$\text{impar} \longrightarrow Me = (x_{n/2} + x_{n/2+1})/2$$

Moda: Es el valor que más se repite.

Cuartiles: Son Q1 (el 25% de los datos), Q2 (50% datos), Q3 (75% datos).

Rango intercuartílico: Q3 – Q1.

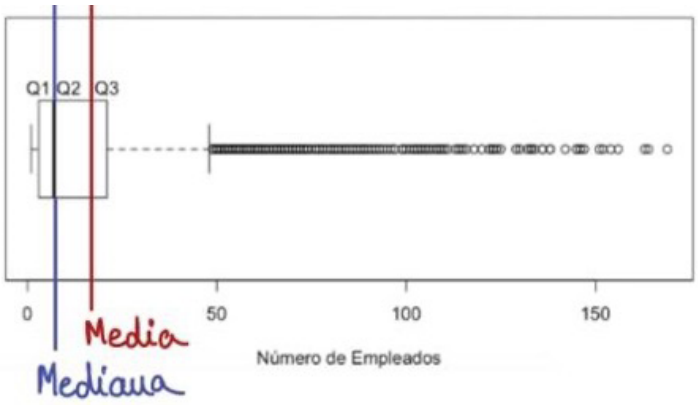

Fig.3. Diagrama de caja.

/ 3. Caso Práctico 1: "Ejemplo de modelo lineal"

Planteamiento: Se tiene un conjunto de datos relativo a ventas de dispositivos móviles y electrónicos de una franquicia en España, para el cual se quiere generar un modelo lineal sencillo. Se necesita determinar el par de variables con la fortaleza relativa más alta del conjunto. ¿Cómo resolver el problema a través de la estadística?

Nudo: El coeficiente de correlación mide la dependencia lineal entre dos variables. Los valores del coeficiente de correlación oscilan entre -1 y 1:

- Correlación 1: Correlación positiva máxima (cuando aumenta una variable, la otra también aumenta).
- Correlación 0: No hay correlación entre las dos variables.
- Correlación -1: Correlación negativa máxima (cuando aumenta una variable, disminuye la otra).

Desenlace: Herramientas como Python o R pueden proporcionarnos, de una forma sencilla y gráfica, esta información.

En este caso el gráfico se ha generado con R para la matriz de correlación *mat_cor* en forma de matriz de calor.

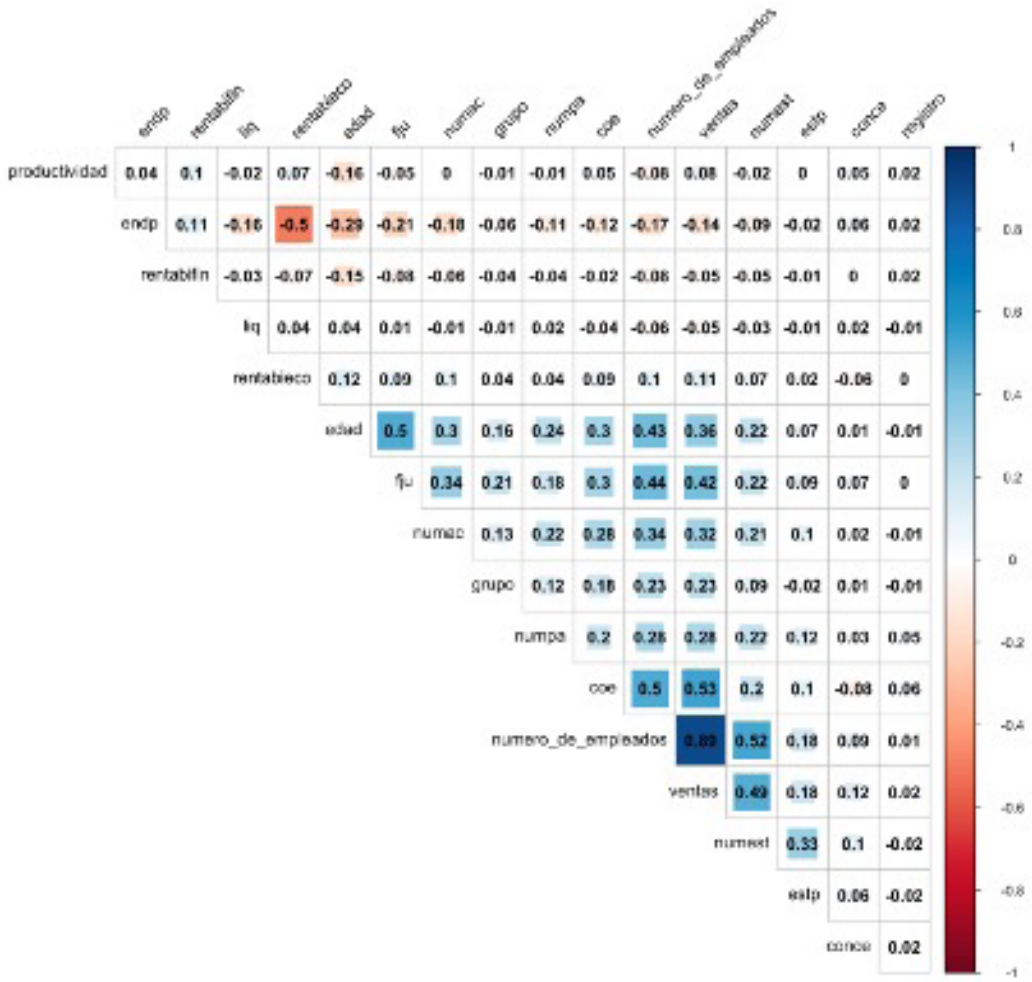

Fig.4. Matriz de correlación con R.

Enlaces de interés...

Esta píldora (Introduction to Mathematical Thinking) ayuda a desarrollar el pensamiento matemático para resolver problemas del mundo real. La inscripción es gratuita:
https://www.coursera.org/learn/mathematical-thinking#

/ 4. Conceptos de álgebra

Comencemos por uno de los elementos fundamentales: los vectores.

Un **vector** es una herramienta matemática que se utiliza para representar valores con dirección y magnitud. Piensa en él como una flecha: tiene un tamaño (la magnitud) y apunta hacia algún lugar (la dirección). En el mundo del Big Data, los vectores se usan para organizar datos, ya que cada componente del vector puede representar un valor, como una característica o variable.

Ejemplo sencillo: Imagina que un vector describe las notas de un estudiante en tres asignaturas:

v = (8, 7, 9). Aquí, cada número es una calificación, y juntos forman un "paquete" de datos. En análisis de datos, los vectores son fundamentales para trabajar con puntos en un espacio multidimensional, como representar a los usuarios o productos en un modelo de recomendación).

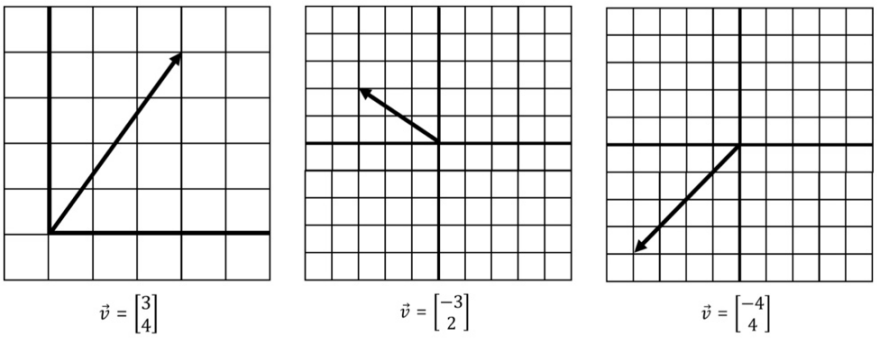

Fig.5. Vector en el plano 2D.

Una de las operaciones básicas con vectores es la **suma**. Se suman sus valores componente a componente:

$$\vec{v}+\vec{w}=\begin{bmatrix} 3 \\ 4 \end{bmatrix}+\begin{bmatrix} 2 \\ 3 \end{bmatrix}+\begin{bmatrix} 5 \\ 7 \end{bmatrix}$$

Otra operación importante es el escalado (alargar o acortar vectores), representado por la siguiente fórmula:

$$\vec{t}=\begin{bmatrix} 3 \\ 1 \end{bmatrix};\ 2\vec{v}=\begin{bmatrix} 6 \\ 2 \end{bmatrix}$$

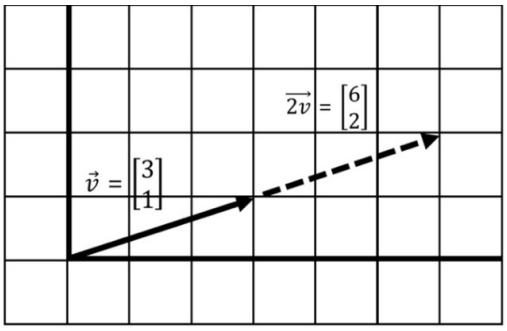

Fig.6. Escalado de vectores.

4.1. Transformaciones lineales

Un vector puede sufrir transformaciones lineales a través de una matriz: escalado, rotación, inversión, etc.

La multiplicación de una matriz por un vector se lleva a cabo de la siguiente forma:

$$\begin{bmatrix} x_{\text{transformado}} \\ y_{\text{transformado}} \end{bmatrix} = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} ax + by \\ cx + dy \end{pmatrix}$$

La multiplicación de matrices se realiza de esta otra forma:

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} e & f \\ g & h \end{bmatrix} = \begin{bmatrix} a \cdot e + b \cdot g \cdot & a \cdot f + b \cdot h \\ c \cdot e + d \cdot g \cdot & c \cdot f + d \cdot h \end{bmatrix}$$

Vídeo 1. "Multiplicar matrices"
https://bit.ly/3pKquIV

4.2. Determinantes y ecuaciones matriciales

El determinante o volumen orientado es una herramienta muy útil para clasificar sistemas de ecuaciones y resolver problemas que implican trabajar con matrices. Para una matriz de 2x2 se resuelve de la siguiente manera:

$$\det(A_{2x2}) = \begin{vmatrix} a & b \\ c & d \end{vmatrix} = a \cdot d - b \cdot c$$

En el caso de matrices 3x3 se aplica la *regla de Sarrus*:

$$|A| = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = (a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32}) - (a_{31}a_{22}a_{13} + a_{32}a_{23}a_{11} + a_{33}a_{21}a_{12})$$

Fig.7. Regla de Sarrus para cálculo de determinantes (3x3).

En Python, con la ayuda de la librería *Numpy*, se puede calcular en tan solo 4 líneas de código:

```
import numpy as np
```

```
fila1 = np.array([1, 3])
```

```
fila2 = np.array([1, 1])
```

```
matriz = np.array([fila1, fila2])
```

```
determinante = det(matriz)
```

```
print('El determinante de la matriz es ', str(determinante))
```

```
El determinante de la matriz es  -2.0
```

Fig.8. Cálculo de determinantes con Python Numpy.

Para resolver una ecuación con matrices es necesario emplear el concepto de **inversa**. A continuación se muestra cómo despejar una ecuación matricial usando este concepto. Recuerda que la multiplicación de una matriz por su inversa es la matriz identidad (diagonal de unos).

$$A \cdot X = B \longrightarrow A^{-1} \cdot A \cdot X = A^{-1} \cdot B \longrightarrow X = A^{-1} \cdot B$$

La inversa de una matriz con *Numpy* se calcula de la siguiente forma:

```
import numpy as np
from numpy.linalg import inv
```

```
fila1_A = np.array([2, 1])
```

```
fila2_A = np.array([-1, 2])
```

```
matriz_A = np.matrix([fila1_A, fila2_A])
matriz_A
```

```
matrix([[ 2,  1],
        [-1,  2]])
```

```
inversa_A = inv(matriz_A)
inversa_A
```

```
matrix([[ 0.4, -0.2],
        [ 0.2,  0.4]])
```

Fig.9. Matriz inversa de A

La solución a la ecuación resulta de multiplicar la inversa de A por B.

```
matriz_B = np.matrix([[1],[-2]])
```

```
# Solución X
inversa_A * matriz_B
```

```
matrix([[ 0.8],
        [-0.6]])
```

Fig.10. Valor de X solución ecuación matricial.

Enlaces de interés...

Amplía tus conocimientos sobre el tema investigando. Pero si necesitas reforzar tus conocimientos de álgebra, puedes practicar aquí: https://www.khanacademy.org/math/algebra

4.3. Descomposición de matrices

La descomposición de matrices consiste en reducir una matriz a sus componentes básicos, tal y como se hace con un polinomio cuando se factoriza.

Hay muchas formas de descomponer una matriz, pero el método más usado en *Machine Learning* es el de **autovalores y autovectores.** Hay un autovalor y un autovector asociado a cada dimensión de la matriz, pero no siempre las matrices pueden ser descompuestas en sus autovalores y autovectores.

Los autovalores se consiguen obteniendo las raíces del polinomio (donde *I* es la matriz identidad):

$$\det(A-\lambda I) = 0$$

Si para cada una de las raíces obtenidas en el paso anterior resolvemos el siguiente sistema de ecuaciones, obtendremos los autovectores:

$$(A-\lambda I)\, v = 0$$

A continuación vemos cómo se calcularían en Python:

```python
# Matriz a descomponer

A = array([
    [1, 2],
    [4, 5]
])

#Cálculo de autovalores y autovectores
autovalores, autovectores = eig(A)

print('AUTOVALORES:')
print(autovalores)
print('\nAUTOVECTORES:')
print(autovectores)
```

```
AUTOVALORES:
[-0.46410162  6.46410162]

AUTOVECTORES:
[[-0.80689822 -0.34372377]
 [ 0.59069049 -0.9390708 ]]
```

Fig.11. Cálculo de autovalores y autovectores en Python.

/ 5. Caso Práctico 2: "Principal Component Analysis (PCA)"

Planteamiento: A menudo solemos pensar que cuantos más datos, mejor. Esto es cierto en cuanto a observaciones (filas) se refiere, pero no en cuanto a columnas o características de los mismos. Por ejemplo, siempre se intentará evitar introducir en el modelo dos variables que estén midiendo el mismo fenómeno, para no contabilizarlas por partida doble.

Nudo: PCA es uno de los métodos más útiles del álgebra lineal. Es una metodología no paramétrica para extraer información significativa de *datasets* complicados. El uso del PCA hace que no se tengan que estructurar los datos antes de facilitárselos al modelo, ya que PCA realizará esa tarea por nosotros.

PCA es capaz de identificar los componentes principales de los datos, que son las direcciones en las que las observaciones presentan mayores varianzas.

Este análisis se suele llevar a cabo en dos pasos:

- **Descorrelación**: No cambia las dimensiones originales de los datos.
- **Reducción de dimensionalidad**: Representa los mismos datos usando menos características.

Desenlace: Mediante esta técnica de análisis se convierte un *dataset* de variables, posiblemente correladas, a un conjunto de variables linealmente no correladas llamadas **componentes principales**. El número de componentes principales siempre será menor o igual que el número de variables original. Esta transformación hace que la primera componente principal sea la que tiene la mayor varianza posible.

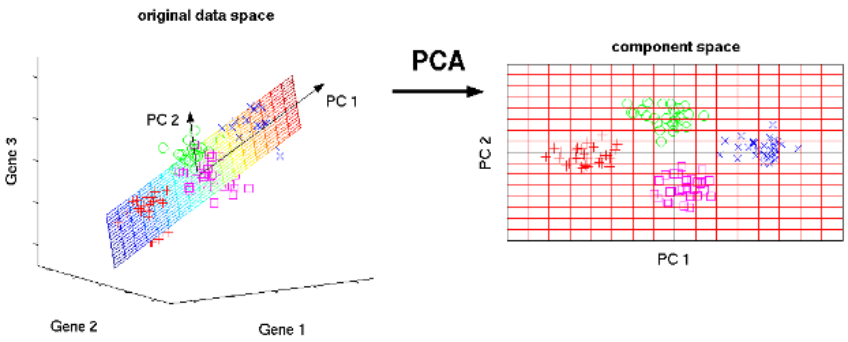

Fig.12. PCA gráficamente.

/ 6. Resumen y resolución del caso práctico de la unidad

En esta unidad se ha dado una visión general de los conceptos y herramientas fundamentales, desde el punto de vista matemático y estadístico, para llevar a cabo análisis de grandes volúmenes de datos.

A continuación se muestran algunos ejemplos de la relación entre los conceptos estudiados y las técnicas de análisis avanzadas que usaremos para el análisis de Big Data:

DERIVADAS	→	Gradiente descendiente – Aprendizaje Automático
INTEGRALES	→	Área Bajo la Curva como (ROC AUC) como métrica de la precisión de modelos de aprendizaje automático
PROBABILIDAD	→	Probabilidad condicionada y Teorema de Bayes para Machine Learning de Aprendizaje automático
AUTOVALORES Y AUTOVECTORES	→	PCA para reducción de dimensionalidad en proyectos de Machine Learning

Fig.13. Esquema resumen del tema.

Resolución al caso práctico inicial

Una métrica relacionada con el cálculo integral es **ROC AUC** (área bajo la curva ROC).

Esta métrica permite hacer un *ranking* de los mejores modelos de clasificación para un problema concreto.

El modelo óptimo es aquel que maximiza el área bajo la curva. La línea roja sería un modelo que proporciona una clasificación aleatoria, mientras que la morada representaría un modelo de clasificación perfecto.

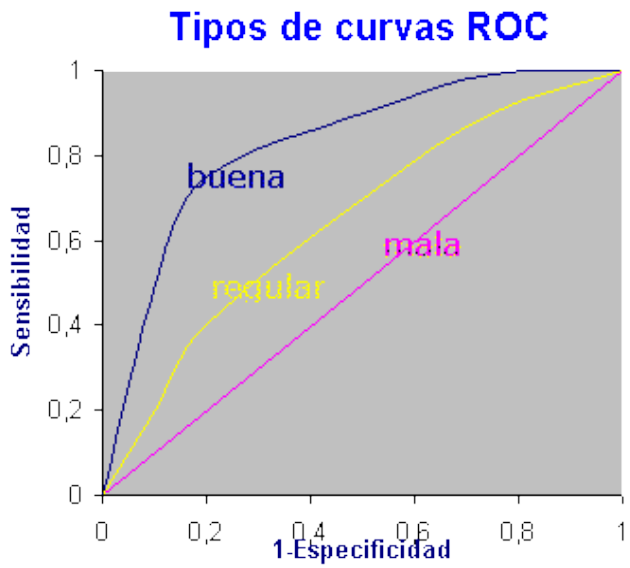

Fig.14. Aplicación del cálculo integral en ML.

/ 7. Bibliografía

Essential Math for Data Science: Take control of your data. Thomas Nield; O'Reilly Media.

Probability and Statistics for Data Science: Math + R + data. Norman S. Matloff; CRC Press.

Statistics for data Science. Deborah Oliver; Stephano de Giorgi Editors.

Math for programmers: 3D graphics, machine learning and simulations with Python. Paul Orland; Simon and Schuster Editors.

Statistical Learning with Math and Python: 100 Exercises for Building Logic. Joe Suzuki; Springer.

MEDIAC