MEDAC
Instituto Oficial de Formación Profesional

SISTEMAS DE BIG DATA

Procesos batch y procesos en tiempo real

3

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. Principales diferencias entre los procesos batch y streaming 4

/ 3. Casos de aplicación 4

3.1. Casos de aplicación de procesos streaming 4

3.2. Casos de aplicación de procesos batch 5

/ 4. Herramientas para el desarrollo específico de proyectos basados en procesos batch y streaming 6

4.1. Herramientas aportadas por plataformas cloud 7

/ 5. Caso práctico 1: “Proyecto de sensorización: batch o streaming” 8

/ 6. Caso práctico 2: “Evaluación de negocio: batch o streaming” 8

/ 7. Resumen y resolución del caso práctico de la unidad 9

/ 8. Bibliografía 9

© MEDAC
Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Conocer las principales características que definen la diferencia entre los procesos batch y en tiempo real.

Casos de uso y herramientas Big Data para la recolección, procesamiento y análisis de datos en ambos procesos.

/ 1. Introducción y contextualización práctica

El procesamiento y los procesos asociados a estos son unas de las principales temáticas en las que se centran los más importantes analistas expertos en tecnologías Big Data.

En este tema, vamos a hablar de **los dos principales tipos de procesamiento:** el procesamiento en **streaming, o en tiempo real,** y el procesamiento **batch.**

En concreto, vamos a explorar las principales aplicaciones y ejemplos asociados a cada uno, las características que diferencian ambos tipos de procesamiento y los aspectos fundamentales que determinan cuándo emplear uno u otro.

A continuación, vamos a plantear un caso práctico a través del cual podremos aproximarnos de forma práctica a la teoría de este tema.

Escucha el siguiente audio donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

Fig.1. Procesamiento batch y streaming.

Audio intro. "Aspectos a tener en cuenta para identificar el tipo de proceso"

https://bit.ly/3Ffih4Z

/ 2. Principales diferencias entre los procesos batch y streaming

Los procesos Big Data se basan en la **extracción de fuentes de grandes volúmenes de datos** procedentes, a su vez, de múltiples fuentes de información, **el almacenamiento de los datos** de las mismas, y su posterior **análisis y modelado** para dar respuesta a diversos casos empresariales de uso.

En concreto, en Big Data, se diferencian dos formas principales de procesar datos**: el procesamiento en streaming, o en tiempo real, y el procesamiento batch, o por lotes.**

Fig.2. Ejemplo visual de diferencia entre streaming y batch.

Las características que determinan un proyecto en streaming son las siguientes:

- Necesidad de procesamiento en tiempo real: Es decir, **necesidad de procesar el dato en el mismo momento en el que se recolecta** de la fuente de información de origen.
- **Mucha menor latencia** que en los procesos batch: **Los datos se procesan antes de almacenarse**, permitiendo rendimientos superiores a los procesos de tipo batch.

Por otra parte, las características que determina un proceso batch son las siguientes:

- El procesamiento de datos se realiza en bloques o lotes: No es necesario el análisis en tiempo real, pero sí se **requiere de amplios procesos de agregación de datos**.
- **El procesamiento se hace después del almacenamiento**.
- Posibilidad de configurar el tamaño de los 'bloques' en función de la frecuencia de procesamiento de los datos.

/ 3. Casos de aplicación

Según lo previamente definido, será la propia naturaleza del caso de uso la que determinará el empleo de uno u otro proceso.

3.1. Casos de aplicación de procesos streaming

De acuerdo con lo que hemos visto, los procesos streaming se aplican cuando **se requiere de una baja latencia para el análisis de datos y la presentación de resultados**, ofreciendo los mismos en tiempo real, teniendo como referencia la toma del dato.

Ejemplos:

- Análisis de datos para la **detección de fraude** según el comportamiento del usuario.
- Procesamiento de datos procedentes de sensores para determinar, por ejemplo, **la disponibilidad u ocupación de un patinete de alquiler** en una gran ciudad.
- **Gestión del tráfico (ya sea marítimo, terrestre o aéreo)** como resultado de los datos procedentes de la situación de las diferentes rutas en tiempo real.
- **Análisis y observación de las condiciones meteorológicas y ambientales de una determinada zona**: temperatura, velocidad del viento, presencia de hidrocarburos en el agua, etc.

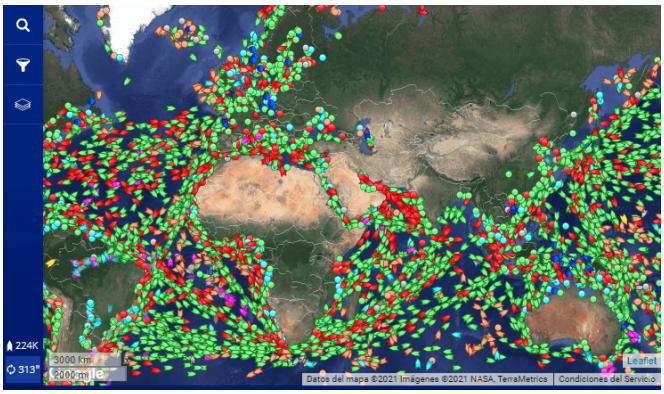

Fig.3. Ejemplo de tráfico marítimo en tiempo real.

3.2. Casos de aplicación de procesos batch

Los procesos streaming plantean **un elevado número de aplicaciones según la necesidad de ofrecer resultados en el mismo momento de la recopilación de datos**. Visto esto, los procesos de tipo batch se emplean en casos que requieren de mayor procesamiento de la información, así como agrupación de datos, gracias a las características que poseen:

- **Representación de datos de movilidad de usuarios de operador**, agrupados y anonimizados con el propósito de cumplir GDPR.

Fig.4. Ejemplo de datos de movilidad procesados en batch.

- **Análisis de datos para identificar correlaciones entre el número de ventas de un determinado producto y las variables analizadas**: fecha de publicación del producto, precio de venta, tipología de clientes, etc.
- **Análisis de datos para determinar el comportamiento de un determinado deportista** en función de una serie de variables.
- **Análisis para determinar el éxito de determinadas campañas turísticas** en función de, por ejemplo, ocupaciones de apartamentos turísticos u hoteles en un determinado periodo de tiempo.

Audio 1. "Exploración de algunos casos de uso"
https://bit.ly/33EJe3T

/ 4. Herramientas para el desarrollo específico de proyectos basados en procesos batch y streaming

Con objeto de dar respuesta a los múltiples casos de uso que requieren de la implantación de procesos de tipo streaming y batch, son **innumerables las herramientas** que algunas de las principales empresas tecnológicas han puesto a disposición de los desarrolladores y de los ingenieros de datos.

A continuación, vamos a conocer algunas de estas herramientas para ambos paradigmas de procesamiento.

A. **Herramientas para el desarrollo de procesos streaming**

En lo referente a las principales tecnologías para el desarrollo de **proyectos basados en procesos streaming,** podemos destacar:

» **Kafka:** Herramienta que puede conectarse a sistemas externos para **construir flujos de datos en tiempo real,** facilitando el despliegue de aplicaciones basadas en microservicios.

» **Apache Spark:** Esta herramienta agrupa los datos en **micro-batches** para llevar a cabo **análisis de baja latencia.** Se publicó en mayo de 2014.

» **Apache Flink:** Plataforma distribuida con alta disponibilidad y escalabilidad. **Puede realizar procesamiento batch y streaming,** aunque su diseño se planteó, en principio, para el procesamiento de eventos en tiempo real. La versión inicial se publicó en mayo del 2011.

Enlaces de interés...

En el siguiente enlace, se encuentra una comparativa de las tecnologías que intervienen en procesos streaming:
https://aprenderbigdata.com/stream-processing/

MEDIO

B. **Herramientas para el desarrollo de procesos batch**

En los inicios de Big Data como concepto, el procesamiento de trabajos batch giraba en torno a Hadoop, en concreto, a **MapReduce.** Actualmente, son más las tecnologías que pueden emplearse para esta tipología de proyectos. Algunas de las más destacadas se nombran a continuación:

» Ingesta de datos: **Comandos HDFS: Flume, Sqoop, etc.**

» Procesamiento: **Hive, Pig o Cascading.**

» Almacenamiento: **HDFS y Hbase.**

4.1. Herramientas aportadas por plataformas cloud

Las tecnológicas proveedoras de infraestructura cloud también han incrementado en los últimos años sus herramientas para el desarrollo de proyectos basados en procesos streaming y batch.

Vamos a explorar los avances realizados, por ejemplo, por **Google** al respecto.

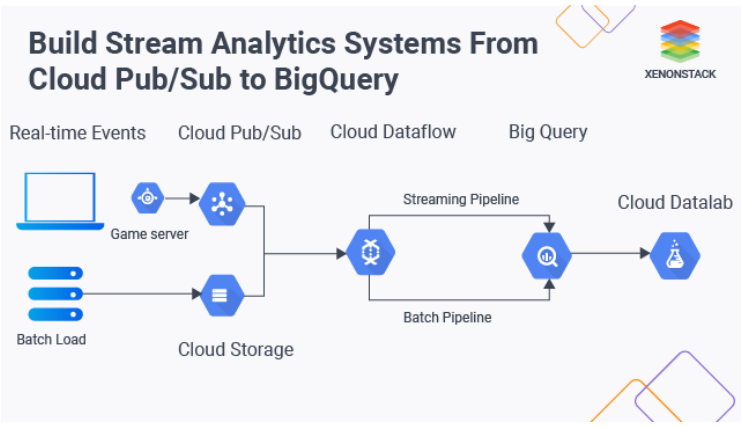

Fig.5. Pipeline de Google para procesos en tiempo real y batch.

Sobre la imagen previa, destaca **Dataflow**, un servicio provisto por Google para procesar datos que permite desarrollar casos de uso basados en procesos de datos en tiempos reales y en procesos batch.

Naturalmente, para ello, Google hace empleo de otros servicios de su suite, como **Cloud Pub/Sub**, servicios orientados a la recolección de datos en tiempo real, o **Cloud Storage**, un servicio de almacenamiento muy utilizado en almacenamiento de datos por lotes.

Vídeo 1. "Así se controla a las estrellas del balón"

https://bit.ly/3mTVIeZ

/ 5. Caso práctico 1: "Proyecto de sensorización: batch o streaming"

Planteamiento: Un ayuntamiento ha llevado a cabo una estrategia de sensorización a través de los principales puntos de la ciudad. Su idea es monitorizar los puntos de mayor criticidad de gestión en las ciudades basándose en la recopilación de grandes volúmenes de datos y del análisis avanzado sobre los mismos.

Nudo: Como paso previo a la ejecución del proyecto, surge la necesidad de hacer un diseño tecnológico que se adecúe en lo posible a las necesidades específicas del ayuntamiento. Una de estas acciones consiste en la selección de las herramientas del ecosistema Big Data que se ajusten a la recopilación, el procesamiento y al tipo de almacenamiento más adecuado para el proyecto. En concreto, y dada la temática del presente tema, el principal problema consiste en seleccionar qué tipo de proceso de datos emplear.

Desenlace: El arquitecto Big Data asignado para definir la solución de procesamiento de datos hace una lectura preliminar del pliego de prescripciones técnicas publicado por el ayuntamiento, en el cual se especifica la necesidad de monitorizar los puntos seleccionados en **tiempo real**. El objetivo del ayuntamiento no es otro que poder realizar intervenciones en aquellos puntos en los que los datos reflejen necesidad de intervención de urgencia: atascos, consecuencia de un semáforo estropeado; calle sin iluminación, consecuencia de farolas estropeadas, etc. Por tanto, parece claro que se deberán emplear herramientas basadas en **streaming**.

Fig.6. Ciudad inteligente.

/ 6. Caso práctico 2: "Evaluación de negocio: batch o streaming"

Planteamiento: Una empresa, del sector retail, propone obtener una visión lo más detallada posible de las principales estadísticas descriptivas de las diferentes tiendas del territorio nacional. Para ello, requiere de un análisis de los datos almacenados y registrados hasta el momento en los sistemas de sus tiendas.

Nudo: Así, la empresa requiere definir unas pautas tecnológicas que, según sus requerimientos de negocio, permitan a sus analistas aportar la mejor solución posible. Aquí es preciso aclarar el tipo de procesamiento de datos que mejor se adapte a la necesidad: procesamiento batch o streaming. En otras palabras, ¿el problema planteado requiere de un procesamiento de datos en tiempo real?

Desenlace: La respuesta es obvia: no. Aunque esta necesidad requiere de un almacenamiento previo, así como de una serie de agrupaciones y procesamientos sobre estos datos almacenados, parece evidente, por tanto, que las características del problema van más dirigidas a emplear procesos de tipo batch.

Fig.7. Análisis descriptivo de datos en retail.

/ 7. Resumen y resolución del caso práctico de la unidad

En esta unidad, hemos analizado las principales opciones de procesos Big Data: batch y streaming.

Hemos expuesto las características que definen cada tipo de proceso, especificando las diferencias entre uno y otro.

Por último, hemos conocido situaciones de aplicación asociadas a ambos procesos, sobre las que hemos planteado dos casos prácticos para evaluar el entendimiento de las pautas de elección.

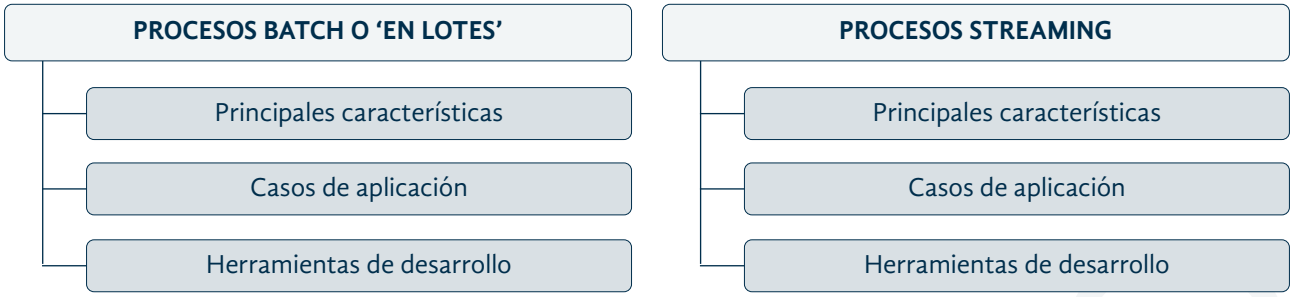

Fig.8. Esquema resumen del tema.

Vídeo 2. "Bath y streaming"
https://bit.ly/3pMiS8T

Resolución caso práctico inicial

Veamos una posible resolución del caso práctico inicial. Los aspectos que definen el tipo de proceso a seleccionar los siguientes:

1. Necesidad de disponibilidad del dato.
2. Nivel de sensibilidad del dato en lo que se refiere a normativa y regulación.
3. Nivel de desagregación o agregación del dato requerido.
4. Necesidad de análisis sobre franja temporal o espacio concreto.

/ 8. Bibliografía

¿Qué son los datos de streaming? Disponible en: https://aws.amazon.com/es/streaming-data/

Soluciones Link (marzo 2021). *Tráfico marítimo en tiempo real.* Disponible en: https://soluciones.link/internet/revisa-el-trafico-maritimo-en-tiempo-real/

Alex Rayón (septiembre 2016). *Paradigma batch para sistemas Big Data (I).* Disponible en: https://blogs.deusto.es/bigdata/paradigma-batch-para-sistemas-big-data-i/

Hadoop in Real World (junio 2020). *Batch Processing with Google Cloud DataFlow and Apache Beam.* Disponible en: https://www.hadoopinrealworld.com/batch-processing-with-google-cloud-dataflow-and-apache-beam/

Cibernos (julio 2021). *Cómo ayuda el Big Data a convertir las ciudades en smartcities.* Disponible en: https://www.grupocibernos.com/blog/como-ayuda-el-big-data-a-convertir-las-ciudades-en-smart-cities

BD16. *Batch vs. streaming.* Disponible en: https://www.precisely.com/blog/big-data/big-data-101-batch-stream-processing