MEDAC
Instituto Oficial de Formación Profesional

SISTEMAS DE BIG DATA

Minería de datos

5

ÍNDICE

/ 1. Introducción y contextualización práctica 3

/ 2. ¿En qué consiste la minería de datos? 4

/ 3. ¿Qué aporta el Data Mining? 5

/ 4. Principales métodos y algoritmos en la minería de datos 5

/ 5. Caso práctico 1: “Caso de aplicación de la metodología SEMMA” 7

/ 6. Caso práctico 2: “Relación entre Big Data y Data Mining” 7

/ 7. Resumen y resolución del caso práctico de la unidad 8

/ 8. Bibliografía 9

© MEDAC
Reservados todos los derechos. Queda rigurosamente prohibida, sin la autorización escrita de los titulares del copyright, bajo las sanciones establecidas en las leyes, la reproducción, transmisión y distribución total o parcial de esta obra por cualquier medio o procedimiento, incluidos la reprografía y el tratamiento informático.

OBJETIVOS

Conocer en qué consiste la minería de datos.

Conocer los principales métodos y algoritmos en lo que respecta a minería de datos.

/ 1. Introducción y contextualización práctica

El incremento de generación de información producido en los últimos años se ha traducido en un significativo aumento de iniciativas creadas para responder a necesidades de negocio y reforzar la toma de decisiones de las empresas y organismos, tomando como base la información objetiva aportada por los datos.

Por ello, surge la necesidad de integrar una serie de **procesos para el tratamiento y el análisis de los datos** para identificar **anomalías, patrones, correlaciones** y demás características que permitan **predecir y extraer resultados**.

En este contexto, tomando como base esta necesidad, adquiere especial relevancia la **minería de datos**, la principal temática sobre la que va a tratar la presente unidad.

A continuación, vamos a plantear un caso práctico a través del cual podremos aproximarnos, de forma práctica, a la teoría de este tema.

Escucha el siguiente audio, donde planteamos la contextualización práctica de este tema. Encontrarás su resolución en el apartado 'Resumen y resolución del caso práctico'.

Fig.1. Mineros extrayendo valor de los datos.

Audio intro. "Ejemplos de Data Mining"
https://bit.ly/3skqFL6

/ 2. ¿En qué consiste la minería de datos?

El volumen de datos generado crece de forma exponencial año tras año. No obstante, **información no es sinónimo estricto de conocimiento**, al menos, si esta información no está adecuadamente tratada y procesada para poder aportar un valor que ayude en una toma de decisiones objetiva.

La minería de datos hace referencia al conjunto de técnicas que permiten extraer conocimiento a partir de la información oculta entre los datos. Entre la información de valor que los datos pueden aportar al negocio, se encuentran la identificación de anomalías, correlaciones entre variables, identificaciones de grupos de datos por similitud de patrones o predicciones de valores continuos específicos.

En concreto, el concepto de minería de datos pivota, principalmente, sobre las siguientes fases específicas: **(i) recolección de datos, (ii) depuración de los datos, (iii) análisis descriptivo o predictivo sobre los datos e (iv) interpretación.**

Fig.2. Fases de Data Mining.

Los profesionales encargados de llevar a cabo tareas de minado de datos son los **'exploradores de datos o mineros de datos'**. Se encargan de identificar patrones e información de valor con el objetivo de ayudar, a la empresa o a la organización, a realizar una toma de decisiones objetiva.

Cabe enfatizar que **Big Data no es lo mismo que Data Mining**, aunque a menudo se confundan estos dos conceptos. Si bien Big Data hace, principalmente, referencia al almacenamiento , gestión y procesamiento de grandes volúmenes de datos, la minería abarca la globalidad de tareas que permite la extracción de información de valor sobre los datos almacenados, es decir, sobre el Big Data.

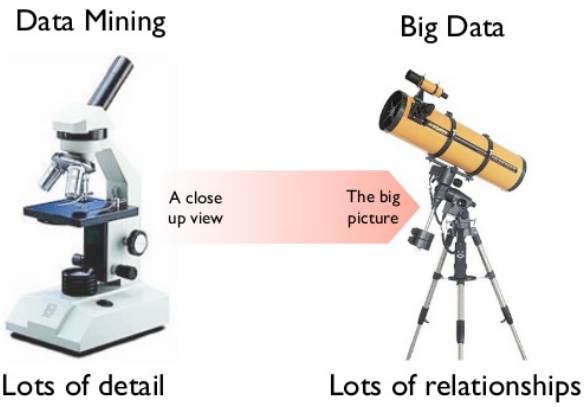

Fig.3. Data Mining vs. Big Data.

Enlaces de interés...

En el siguiente enlace, encontrarás un artículo comparativo entre el concepto de Data Mining y el de Big Data:
https://www.campusbigdata.com/big-data-blog/item/82-data-mining-vs-big-data

/ 3. ¿Qué aporta el Data Mining?

Las aportaciones de valor que proporciona la información para una toma de decisiones objetiva son incontables. Algunas de ellas pueden ser las siguientes:

- **Descubrimiento, por parte del analista, de información no esperada**, como paso previo al análisis de datos.
- **Capacidad de extraer valor de grandes volúmenes de datos** de una forma ágil y segura, sin información de valor aparente entre ellos.
- **Capacidad de extraer *insights* de negocio de fácil interpretación** por parte de decisores y analistas de negocio.
- **Permite identificar nuevas líneas de negocio**, facilitando la exploración de oportunidades identificadas entre los resultados obtenidos de los datos.
- **Permite identificar procesos de elevados costes** y dedicación asignada, de una forma rápida y objetiva.
- **Los datos** recopilados y analizados pueden ser empleados para más de un análisis, pudiendo, por tanto, ser **reciclables para más de un caso de aplicación**, en la propia empresa u organización.
- **Los modelos, algoritmos y cuadros de mando** aplicados sobre el conjunto de datos, para poder extraer valor de estos pueden ser empleados para más de un caso de aplicación. Igual que los datos, también pueden ser reciclables, acortando los tiempos para extraer valor de otros casos similares.
- **Las empresas y organizaciones pueden conocer más y de forma más personalizada a su cliente o usuarios**, pudiendo, entre otras cosas, segmentar los grupos según características.

Fig.4. El valor del Data Mining para negocio.

Vídeo 1. "Minería de datos contra corrupción"

https://bit.ly/3Gz4tlz

/ 4. Principales métodos y algoritmos en la minería de datos

Para la ejecución de proyectos de minería de datos existen una serie de metodologías. Destacan las dos detalladas a continuación:

- **La metodología SEMMA: *Sample, Explore, Modify, Model, Assess.*** Es una metodología de minería de datos propuesta por la popular empresa de *Business Intelligence* SAS. La propia empresa SAS la define como una metodología para la **selección, exploración y modelado de datos** para extraer valor sobre el negocio.

La imagen presentada a continuación plantea una visión general de las diferentes etapas de la metodología, así como de las actividades principales que la componen.

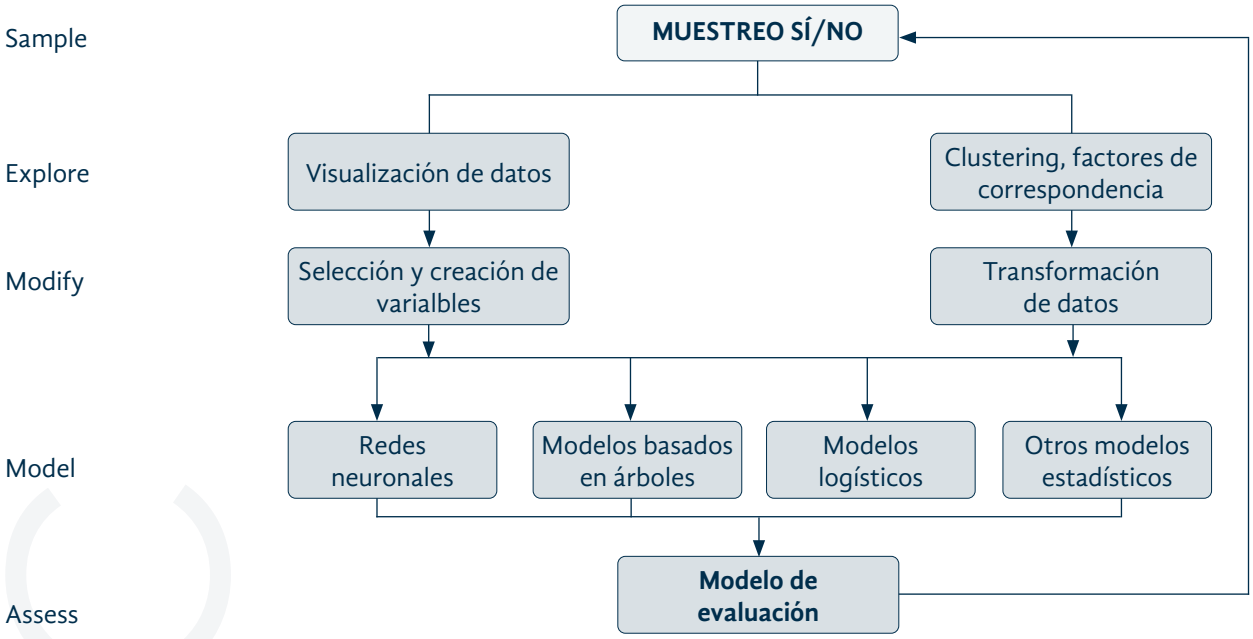

Fig.5. Metodología SEMMA.

- **La metodología CRISP-DM: *Cross Industry Standard Processfor Data Mining*.** Es un marco de trabajo cuya definición se basa en el ciclo de vida estándar de un proyecto de analítica avanzada de datos. En concreto, esta metodología cubre las fases de un proyecto, sus tareas y actividades características. Las fases específicas son:
  - » **Fase I: Definición de necesidades y comprensión del negocio y contexto del cliente.**
  - » **Fase II: Análisis de los datos.**
  - » **Fase III: Preparación de los datos.**
  - » **Fase IV: Modelado.**
  - » **Fase V: Evaluación de modelos.**
  - » **Fase VI: Despliegue del modelo.**

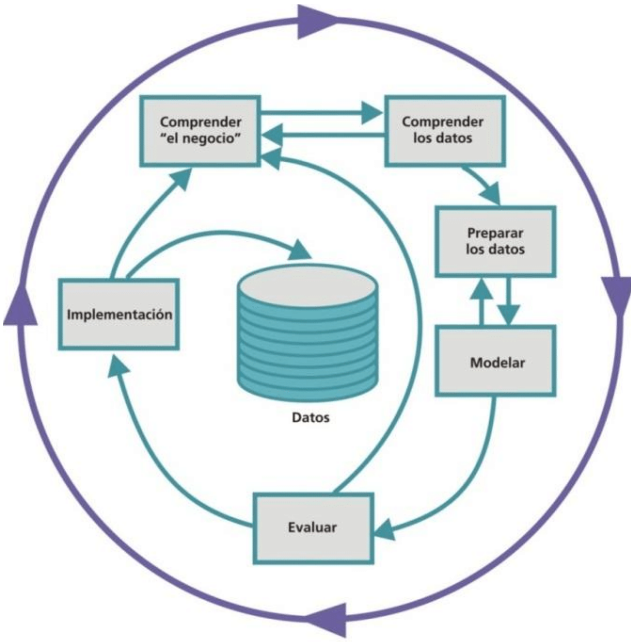

Fig.6. Metodología CRISP-DM.

Audio 1. "SEMMA y CRISP-DM"
https://bit.ly/3IZsi7M

/ 5. Caso práctico 1: "Caso de aplicación de la metodología SEMMA"

Planteamiento: Una empresa quiere implantar, en su departamento de analítica de datos, la metodología SEMMA, lanzada por SAS. Si bien el equipo empieza a asentar los principales conceptos teóricos que la componen, el próximo reto es buscar la aplicación real al proyecto.

Nudo: ¡Y, naturalmente, el primer proyecto llega! Surge la oportunidad de analizar unas encuestas realizadas por la compañía, con el objetivo de conocer más al cliente final y al usuario de sus servicios.

Desenlace: En primer lugar, según la metodología, hay que abordar la selección del **muestreo de los datos**. Para ello, es esencial que este sea lo suficientemente representativo como para evitar realizar el proyecto sobre el total de encuestas realizadas y agilizar así los tiempos de entrenamiento. A continuación, con el objetivo de validar las muestras seleccionadas, se lleva a cabo una **exploración de los datos**; esta podrá hacerse mediante la extracción de parámetros estadísticos o la realización de visualizaciones.

Una vez verificada la muestra, se procede a realizar las **modificaciones** oportunas sobre los datos, incluyendo la selección de las variables *features* y las variables *target* del proyecto, así como potenciales reducciones de variables. Luego se dividen los datos de muestra en **entrenamiento, validación y test**, para evaluar los modelos y ver su *performance* sobre un conjunto 'desconocido'. A continuación, sobre los datos modificados y preparados, se procederá a la **selección de algoritmos** de entrenamiento. De entre estos, se procede a la **evaluación y selección del algoritmo** que mejor se adapte a las necesidades del negocio. Sobre el algoritmo 'campeón' se lleva a cabo **el despliegue en producción**.

Fig.7. Análisis de datos sobre encuestas.

Enlaces de interés...

En el siguiente enlace, encontrarás un artículo sobre qué determina la representatividad de una muestra:
https://www.questionpro.com/blog/es/muestra-representativa-para-investigacion/

/ 6. Caso práctico 2: "Relación entre Big Data y Data Mining"

Planteamiento: A menudo Big Data y Data Mining o minería de datos son conceptos que se confunden. Ahora bien, ¿existe relación entre estos dos conceptos o no guardan relación entre sí?

Nudo: El principal objetivo entonces es identificar potenciales relaciones entre el amplísimo concepto que abarca el Big Data y lo que se conoce como Data Mining. Pero, ¿en qué se basa esta relación?

Desenlace: El Big Data es la práctica tecnológica vinculada con la recolección y el almacenamiento de grandes volúmenes de datos, de procedencia fiable, de amplia variedad, entre los datos recopilados y con una elevada velocidad de generación de los mismos. Estos datos almacenados representan un elevado volumen de información, en ningún caso tienen que vincularse con conocimiento de valor para la toma de decisiones de negocio. Es precisamente en este punto, donde entra en juego la minería de datos. Esta es el conjunto de procesos y técnicas que habilitan al negocio a extraer valor de las enormes cantidades de información almacenadas, es decir, del Big Data.

Por tanto, la minería de datos tiene sentido en aquellos casos en los que contemos con un elevado volumen de datos sobre el que aplicar las distintas metodologías y procesos vistos en la presente unidad.

A modo de analogía, es muy similar al concepto de una tierra con unas características propicias para la agricultura. En ella ya hay productos sembrados, pero requiere de un conjunto de cuidados y trabajos para poder convertir lo sembrado en alimentos que llevar a la mesa, bajo unas condiciones específicas.

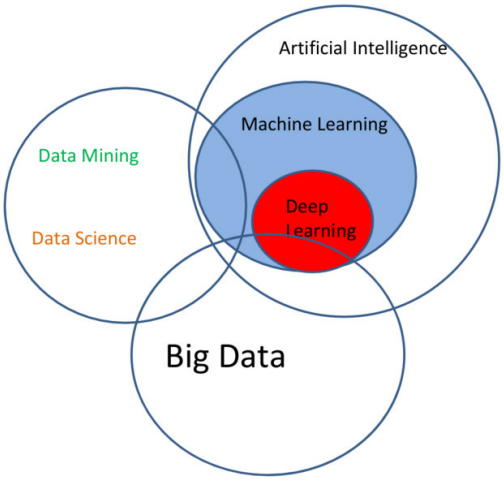

Fig.8. Relación entre Big Data y Data Mining.

/ 7. Resumen y resolución del caso práctico de la unidad

En esta unidad, hemos conocido el concepto de minería de datos, en qué se basa el término y qué beneficios aporta a las empresas la aplicación de las técnicas que lo conforman.

De forma adicional, hemos estudiado las metodologías de minería de datos de referencia más populares para los científicos de datos del momento.

Por último, hemos profundizado, mediante un caso práctico, en las diferencias y la relación entre el concepto de Big Data y el concepto de Data Mining.

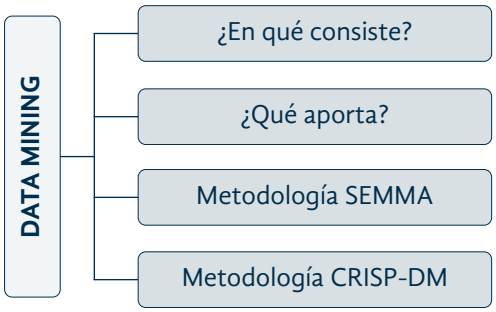

Fig.9. Esquema resumen del tema.

Resolución del caso práctico

Por último, en el caso práctico inicial, se lanza la pregunta: ¿En qué casos se aplica Data Mining? El Data Mining se aplica en todos los casos en los que se precisa la extracción de conocimiento sobre un volumen elevado de información. Por ejemplo:

- Predicción del número de ventas de un determinado producto en función del histórico y de fuentes de datos adicionales y complementarias.
- Predicción del número de turistas que van a visitar una determinada zona, en función de una serie de variables como aspectos económicos globales, fechas concretas, principales eventos en ese año, etc.
- Análisis para la segmentación de clientes y usuarios, en función de sus datos personales, sus preferencias y gustos y su histórico.
- Predicción del rendimiento de un determinado deportista, en función de una serie de datos acerca de su estado físico y sobre una serie de variables propias del deportista y de su entorno.

Vídeo 2. "Minería de datos"
https://bit.ly/3oQm8iP

/ 8. Bibliografía

SAS. *Minería de datos, qué es y por qué es importante*. Disponible en:
https://www.sas.com/es_es/insights/analytics/data-mining.html#dmimportance

Grupo Fractalia. *Data Mining: qué es y para qué sirve*. Disponible en:
https://fractaliasystems.com/data-mining-que-es-y-para-que-sirve-2/

Jesús S. Economía 3. *¿Qué es el Data Mining y cómo ayuda con grandes cantidades de datos?* Disponible en:
https://economia3.com/que-es-data-mining/

SNGULAR. CRISP-DM: *La metodología para poner orden en los proyectos*. Disponible en:
https://www.sngular.com/es/data-science-crisp-dm-metodologia/

Data Mining vs Big Data. Disponible en:
https://www.campusbigdata.com/big-data-blog/item/82-data-mining-vs-big-data

(Junio 2019) Jorge Romero. *Metodologías de Minería de Datos*. Disponible en:
https://jorgeromero.net/metodologias-de-mineria-de-datos/#Metodologia_SEMMA